Offline RL 기반 기업 신용등급 개선정책 학습

서강대학교 AI·SW대학원 DS·AI 전공

A67035 조종선

Github : https://github.com/CallMeDemian/Offline-RL-approach-for-Corporate-Credit-Rating-Recourse-Strategy

서강대학교 SOGANG UNIVERSITY

프로젝트 주제 및 목표

- **주제 : Offline RL 기반 기업 신용등급 개선정책 학습**
  – 기업의 재무제표는 한 해의 경영성과 정보를 함축하고 있는 데이터로,
  매년 금융기관 및 전문 신용평가사는 재무정보를 기반으로 기업의 신용등급을 측정한다
  – 이때, 기업의 올해의 재무제표를 State, 경영활동을 Action, 다음해의 재무제표를 State′,
  신용등급 변화를 Reward로 본다면 Offline RL 기반으로 기업 경영의 Policy와 그에 따른
  성과를 신용등급의 관점에서 평가가 가능하다는 가설을 세울 수 있다
- **목표**
  – 본 프로젝트의 목표는 기업 경영에 있어서의 절대적인 법칙을 찾는데 있지 않다
  다만, Historical Data set에 함축되어 있는 기업의 현실적인 Action distribution을
  진단하고 보다 **개선된 Action을 제안**하는데 의의가 있다
  – 또한, 실제 현실에서 Counterfactual Action을 취하고 그 결과(S′, R)를 관측하는 것은
  불가능하기에 본 Offline RL의 결과물을 **실제에 적용**하는데는 **한계점**이 있을 것으로 추측된다

선행연구

- **Algorithimic Recourse + Offline RL**
  - 자동화된 의사결정 시스템의 결과를 개선하기 위하여 개인에게 실행 가능한 행동을 추천하는 Algorithmic Recourse 연구가 이어졌으며(Karimi et al., 2022), 최근에는 이에 Offline RL 방법론을 적용한 연구 또한 진행되는 추세다(Ceccon et al., 2025).
  - 본 연구 또한 기업의 신용등급 개선 Action을 제안하는 **Algorithmic Recourse** 분야에 속하며, **Transformer Encoder** 기반 Representation Learning, **Advanced Weighted Behavior Clonning** + **Implicit Q Learning**을 통해 학습한 Q value를 향상시키는 Action을 제안한다
- **Data Augmentation + Reward Shaping**
  - Transition, Reward 등 데이터가 부족한 Offline RL의 한계를 보완하기 위하여 Counterfactual Data Augmentation(Hongye Cao et al., 2025) 등이 시도되었으며, Reward Sparsity를 보완하기 위해 Reward Shaping 기법들이 연구되었다
  - 본 연구에서는 데이터의 불균등한 Action distribution 및 Reward Sparsity를 보완하기 위하여 **Financial Simulator 기반 Counterfactual Augmentation** 및 **Auxiliary Dense Reward**를 활용하여 Offline RL의 한계점을 개선하고자 한다

방법론

- **개요**
  - 본 연구는 Evaluation metric인 가상의 신용평가모형(Oracle)을 개발하는 단계와 Offline RL을 통해 신용등급 개선 Policy를 학습하는 단계로 구분된다(Oracle : stage 0 ~ 1, RL : stage 2 ~ 6)
  - **Oracle**은 RL 학습단계에서는 참조하지 않는 **Only Evaluation metric**이며, **Offline RL**은 실제 주요 신용평가사가 부여한 **기업 신용등급**과 재무관리 이론에 기반한 **Aux Dense Reward**를 기반으로 학습한다.
- **상세**
  - **(Oracle)** 신용평가모형 중 전통적인 Score Card 기반 모형(Alpha), Logit Model 구조 모형(beta), ML 기반 XGBoost 모형(Gamma) 3가지 모형을 개발하며, 각 모형은 동일한 변수를 사용한다
  - **(Offline RL)** Stage3 Transformer Encoder가 기업의 재무정보를 보고 Representation을 학습하여 전달하고, Stage4 Behavior Clonning은 Historical Data set으로부터 Action을 사전 학습하며, Stage 5 IQL은 Encoder + Behavior Clonning을 출발점으로 삼아 RL 학습을 진행하게 된다

    이는 전체 데이터셋(한국 상장사 재무제표 데이터 70,777건) 중 **신용평가사의 신용등급 데이터**가 **확보된 데이터셋(rated firm-year 4,924건)이 작아** 이를 보완하기 위함이다

방법론 구조도

신용평가모형(Oracle)

Stage 0
Raw 재무제표 70,777건
+ 신용평가사 등급 매칭
→ 4,924건 rated firm-year

Stage 1
(1) rated firm-year 4,924건
+ 재무제표 결합 → Panel
(2) firm-year 재무비율 산출
→ 26개 재무모형 변수 후보
(3) 비재무군 데이터 전처리
→ 28개 비재무 변수 후보
(4) 11개 재무&비재무 변수,
가중치, 등급 Cut-Off 산출

Output
신용평가모형(Oracle)
Alpha, Beta, Gamma

강화학습(Offline RL)

Stage 2

Stage 2A
Historical Raw Data
→ 10 Dimension
Action Space 추출

Stage 2B
Stage1 Output
→ Broad / Rated
Train(~'23) / eval('24)
Transition 생성

Stage 2C
Stage2B Transition
→ 11개 Action 후보
매핑, Reward 계산

Stage 2D
Stage2C Output
→ rated firm-year
기반 Transition 증강
(3,159T → 34,749T)

Broad Input

Stage 3
Self Supervised Encoder(Transformer 구조)
→ (Feature) 129개 재무비율, 2개 범주형

State
Representation

Rated

Broad Input

Stage 4
Class&Family Balanced Behavior Cloning
→ 11개 Action 사전학습(Soft Target)

Historical behavior
Pretrained Action

Stage 5
Implicit Q Learning
→ Encoder Representation,
BC의 사전학습 Action을
출발점으로 학습(Critic, Actor)
→ **신용등급 데이터가 있는 Rated 데이터만 학습(~'23년 Train Set만)**
→ Rated Transition(3,159) /
Counterfacutal 증강(34,749)
중 선택 가능

'24년 State

Offline RL Policy

Stage 6
Multi Oracle Offline RL Evaluation
→ '24년 State + Action + Financial Simulator

방법론 - 데이터 수집 및 전처리

- **데이터셋 개요**
  – 한국 상장사(KOSPI/KOSDAQ/KONEX) 재무제표 70,777건 (폐지사 포함 → 생존편향 완화)
  – Temporal Split : Train ~'23년 / Eval '24년. Oracle과 RL 동일한 시간 분할 (미래 데이터 look ahead 방지)
- **Oracle 데이터 전처리 과정(Stage0~1)**
  – (Stage0) Raw 재무제표에서 신용평가사 외부등급 매칭 → 4,924건 rated firm-year 확정
  – (Stage1) rated firm-year에 대해 재무비율 산출 및 변수 선정(Alpha, Beta, Gamma 모두 동일 데이터 사용)
    - 모형 학습 : '02~ '19년 2,032건, 시간 외 검증(OOT): '20~'23년 1,790건
- **RL 데이터 전처리 과정(Stage2)**
  – (2A) Raw 재무제표에서 10차원 연속 Action 벡터 추출 (매출성장률, 원가율변화, 부채변동 등)
  – (2B) firm_id × fiscal_year 연속 쌍으로 Transition(s, a, s') 구축 + Broad / Rated 분리
    - Broad(전체 상장사, 등급 불필요) → Stage 3 Encoder, Stage 4 BC 학습용
    - Rated(등급보유만, Reward 계산 필요) → Stage 5 IQL 학습용
  – (2C) 10D 연속 Action을 11개 이산 후보에 L1 매핑(Candidate Projection) + Dense Reward 계산 및 표준화
  – (2D) Rated Transition에 대해 Financial Simulator로 Counterfactual Next-State 생성
    - 관측 3,159 Transition → Counterfactual 34,749 Transition (1:10 증강)

방법론 ① - 신용평가모형(Oracle)

- **구조**
  - **(Alpha)** NICE평가정보의 홈페이지에 공개된 모형 구조(재무모형 70% + 비재무모형 30%)를 기반으로 설계한 **Score card 모형**이며, **재무모형 6개 변수**(수익성, 안정성, 부채상환능력, 유동성, 활동성, 성장성) 및 **비재무모형 5개 변수**(산업위험, 경영위험, 영업위험, 재무위험, 신뢰도)를 기반으로 하며, 변수 → 표준화 → 구간화 → 단조 변환 → 가중치 최적화 → 등급 Cut-Off 단계로 개발
  - **(Beta)** 부도율을 직접 추정하는 **순서형 로지스틱 회귀(Ordered Logit)** 구조이며, 변수 → 표준화 → 로지스틱 회귀 → 임계치 추정 단계로 개발되며, 11개 변수는 Alpha와 동일하게 사용
  - **(Gamma)** 트리 앙상블 기반 **XG Boost 구조**이며, 변수 → XG Boost 회귀 → 점수화 → 등급 Cut-Off 매핑 단계로 개발되며, 11개 변수는 Alpha와 동일하게 사용

- **기타**
  - Data Set은 신용평가사 등급이 있는 rated firm-year 3,822건('02~'23년)이며, Split은 모형 학습 '02 ~ '19년 2,032건, 검증(OOT) '20 ~ '23년 1,790건, '**24년은 Cut-Off**임**(RL Evaluation에서 사용)**

    Stage 0에서 전처리하여 rated firm-year set 확정하고, Stage 1에서 재무모형 및 비재무모형 변수 후보군 데이터셋을 만들고, 변수와 신용등급 간 유의성, 다중공선성 등 고려하여 모형 개발

방법론 ② - Markov Decision Process 정의(Environment 설계)

- **Markov Decision Process 정의**
  - **(State)** 신용평가사의 등급이 존재하는 기업의 T년 시점 재무제표
    (단, SSL Encoder에 의해 129개 재무비율 + 2개 범주형 feature 추출 후 256D로 임베딩)
  - **(Action)** 기업 경영활동 중 재무적 의사결정이 가능한 10개 재무항목(10D Action Space)을
    기반으로, 전략의 일관성 관점에서 구성된 11개 Candidate Action Set.
    또한 기업의 재무제표 상 10D 변화를 기준으로 가장 가까운 Action set으로 Pseudo-labeling함
  - **(Reward)** 기업의 실제 신용등급 Notch 변화(AAA~D 10개 등급구간 기준)
    + Auxiliary Dense Reward ($\lambda m \cdot \Delta$Merton + $\lambda f \cdot \Delta$FCFF + $\lambda l \cdot \Delta$liquidity)

    Merton : Merton의 부도예측모형(1974)에 의한 부도거리
    FCFF : 기업의 잉여현금흐름으로, DCF법에 의한 기업가치 측정의 척도
    Liquidity : 기업이 보유한 현금 유동성(현금 보유 ↓ → 부도 발생 가정)
  - **(Transition)** 실측 기업의 신용등급 기반 Transition 데이터는 3,159건이나,
    Counterfactual Augmentation 기반 적용 시 모든 Transition에
    11개 Action을 취하였을 때 Next State를 Financial Simulator로 생성하여
    총 34,749개(=3,159개 × 11개 Action) Transition 생성 가능

방법론 ② - ⓐ 기업 경영활동 Simulation

- **Financial Simulator**
  - Financial Simulator는 기업이 영업하여 현금흐름이 흘러들어와 축적되는 구조에 착안하여, T년 시점 S와 Action을 기반으로 T+1년 시점 S′를 생성
  - 다만, 기업의 재무성과는 주요 재무비율(영업이익률, 부채비율 등)로 대표되지만, 실제 재무의사결정자(CFO)가 조절할 수 있는 것은 아니기에, **조절 가능성** 감안하여 **Tier Ⅰ, Ⅱ Action Space** 선정
  - **(Tier Ⅰ Action)** CFO가 직접 조절이 가능한 변수군
    부채구조 : 단기차입금, 장기차입금, 사채
    투자규모 : 유형자산 투자지출
    운전자본 : 재고, 매출채권, 매입채무 회전율
  - **(Tier Ⅱ Action)** 기업 경영활동에 따라 간접적 변동
    영업활동 : 매출성장률, 매출원가율, 판관비율

- **Financial Simulator 구조(회계 항등식 기반)**

① T년 시점 재무제표 State
매출 → 원가 → 판관비 → 영업이익
Business Plan(성장률 등)
10D Action(경영의사결정)

② 손익계산서
매출 → 원가 → 판관비 → 영업이익
← (Action) 매출성장, cogs, sga, ppe, 차입

③ 영업 Cash Flow
영업이익 + 감가상각 – 운전자본 변동
← (Action) 재고, 매출채권, 매입채무 회전율

④ 투자 Cash Flow
유형자산 취득/처분 (CAPEX)
← (Action) ppe_pct

⑤ 재무 Cash Flow
차입금 증감 + 사채 발행/상환
← (Action) s_dbt, l_dbt, bond

⑥ B/S Closing(Next State)
기말현금 = 기초현금 + 영업CF + 투자CF + 재무CF
“자산 = 부채 + 자본” 항등식 검증**(기말현금 부족 시 차입으로 조달 가정)**

방법론 ② - ⓑ 10 Dimension Action Space

구분	차원	의미	예시 (P50 보정 기준)
재무정책 (Tier 1) **기업이 직접 통제 가능**	ppe_pct	유형자산 투자 변화율	CX1: −7.4%
	short_debt_pct	단기차입금 변화율	DL1: −24% DL2: −39%
	long_debt_pct	장기차입금 변화율	DL1: −25% RF1: +38%
	bond_pct	사채 변화율	DL1: −33% RF1: +33%
	inv_turnover_chg	재고회전율 변화 (회전수)	WC1: +1.47
	ar_turnover_chg	매출채권회전율 변화 (회전수)	WC1: +1.08
	ap_turnover_chg	매입채무회전율 변화 (회전수)	WC2: −2.26 (지급 연장)
경영계획 (Tier 2) **경영 판단 제약적 변동**	revenue_growth	매출 성장률	본 연구에서 0 고정 (시나리오만)
	cogs_ratio_chg	매출원가율 변화 (%p)	OE1: −1.2%p OE2: −2.4%p
	sga_ratio_chg	판관비율 변화 (%p)	OE1: −0.7%p OE2: −1.5%p

각 기업의 한 해 경영활동을 10개 차원의 연속 벡터로 표현하며, 후보별 크기는 Historical Data 관측 중앙값(50%) 기준으로 보정된다.
P50 = Action Space별 관측된 기업 행동의 절대값 기준 중앙값. 이론적 최대(ACTION_BOUNDS)가 아닌 현실적 행동 크기.

방법론 ② - ⓒ 11 Candidate Action set

행동군	ID	ppe	inv	ar	ap	s_dbt	l_dbt	bnd	rev	cogs	sga	요약
Noop	A0	—	—	—	—	—	—	—	—	—	—	기준선
부채 축소	DL1	—	—	—	—	-24%p	-25%p	-33%p	—	—	—	소폭
	DL2	—	—	—	—	-39%p	-50%p	-50%p	—	—	—	중폭
차환	RF1	—	—	—	—	-29%p	+38%p	+33%p	—	—	—	단기→장기
Capex·WC	CX1	-7.4%p	—	—	—	—	—	—	—	—	—	설비투자↓
	WC1	—	+1.47	+1.08	—	—	—	—	—	—	—	운전자본 압축
WC+AP	WC2	—	+1.47	+1.08	-2.26	—	—	—	—	—	—	WC1+지급연장
비용 효율	OE1	—	—	—	—	—	—	—	—	-1.2%p	-0.7%p	소폭 절감
	OE2	—	—	—	—	—	—	—	—	-2.4%p	-1.5%p	중폭 절감
혼합	MX1	—	—	—	—	-24%p	—	—	—	-1.2%p	-0.7%p	비용+부채↓
	MX2	—	+1.47	+1.08	-1.13	-24%p	—	—	—	—	—	유동성 확보

10D Action Space를 기반으로, 전략정 방향성이 일관적인 그룹을 묶어 11개 Candidate Action set을 생성하였음
이는 10D Continuous Action Space로 직접 IQL을 학습하였을 때, RL이 학습한 Policy가 의미론적으로 일관성이 떨어졌기 때문.
따라서 Heuristic 반영하여 Action set 구성하였으며, 이 중 long_debt_pct 와 bond_pct는 historical 변동폭이 너무 커 최대값으로 clip되었음

방법론 ③ - Offline RL 알고리즘

Stage 3 · Self-Supervised Encoder (= MDP State 구현) — Broad (70,777)

입력 Broad phase1_pretrain	① 토큰화 각 재무비율=1토큰 값+FeatID+BlockID	② Transformer 4-layer · d=256 8 heads	③ CLS 256-D Firm 임베딩

MCM Masked Context Modeling	ACD Action-Conditional Dyn.	Contrastive NT-Xent · firm 정체성

Loss = 1.0·MCM + 0.5·ACD + 0.3·Contrastive · Reward와 무관

Stage 4 · Behavior Cloning (= MDP Action 11-class 모방) — Broad (70,777)

Encoder Frozen phase2_bc	BC Head Linear 256→11 Soft Target·11-class	π_BC 사전학습 분포	Epochs 80 · Batch 512 LR 1e-3 · WD 1e-4 BC Head = Stage 5 Actor 초기값

Stage 5 · Candidate-IQL (= MDP Reward로 최적 정책) — Rated (3,159 / 34,749)

Encoder+BC Frozen Rated Obs 3,159 CF 34,749	Twin-Q Critic $Q_1,Q_2(s,a)$·Smooth L1 Value V(s) expectile τ=0.85 Actor π(a|s) BC init · distill λ=1.5	advantage→weight adv=min(Q_1,Q_2)−V w=exp(β·adv) clamp(20) RL 신호 요약 r→Q→V→adv→w→π weight가 critic→RL	HP γ=0.6 τ=0.85 β=15 CQL α=0 Ep 80 B 128 LR 1e-4

Checkpoint · q_pareto_knee

Stage 6 · 정책 평가 + Oracle 관계 (학습 완료 후, 2024년 데이터)

학습된 Actor q_pareto_knee	행동 배정 2024·575 firm	Financial Sim next-state 생성	α/β/γ Oracle frozen 채점

- **Stage 3 : Self-Supervised Encoder (Transformer, d=256)**
  - 129개 재무비율을 각각 독립 토큰으로 변환
  - 132개 토큰 시퀀스 → 4-layer Transformer
→ CLS 토큰 = 256차원 임베딩
  - SSL 목적함수 : Loss = MCM + 0.5·ACD + 0.3·Contrastive
- **Stage 4 : Class & Family Balanced Behavior Cloning**
  - Encoder를 통해 관측된 행동 모방 (Soft Target, Broad 데이터 input)
  - Class Balance : 희소 후보(MX2, RF1) 가중 + Family Balance(균형)
  - BC는 IQL Actor의 출발점이며, BC가 특정 행동을 누락하면 IQL도 선택 불가(OOD)
- **Stage 5 : Candidate-IQL**
  - Stage 4 Encoder+BC를 초기값으로, Critic/Value/Actor를 동시 학습
  - Twin-Q Critic : target = r + γ(1−done)·V(s'), Smooth L1
  - Expectile Value : τ=0.85 비대칭 regression → Implicit Max 추출
  - AWR Actor : exp (β·advantage) × CE (logits, a) → Advantage 가중
  - Cross-Attention Critic Head : Firm-State × 후보 간 Attention
  - q_pareto_knee Checkpoint : Q ↔ Entropy Pareto Frontier 최적화
  - 학습 데이터 : Rated만 (~'23 Train Set)
  - 평가 : 실측값 Observed(3,159) 또는 Counterfactual 증강(34,749)

방법론 ④ - Evaluation metric

- **Stage 6 : Oracle based RL Evaluation**
  - Oracle(α/β/γ)은 RL 학습 단계에서 일절 참조하지 않는 only evaluation metric (Information Barrier)
  - Stage 5까지 학습 완료된 정책을 2024년 재무제표에 State 적용하여, Financial Simulator로 Next State 생성
  - 평가 대상 : 2024년 575 firm × 각 정책의 행동 → Financial Simulator → Oracle 채점 → 신용등급 평점 변화
  - **α (Isotonic Scorecard)** : 변수별 단조 보정(isotonic regression) → 가중합 → R_score → 등급
  - **β (Ordered Logit)** : 순서형 로지스틱 회귀로 부도율 직접 추정 → 임계치 기반 등급 부여
  - **γ (XGBoost)** : 트리 앙상블 회귀 → 점수화 → 등급 매핑
- **RL과 비교 대상 정책**
  - **C0_noop** : **No Action**, 2024년 State에서 아무런 Action을 하지 않고 Next State 생성하여 Oracle로 평가
  - **C2_weakest_component_rule** : Oracle 변수 11개 중 **평가점수가 가장 낮은 재무항목**을 선택하여, 해당 항목을 개선하는 Rule-based Heuristic (Oracle 구조 기반)
  - **C3_candidate_iql** : IQL이 학습한 Policy에서 **Q 값**과 **Action distribution entropy**를 Pareto 최적화 하는 Epoch을 선정
  - C3 변형 : q_argmax(Q만 최대화), q_rerank_at_k(상위 k개 Policy 중 Q값이 높은 것 재선택, k=3,5,7,9)
  - **Only Single Action** : 11개 Action 후보 중 1개를 **모든 firm에 동일하게 적용**했을 경우 (DL2, OE2, MX2, OE1 등)

실험환경

- **실험장비**
  - 장비 모델명 : Lenovo LOQ 15ARP9 노트북
  - 프로세서 : AMD Ryzen 7 7435HS(3.10 GHz), RAM 24.0GB(4800 MT/s)
  - **그래픽카드 : NVIDIA GeForce RTX 4060 Laptop GPU (8GB of GDDR6 VRAM)**
- **소프트웨어 환경**
  - 운영체제 : Windows 11
  - 개발환경 : Python 3.12 가상환경(.venv), Windows PowerShell, VS Code
  - 주요 라이브러리 : PyTorch(2.6.0+cu124), CUDA(12.4) pandas(3.0.3), numpy(2.4.6), scikit-learn(1.9.0), scipy, statsmodels, pyarrow
  - GPU 학습 : PyTorch CUDA backend 사용
- **실행 및 재현조건**
  - 프로젝트 경로 : C:₩Users₩UserName₩Desktop₩RL_repo
  - 주요 실행 스크립트 : run_oracle_stage0_stage1.ps1, run_rl_unified_stage3456.ps1
  - Deterministic(No seed) : Stage 0 ~ 2(데이터 전처리), Stage 6(Eval) / **Stochastic(Seed) : Stage 3 ~ 5(RL)**
  - Oracle 및 데이터 전처리 단계는 CPU 중심, Stage3~5 RL 학습은 GPU 중심으로 수행

실험결과 – Key Findings

- **데이터와 Offline RL의 구조적 한계**

데이터 · 레이블

① 실제 기업 action 관측 불가
→ **pseudo action labeling 사용**

② 외부 신용등급 보유 데이터 희소
(rated ≈ 4천 / transition ≈ 3천)

③ 등급이 실제로 변한 transition은 약 18%뿐

Action 구조

④ 재무제표만으로 firm별 알맞은 action 선택이 어려움 (firm-curated)

⑤ 11개 candidate에 명확한 우열
→ **단일 action(DL2)이 상당히 강함**

⑥ Oracle이 선호하는 action(DL2·MX2)은 historical 관측엔 희소함 → **Counterfactual**

⑦ Offline RL은 Out-of-Data action 학습이 본질적으로 어려움

Reward 신호

⑧ Base reward(등급 notch Δ)는 너무 희소
→ agent가 action을 학습하기 어려움
(등급변화 567T, 상향 291, 하향 276)

⑨ Dense aux reward가 필요하나, 평가자(Oracle)를 직접 참조해선 안 됨

데이터 출처 (data provenance)

파일 / 위치	행수	이 자료에서의 용도
multi_oracle_policy_eval.parquet (각 run/outputs/stage6_multi_oracle_eval/)	10,350 =575×18	정책별·firm별 Oracle α/β/γ 점수와 Δnoop (T1·T3·T4·T5·T6·T7)
phase1_pretrain_candidate.parquet col = projected_candidate_id	38,190	관측 행동 pseudo-label 분포(broad) = C_obs 가중치 (T2·T3)
phase3_iql_candidate.parquet col = reward_raw_notch / reward_aux_*	3,159 (dev1584/oot1575)	rated transition의 base·aux reward 분포·통계 (T8a)
phase3_iql_counterfactual_candidate__P50.parquet col = candidate_id / delta_*_capacity	34,749 =3,159×11	행동별 capacity Δ = aux 성분 기전 (T8b)
run 디렉토리 × 7 seed (rl_unified_...{s1..s5,s3a,s3b})	—	멀티시드 안정성 (T7)

실험결과 – Key Findings (Framework)

- **희소성을 극복하기 위한 설계**
  - Rated Transition이 3,159개로 적고, 그 중 Reward가 발생하는 Transition은 567개에 불과하여 적은 데이터로 RL Agent를 학습시킬만한 설계 필요
  - **(Multi layer 사전학습)** 70,777건의 풍부한 Unrated Broad 데이터셋을 활용하여 Encoder로 Representation을, Behavior Cloning으로 기업의 Historical Action을 사전학습한 후, **Rated 데이터셋 3,159건으로 IQL을 최종학습**하는 방안 채택
  - **(Auxiliary Reward)** 신용등급 변화라는 Base Reward는 567건으로 희소하기에 전체 Transition의 80% 이상이 무보상이며, 따라서 **Merton**의 부도 모형, 기업가치(DCF)의 기초인 **FCFF**, 그리고 **Liquidity**를 보조로 사용하여 Reward Sparsity 해소
  - **(Semantic Allignment)** 10D Continuous Action Space를 RL이 직접 학습하면 전략적으로 일관된 Policy를 학습 못하는 단점이 있어, Heuristic 기반 **11개 Candidate Action set** 설정하고 RL이 선택할 수 있게 하여 전략적 일관성 강화

70,777
Raw 재무제표
(KOSPI/KOSDAQ/KONEX, 폐지사 포함)

▶

4,924
rated firm-year
(외부 신용등급 매칭)

▶

3,159
관측 Transition
(IQL 학습 대상, rated)

▶

567
등급 변화 transition
(17.9%, 나머지 82.1%는 무보상)

Temporal split 학습 ~2023 / 평가 2024 — Oracle·RL 동일 분할로 미래 데이터 look-ahead 차단. **Oracle 학습** 2002~2019 (2,032) / OOT 검증 2020~2023 (1,790).

실험결과 – Key Findings (Pseudo Action Labeling & BC)

- **기업의 Historical Action의 한계점 극복 필요**
  - 본 Offline RL의 Pseudo Action Labeling 및 Behavior Cloning은 본질적으로 기업의 Historical Action을 모방하도록 설계되었으나, **Historical Action은 Oracle Alpha 상 가치가 낮은 Action(CX1, WC1 등)의 비중이 크다**는 단점이 있다

관측된 기업 행동 분포(C_obs)

C_obs = Σ_a p_obs(a)·mean_Δnoop(a) | p_obs: projected_candidate_id 빈도(n=38,190) · Δnoop: T1 단일행동값(n=575)

행동	count	p_obs	α Δnoop	α 기여	β Δnoop	β 기여	γ Δnoop	γ 기여
A0 (noop)	3,436	0.0900	+0.0000	+0.00000	+0.0000	+0.00000	+0.0000	+0.00000
DL1	1,900	0.0498	+0.2781	+0.01384	+0.0250	+0.00124	+0.3440	+0.01712
DL2	**753**	**0.0197**	**+0.5199**	**+0.01025**	**+0.0440**	**+0.00087**	**+0.5840**	**+0.01152**
RF1	2,370	0.0621	+0.1241	+0.00770	+0.0138	+0.00086	+0.1593	+0.00989
CX1	**10,954**	**0.2868**	**+0.2002**	**+0.05742**	**+0.0128**	**+0.00366**	**+0.1864**	**+0.05347**
WC1	**6,270**	**0.1642**	**+0.3068**	**+0.05036**	**+0.0184**	**+0.00303**	**+0.2690**	**+0.04416**
WC2	3,015	0.0789	+0.4795	+0.03785	-0.0140	-0.00111	+0.4164	+0.03287
OE1	**4,099**	**0.1073**	**+0.3064**	**+0.03288**	**+0.0889**	**+0.00954**	**+0.1744**	**+0.01871**
OE2	**3,745**	**0.0981**	**+0.5700**	**+0.05589**	**+0.1764**	**+0.01730**	**+0.3728**	**+0.03656**
MX1	955	0.0250	+0.5003	+0.01251	+0.1091	+0.00273	+0.4389	+0.01097
MX2	**693**	**0.0181**	**+0.6013**	**+0.01091**	**+0.0240**	**+0.00044**	**+0.5665**	**+0.01028**
Σ = C_obs	38,190	**1.000**		**+0.28962**		**+0.03855**		**+0.24554**

검증 C_obs(α)=+0.290(broad) vs C3(α)=+0.612 → 2.11×. 리포트의 CX1 31.1%는 rated 분포(31.9%)와 일치 — 리포트는 rated 기준, 본 표는 broad(28.7%) 기준. 둘 다 C_obs≈+0.29~0.32.

실험결과 – Key Findings (Action Labeling & BC 분포 교정)

- **Low value Action 편중 완화 Solution : L1 Projection · Class Balance · Family Balance**
  - Offline RL은 BC distribution 외의 행동을 학습하기 어려움. BC의 Low value Action 편중(CX1 28.7%·WC1 16.4%) 때문에 BC→IQL의 CX1 Action 비중이 높아지므로, **고가치 희소행동(DL2·MX2)**을 BC distribution에서 **보존**해야 한다

① L1 Projection

(active-intent 가중)

10D 연속 action을 의미축에 가중치를 준 L1로 후보에 매핑. 단순 L1은 애매한 행동을 noop으로 흘려보내지만 , active-intent는 의도를 살려 올바른 후보로 레이블링.

효과 - noop sink 회수

A0 비중 (raw L1) 33.7%

A0 비중 (active-intent) 9.0%

② Class Balance

(β=0.999, effective number)

빈도에 따라 역으로 가중치 적용. **흔한 저가치 Action 가중치↓, 희소·고가치 후보는 가중치↑** → BC가 희소행동을 누락하지 않도록 유도하는 장치

효과 - 표본 가중치

MX2 ×1.58 DL2 ×1.49 MX1 ×1.28 ↑

CX1 ×0.79 WC1 ×0.79 (저가치) ↓

③ Family Balance

(p=0.5 blend)

11개 행동을 6개 family(부채·차환·Capex/WC·비용·혼합·noop)로 묶어 **family 단위로 분포를 균형화**함 → 한 계열이 Action distribution을 독점하는 것을 방지

효과 - family 분포

Capex·운전자본 53.0% → 34.8% ↓

혼합(MX1·MX2) 4.3% → 10.5% ↑

종합 효과 — 관측 분포 → BC 사전분포 교정 → C3(RL) 최종 분포

행동	Oracle α 가치	관측 비중 (BC 타깃)	3-Lever 효과	C3(RL) 최종 비중	해석
CX1	저 (+0.20)	**28.7% (최다)**	CB ×0.79 ↓ · family ↓	**0%**	**저가치·고빈도 Action → 제거됨**
WC1	중 (+0.31)	16.4%	CB ×0.79 ↓ · family ↓	18.6%	억제되나 일부 잔존
DL2	고 (+0.52)	**2.0% (희소)**	CB ×1.49 ↑ · family ↑	**29.7%**	**고가치·저빈도 → 보존·증폭**
OE2	고 (+0.57)	**9.8%**	CB ×0.81 (유지)	**36.2%**	**고가치 → RL이 주력 채택**

핵심 3-Lever는 BC 사전분포를 교정해 '저가치 CX1 collapse'를 막고 고가치 희소행동을 살린다. 최종 비중은 그 위에서 IQL의 Q값(보상)이 결정
레버는 **필요조건**(없으면 IQL이 CX1에 갇힘), 분포 다양화는 보상·HP가 마무리. C3 분포는 s1 기준(seed별 상이).

실험결과 – Key Findings (Encoder)

- **Encoder의 학습 정도 ≠ 기업의 재무정보 Representation**
  - 본 실험에서 SSL Encoder의 목적함수로 MCM, ACD, Contrastive를 설정하였으나, 해당 목적함수가 **"기업별 알맞은 Action을 고르기 위한 재무정보"** 와는 차이가 있었던 것으로 보인다(Encoder는 RL Reward로 학습 X)
  - Batch와 Epoch을 늘려 학습하면 Train Loss는 떨어졌으나 IQL이 성능이 하향되는 추세를 보였고, Epoch을 15까지 줄이면 성능은 향상되었으나 Multi seed 안정성이 훼손되었다
  - 따라서 Encoder는 중간 수준인 **Batch 512, Epoch 30** 선에서 fix하고 다음 단계 진행하였다

Encoder 목적함수 $\mathcal{L} = 1.0\,\mathcal{L}_{\mathrm{MCM}} + 0.5\,\mathcal{L}_{\mathrm{ACD}} + 0.3\,\mathcal{L}_{\mathrm{Con}}$

Encoder Sweep

Encoder 설정	best val_loss	IQL 성능 경향
B512 · Epoch 15	1.6641 (최악)	성능 ↑ (높음)
B512 · Epoch 30 ← 채택	1.3815	**균형 (안정적)**
B256 · Epoch 50	1.2201	성능 ↓
B256 · Epoch 49 (s42)	1.1325 (최저)	성능 ↓ (낮음)

loss가 낮을수록 IQL 성능이 낮은 **역상관 관계** (Epoch 15 > 30 > 50).

Explanation

(Representation) Encoder의 학습은 **기업별 알맞은 Action** 결정하는 **Frim aware information과 정렬되지 않는다**. 과적합된 Encoder는 IQL이 사용하기 어려운 방향으로 firm 정보를 압축한다.

(Epoch 15) 성능은 가장 좋았으나 **multi-seed별 편차 과도**하여 사용 어려우며 재현성을 위해 Batch 512 · Epoch 30을 선택함

(Cross-Attention critic head) 표현 전달을 늘리려 Linear Head에서 교체하였으나 sparse reward에선 오히려 성능 하락하였음. 단, **Dense Aux Reward 도입 후엔 정상 작동함**(Finding 5).

실험결과 – Key Findings (IQL Critic & Actor)

- **Critic & Actor의 학습과 안정성 사이의 절충**
  - 본래 IQL은 Critic이 Offline Data set에서 Q와 V를 학습하고 Actor는 Critic이 높게 평가한 Action을 Advantage 기반으로 학습하지만, 본 실험에서 **Critic과 Actor가 학습한 Policy에 간극이 큰 문제**가 있었다
  - 따라서 Advantage 외에도 **Distillation 항을 추가**하여 Actor가 직접 Critic Policy를 모방할 수 있도록 하였으며, Critic의 Head를 Linear Head에서 **Cross Attention Head**로 변경하여 Encoder가 학습한 기업의 재무정보에 관한 Non linear Representation을 잘 캐치할 수 있도록 설계하였다

IQL의 Critic은 신용등급을 개선하는 가치(Q, V)를 학습했으나, Actor는 epoch을 늘려도 그 정책을 재현하지 못함(Stage 5 Epoch 80 ~ 150)

`r` 보상 → `Q(s,a)` Twin-Q Smooth L1 → `V(s)` Expectile τ=0.85 → `adv` min Q−V → `w` exp(β·adv) β=15, clamp → `π(a|s)` AWR Actor BC init

Critic 사슬 (가치 학습)

Actor (정책 추출)

진단 Actor가 Critic이 평가한 고가치 행동을 정책으로 옮기지 못함 → **Critic→Actor Distillation (CE, λ=1.5)** 추가.
Distill을 키우자 Actor가 Critic 정책을 잘 흡수하였으나, 지나치게 Distill이 커지면 Action distributio이 Single Action으로 Collapse 하였음

BC에 갇히면 안 되는 이유

BC 분포는 저가치 행동(CX1) 중심. Actor가 BC를 그대로 복제하면 Oracle 가치가 낮은 정책에 머문다

BC에서 너무 멀어지면 안 되는 이유

distill이 과하면 **단일 action으로 collapse(데이터 분포 이탈 = OOD)**. Offline RL은 데이터 밖 행동의 가치를 신뢰할 수 없으므로, BC 근방에 머물며 그 안에서 개선해야 한다.

실험결과 – Key Findings (Base & Aux Reward)

- **Sparse Baseline Reward 와 Dense Auxilliary Reward의 상관관계**
  - Baseline Reward는 전체 Transition 중 17.9%(567건)에만 신용등급 변화가 있어 학습이 어려우며, 따라서 기업 재무관리 분야에서 이론적 배경을 가진 **Merton, FCFF, Liquidity** 항을 Aux Reward로 사용하기로 하였다

Auxiliary Reward 상세

항	측정량 (시점 t) — 코드 확정	Δ (변화)	scale: clip(Δ/s, ±cap)	Λ(최종)
Merton*	**b = D / 총자산, D = 단기차입 + ½·장기차입 + 회사채** (KMV 부도점)	Δ_M = b_t − b_(t+H)	s = 0.171 (p95|Δ|), ±1.0	0.05
FCFF	**c_F = (영업CF − CapEx) / 총자산**	Δ_F = c_F(t+H) − c_F(t)	s = 0.249 (p95|Δ|), ±0.5	0.45
Liquidity	**c_L = (현금 + 단기투자) / 총자산**	Δ_L = c_L(t+H) − c_L(t)	s = 0.178 (p95|Δ|), ±0.5	0.45
Base	**rating_num (신용등급 notch)**	r_base = rating_num(t) − rating_num(t+H), 정수 (−7…+6)	- (이산, scale 없음)	—

* Merton 모형은 본래 수식에 부도율(PD)을 사용하나, Raw Data에서 부도율 측정 불가능하여 **본 실험은 KMV 모형에 따른 부도점을 Proxy 변수로 사용하였음**

Reward 성분 통계 (n=3,159)

성분 (컬럼)	mean	std	λ
reward_raw_notch (base)	-0.0003	0.5995	—
reward_aux_merton	-0.0002	0.0188	0.05
reward_aux_fcff	+0.0021	0.1392	0.45
reward_aux_liquidity	-0.0026	0.1239	0.45
reward_total_raw	-0.0010	0.6376	—
reward_train (표준화)	**-0.0018**	**0.9862**	—

Aux ↔ Baseline Reward 간 상관관계 (n=3,159)

성분	Pearson r	p-value
Merton	-0.0090	**0.6148**
FCFF	-0.0123	**0.4897**
Liquidity	+0.0177	**0.3191**

실험결과 – Key Findings (Aux Reward & Actor's learned Policy)

- **Dense Auxilliary Reward이 IQL Actor에 미치는 영향**
  - Aux Reward 중 **Merton 부도거리 항**은 IQL Actor가 학습하는 Action distribution 중 **DL2(강한 부채감소)에 크게 보상**하는 경향이 있었으며, DL2는 Oracle Alpha 점수 개선효과가 크기 때문에 **Actor의 성능을 개선**시키는 효과가 있었다
  - 그러나 **Merton 항**의 영향이 너무 크기 때문에 **가중치(λ_M)를 최소화**하고 **Liquidity 항의 가중치(λ_L)를 높여**, Agent가 기업이 보유한 현금으로 부채를 축소하려는 유인을 견제하는 방향으로 학습 진행하였다

Aux Reward가 IQL Actor의 Action distribution에 미치는 영향

행동	Δmerton (부도거리,+=개선)	Δfcff (잉여현금)	Δliquidity (현금,+=보유↑)	Oracle αΔ (Evaluator)
A0 (noop)	0.0052	0.0000	0.2907	+0.0000
DL1	0.0239	-0.0000	0.2628	+0.2781
DL2	**0.0353**	**0.0000**	**0.2642**	**+0.5199**
RF1	0.0166	+0.0008	0.2659	+0.1241
CX1	0.0016	0.0002	0.2028	+0.2002
WC1	0.0048	0.0001	0.2631	+0.3068
WC2	0.0054	-0.0000	0.2911	+0.4795
OE1	0.0040	-0.0005	0.2619	+0.3064
OE2	0.0078	-0.0007	0.2705	+0.5700
MX1	0.0223	-0.0001	0.2776	+0.5003
MX2	**0.0221**	**0.0001**	**0.2926**	**+0.6013**

src: phase3_iql_counterfactual_candidate__P50.parquet (n=34,749=3,159×11) · 행동별 평균 raw Δ · Oracle αΔ는 T1

Aux Reward 조합에 따른 Actor(C3)의 Major Action

Run	λ_M	λ_F	λ_L	C3 Major Action	C3–C2 α
28	0.30	0.00	0.90	MX2 54% (유동성 쏠림)	+0.08
30	0.10	0.35	0.78	MX2 78% (유동성 쏠림)	+0.05
24	0.15	0.10	0.50	**DL2 79% (부채 쏠림)**	**+0.64***
33	0.10	0.45	0.45	DL2 43% (분산)	+0.17
37 ★	**0.05**	**0.45**	**0.45**	**DL2 56% (균형·채택)**	**+0.12**

실험결과 – Key Findings (Counterfactual Augmentation)

- **Counterfactual Transition Augmentation – Historical Action의 가치-빈도 역전을 All Action 균등화로 교정**
  - Aux Reward 이후 Actor는 C2(Weakest improvement)를 따라잡았지만, Counterfactual 적용 이후 C2를 큰 격차로 추월하기 시작하며, 가장 Value가 높은 Single Action(MX2, DL2, OE2 등) 이상으로 성능 향상되었다
  - 기존 Offline RL은 Transition 당 학습 가능한 Action이 하나로 제한되지만, Counterfactual은 모든 Transition에 11개 Action 모두 증강함으로써 학습 가능한 신호를 늘린다. 다만 실질적으로 Contextual Bandit에 가까워지는 단점이 있다

Counterfactual Augmentation이 고가치 Action(MX2, OE2, DL2) 학습에 미치는 영향

행동	관측 빈도(BC) (n=3,159)	관측 비중 (%)	Counterfactual Aug. (전 행동 균등)	학습 reward (train)	Oracle αΔ (Evaluator)
MX2	63	2.0	3,159	0.617	+0.601
OE2	284	9.0	3,159	0.581	+0.570
DL2	57	1.8	3,159	0.620	+0.520
MX1	93	2.9	3,159	0.626	+0.500
WC2	239	7.6	3,159	0.574	+0.480
WC1	519	16.4	3,159	0.544	+0.307
OE1	393	12.4	3,159	0.552	+0.306
DL1	172	5.4	3,159	0.589	+0.278
CX1	1,100	34.8	3,159	0.385	+0.200
RF1	208	6.6	3,159	0.583	+0.124
A0 (noop)	31	1.0	3,159	0.607	기준

src: 관측 분포 = phase3_iql_candidate.parquet (n=3,159) · CF = phase3_iql_counterfactual__P50 (34,749=3,159×11) · Oracle αΔ는 stage6 α(575) · 반례 행동 base=0이라 행동별 신호는 시뮬 aux.

실험결과 – Key Findings (Pareto Knee Checkpoint Selection)

- **Pareto selection – 정책가치 Q와 Action 다양성 Entropy가 균형을 이루는 Frontier에서 Checkpoint 생성**
  – 이전의 Max Q selection은 Critic Q를 최대화하는 방식으로 Action 불균형이 강하였으나, 31번 실험부터 적용된 Pareto knee(Q 체감 시작점) selection은 Q를 5%만 양보(0.662 → 0.629)하며 11개 Action 모두 살렸음
  – 본 실험에서는 Pareto selection 구현을 간단화하기 위하여 정규화 후 최소목적 최대화 방식으로 구현되었으며, 이는 정규화 공간에서 이상점 (1, 1)까지 L∞(Chebyshev) 거리가 최소인 Frontier 상 점을 고르는 것이다 (argmax min(q_norm,e_norm) = argmin max(1−q_norm, 1−e_norm) (이상점 L∞·Chebyshev 거리))

Pareto frontier (Q proxy ↑ vs entropy →, 80 epochs)

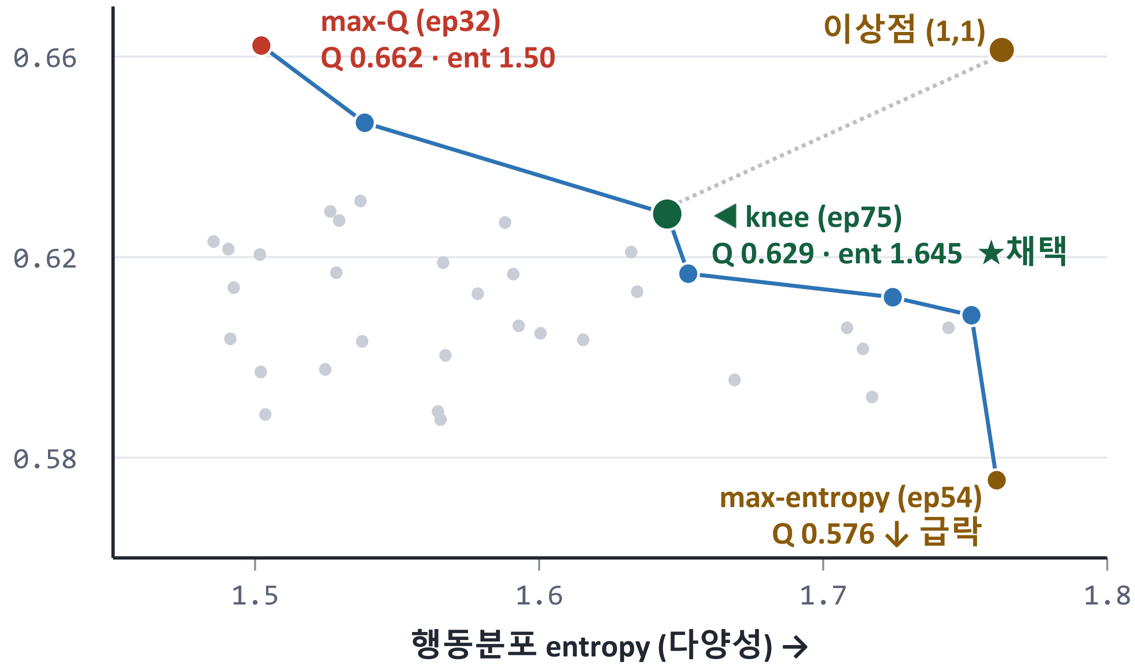

argmax 행동분포 — max-Q vs knee

행동	max-Q (ep32)	Pareto knee (ep75)
OE2	25.3	39.3
MX1	22.3	24.3
DL2	35.3	17.0
RF1	5.8	8.5
WC1	0.0 (drop)	3.8
CX1	0.0 (drop)	2.5
MX2	10.1	2.0
DL1	0.0 (drop)	0.9
OE1	0.0 (drop)	0.8
WC2	1.1	0.8
A0	0.0 (drop)	0.2

실험결과 – Key Findings (Hyperparameter 확정, Multi seed run)

- **M 0.05, F 0.45, L 0.45 Couterfactual Pareto selection 조합 확정 – 성능은 안정적, Action distributio은 편차 존재**
  - 확정된 Hyperparameter 조합은 seed에 따라 Action distribution이 계속 바뀌는 등 편차가 있었으나, Actor가 고르는 Major Action은 DL2, OE2, MX2 등 Oracle Alpha 기준 고가치 Action이었으며 **전체 성능은 C2 대비 높게 유지**되었다
  - IQL Actor가 학습하는 Policy가 seed에 따라 변하는 것은 **Encoder가 학습하는 Representation**, **BC가 학습하는 Historical Action, IQL의 Critic이 학습하는 Policy** 모두 달라져 영향을 받기 때문인 것으로 보인다((1/2/2) & (2/1/1) run 교호작용)

Aux Reward 확정 조합(M 0.05 F 0.45 L 0.45)의 Multi seed run

seed (S3/S4/S5)	C3 α	C2 α	C0 α	C3−C0 α	C3−C2 α	C3−C0 β	C3−C0 γ	C3 주력행동
s1 (1/1/1)	69.3702	69.2639	68.7583	+0.6119	+0.1063	+0.1048	+0.4986	OE2 36%
s2 (2/2/2)	69.3886	69.2639	68.7583	+0.6303	+0.1247	+0.0758	+0.5948	DL2 55%
s3 (3/3/3)	69.3436	69.2639	68.7583	+0.5854	+0.0797	+0.0708	+0.6020	DL2 61%
s4 (4/4/4)	69.3667	69.2639	68.7583	+0.6085	+0.1029	+0.0771	+0.5472	DL2 34%
s5 (5/5/5)	69.4449	69.2639	68.7583	+0.6866	+0.1810	+0.0414	+0.6073	MX2 62%
s3a (1/2/2)	69.4313	69.2639	68.7583	+0.6730	+0.1674	+0.1056	+0.5507	DL2 43%
s3b (2/1/1)	69.3862	69.2639	68.7583	+0.6279	+0.1223	+0.0795	+0.5470	DL2 39%
평균 (7 seed)	—	—	—	**+0.6320**	**+0.1263**	**+0.0793**	**+0.5639**	—
표준편차 (ddof=1)	—	—	—	**±0.0361**	**±0.0361**	**±0.0219**	**±0.0394**	—

핵심 C3−C0(α) seed std = ±0.0361 ≈ 정책효과(+0.632)의 1/18 → 결론은 seed 운에 무관. 단, 주력행동은 OE2/DL2/MX2로 seed마다 크게 달라짐(성능은 안정·분포는 불안정) 리포트 5-seed 부분집합(s1·s2·s3a·s3b·s3) 기준: +0.6257±0.0286.

src: 각 run/outputs/stage6_multi_oracle_eval/multi_oracle_policy_eval.parquet (n=575) · C0 동일(noop=시뮬레이션 무관)

실험결과 – Key Findings (최종실험 RL > C2 > C_obs)

- **최종 확정된 RL 결과는 C2, C_obs 보다 좋다**
  - IQL Actor는 C2 Heuristic (Oracle 상 약점 개선), C_obs (기업의 실제 Historical Behavior) 보다 좋은 결과를 보이며, 이는 기업이 실제로는 CX1(28.7%), WC1(16.4%) 등 신용평가모형(Oracle) 상 낮은 가치의 행동 비중이 높았기 때문으로 어쩌면 **실제 기업**은 RL과 달리 **경영여건 상 취할 수 있는 Action의 폭에 제약**이 있다고 해석할 여지도 있다
  - 다만, RL은 Oracle Beta에서는 C2에 근소하게 뒤지는 결과를 보이는데 이는 Oracle Alpha, Beta, Gamma가 동일한 11개 변수를 사용함에도 각각 구조와 가중치가 다르며, Beta에서는 Alpha와 달리 비용효율적인 Action(OE2, MX1, OE1)의 Score 효과가 높기 때문이다

동일 575 firm · 동일 Oracle α 채점. C_obs = 기업의 실제 관측 행동분포를 그대로 적용했을 때의 기대 점수

+0.290
C_obs · 관측 행동
(historical 분포)

+0.506
C2 · 휴리스틱
(약점 컴포넌트 규칙)

+0.612
C3 · RL
(IQL 처방)

2.11×
C3는 관측 행동(C_obs) 대비
약 2.1배의 등급 개선

이론 상한(firm별 최적 = +1.1306) 대비 포착률 · Oracle α

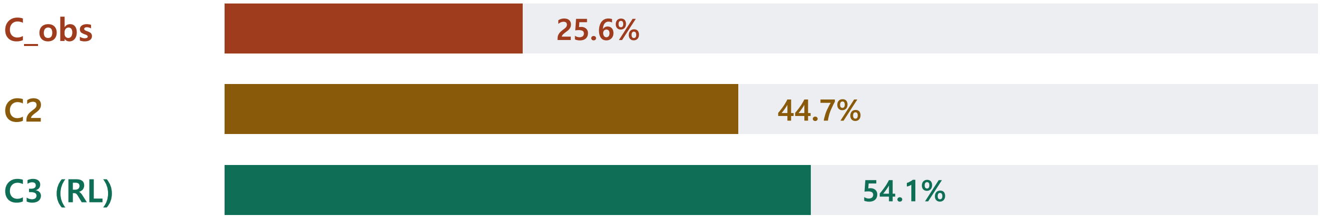

β backend에서는 C2가 C3보다 근소 우위(α·γ는 C3 우위). C_obs는 세 backend 모두에서 최하위.

이론 상한 (firm별 최적행동) 대비 C3, C2, C_obs 성과

Oracle	ceiling Δnoop	C3 / 천장	C2 / 천장	C_obs / 천장
α	+1.1306	**54.1%**	44.7%	25.6%
β	+0.1774	**59.1%**	**76.0%**	21.7%
γ	+0.9705	**51.4%**	41.4%	25.3%

실험결과 – Key Findings (최종 Offline RL 성능)

- **그러나 최종 Offline RL은 썩 좋지도, 나쁘지도 않다**
  - 전체 기업 중 58.6%에서는 최적의 Action이 2개 이상이며, 11개 모두 최적은 15.1%, No Action이 최적인건 17.9%이었다 이는 Oracle Alpha의 Score가 평가항목별 50개 구간으로 나뉘어 산출되기 때문에, 동일구간에서는 Score 변화가 없기 때문 (전통적 Score Card 모형의 특징)
  - RL이 정확한 최적 행동을 맞힌건 13.0%, 최적은 아니지만 Score가 유사한 것은 45.7%, State별 Top3 Action을 맞힌건 77.4%로, RL은 평가기준에 따라 성능이 좋다고도 나쁘다고도 평가할 여지가 있다

기업별 최적행동 현황

지표	firm 수	%	정의
exact tie (gap=0)	337	58.6%	최적 행동 ≥2개 점수 동일
ㄴ 11개 행동 전부 동점	87	15.1%	Oracle가 행동에 완전 무감
noop weakly optimal	103	17.9%	모든 비-noop 행동 ≤ 0

gap = (firm 최고 Δnoop) − (2nd) · src: multi_oracle_policy_eval (s1, n=575, Oracle α)

firm별 최적행동 분포 (α, tie-break = noop 우선)

행동	firm 수	%	행동	firm 수	%
WC2	110	19.1%	CX1	51	8.9%
A0(noop)	103	17.9%	DL1	48	8.3%
DL2	82	14.3%	OE1	37	6.4%
OE2	77	13.4%	MX2	33	5.7%
—	—	—	WC1 / MX1 / RF1	27/7/0	4.7/1.2/0%

RL(C3) 적중률 — 정의별

정의	firm 수	%
strict label match	75	13.0%
ceiling 달성 (value=max)	**263**	**45.7%**
value top-3	**445**	**77.4%**

분산 분해 (α 원점수)

지표	값	정의
firm-identity std	7.8637	575개 firm-mean의 std
action-effect std	0.1961	11개 action-mean의 std
ratio (action/firm)	2.49%	= 40.1× firm 우위
within-firm best−worst	1.2221	firm내 최선−최악 (평균)
firm score range	40.3	firm-mean 최대−최소

토의 및 결론– 실험결과에대한생각– 보완및개선사항

- **성과 및 Contribution**
  - 적은 규모의 Data set, Sparse Reward, Offline RL의 OOD 한계 등을 Encoder + BC + Counterfactual + IQL로 극복한 것은 해당 실험의 성과라고 생각된다
  - 기업의 재무제표로부터 Behavior Cloning으로 Historical Behavior 패턴을 추출하고, 가상의 신용평가모형(Oracle)을 개발하였으며, Financial Simulator를 통해 Counterfactual RL을 시도할 환경을 구축한 점 또한 성과라고 생각된다
  - C2 및 Signle best Action(DL2, 강한 부채축소)은 의미상 강한 Heuristic인데 이를 RL이 뛰어넘는 성능을 달성한 것 또한 성과라고 생각된다
- **보완 및 개선사항**
  - 이번 실험에서 다룬 Action은 오직 재무관리 관점의 의사결정 뿐이었지만, 실제 경영환경에서 재무 의사결정은 사업계획에 의존적이기에 재무 의사결정 만으로 신용등급 개선이 가능하다고 주장하기에는 무리가 있다
  - Financial Simulator의 Business Plan 기능은 실제 경영환경의 어려움(ex. 매출증가 하려면 CAPEX, 마케팅비용 등을 늘리는 Trade-off 존재)을 반영하지 못한다는 한계점이 있으며, 이를 개선하면 더욱 유용한 결과 도출 가능할 것이라 생각된다
  - M&A, 물적분할, SPC 설립 등 기업의 구조적 변화를 수반하는 의사결정을 검토하지 못한다. 이를 가능하게 하기 위해서는 Oracle의 약한 비재무 평가모형과 Financial Simulator 기능이 강화되어야 가능할 것으로 판단된다
  - RL이 기업별 특성 정보를 학습하여 알맞은 Action을 선택하는 Policy 학습이 약하였다. Encoder 학습 시 목적함수 변경, 혹은 구조적 변화가 있어야 성능 개선할 수 있을 것으로 추측된다

실험결과 요약 - 사전실험

#	Enc	CB	FB	Proj	A0	Dist λ	Critic	λ_M	λ_F	λ_L	γ	τ	β	Sel	n	C3 Actor 주력	C3−C2 α	C3−BSA α
1	B256 E30	-	-	–	-	–	Lin	–	–	–	0.8	0.9	10	-	421	-	-0.66	-1.250
2	(reuse)	-	-	–	-	–	Lin	–	–	–	0.8	0.9	1	-	421	-	-0.58	-1.170
3	(reuse)	✓	-	–	-	–	Lin	–	–	–	0.8	0.9	10	-	421	-	-0.30	-0.890
4	(reuse)	-	-	L1	-	–	Lin	–	–	–	0.8	0.9	10	-	421	-	-0.29	-0.880
5	(reuse)	-	-	L1	✓	–	Lin	–	–	–	0.8	0.9	10	-	421	-	-0.49	-1.080
6	(reuse)	-	-	WL1	-	–	Lin	–	–	–	0.8	0.9	10	-	421	noop 46%	-0.33	-0.920
7	(reuse)	✓	-	WL1	-	–	Lin	–	–	–	0.8	0.9	10	-	421	noop 37%	-0.26	-0.850
8	(reuse)	✓	-	WL1	-	2.0	Lin	–	–	–	0.8	0.9	10	-	421	MX1 41%	-0.14	-0.730
9	(reuse)	✓	-	WL1	-	0.3	Lin	–	–	–	0.8	0.9	10	-	421	noop 32%	-0.23	-0.820
10	(reuse)	✓	-	WL1	-	1.0	Lin	–	–	–	0.8	0.9	10	-	421	MX1 37%	-0.17	-0.760
11	(reuse)	-	-	–	-	1.0	Lin	–	–	–	0.8	0.9	10	-	421	CX1 69%	-0.64	-1.230
12	B256 E30	✓	-	WL1	-	1.0	Lin	–	–	–	0.8	0.9	10	-	421	DL2 24%	+0.05	-0.540
13	B256 E30 s2030	✓	-	WL1	-	1.0	Lin	–	–	–	0.8	0.9	10	-	421	DL2 37%	+0.17	-0.420
14	B256 E50	✓	-	WL1	-	1.0	Lin	–	–	–	0.8	0.9	10	-	421	A0 51%	-0.62	-1.210
15	B512 E15	✓	-	WL1	-	1.0	Lin	–	–	–	0.8	0.9	10	-	421	OE2 33%	+0.18	-0.410
16	B512 E30	✓	-	WL1	-	1.0	Lin	–	–	–	0.8	0.9	10	-	421	DL2 30%	+0.09	-0.500
17	B512 E50	✓	-	WL1	-	1.0	Lin	–	–	–	0.8	0.9	10	-	421	MX2 56%	-0.06	-1.170
18	B256 E30	✓	-	WL1	-	1.0	CA	–	–	–	0.8	0.9	10	-	421	DL2 34%	+0.11	-0.480

사전실험: BC·Projection·Class/Family Balance·Distillation·Encoder 정련 단계. BSA = Best Single Action (전 firm에 동일 Action 적용 시 최고 성과). Runs 1-11은 1st run Encoder 재사용, Reward는 sparse (notch Δ only).
✓ = 적용, – = 미적용/기본값, P = Pareto Selection.

실험결과 요약 – 본 실험

#	Enc	CB	FB	Proj	A0	Dist λ	Critic	λ_M	λ_F	λ_L	γ	τ	β	Sel	n	C3 주력	C3–C2 α	C3–BSA α
19	B512 E30	✓	-	WL1	-	1.0	Lin	0.5	0.1	–	0.8	0.9	10	-	421	MX2 30%	-0.24	-0.823
20	(skip)	✓	-	WL1	-	3.0	Lin	0.5	0.1	–	0.8	0.9	10	-	421	MX2 42%	-0.06	-0.650
21	(skip)	✓	-	WL1	-	3.0	Lin	0.5	0.1	–	0.8	0.7	10	-	421	MX2 34%	-0.13	-0.713
22	**(skip)**	✓	✓	**WL1**	**-**	**3.0**	**CA**	**0.1**	**0.2**	–	**0.8**	**0.9**	**10**	**-**	**421**	**DL2 52%**	**+0.77**	**-0.124**
23	(skip)	✓	✓	WL1	-	3.0	CA	0.15	0.15	0.15	0.8	0.9	10	-	421	DL2 48%	+0.81	-0.082
24	(skip)	✓	✓	WL1	-	3.0	CA	0.15	0.1	0.5	0.75	0.9	15	-	421	DL2 79%	+0.64	-0.042
25	(skip)	✓	✓	WL1	-	3.0	CA	0.15	0.1	0.5	0.75	0.7	6	-	421	DL2 78%	+0.63	-0.052
26	(skip)	✓	✓	WL1	-	3.0	CA	0.05	0	0.5	0.75	0.7	6	-	421	DL2 54%	+0.55	-0.132
27	**(skip)**	✓	✓	**WL1**	**-**	**1.0**	**CA**	**0.15**	**0.2**	**0.05**	**0.75**	**0.7**	**6**	**-**	**575**	**DL2 81%**	**+0.10**	**+0.007**
28	(skip)	✓	✓	WL1	-	3.0	CA	0.3	0	0.9	0.6	0.9	30	-	575	MX2 54%	+0.08	-0.012
29	(skip)	✓	✓	WL1	-	3.0	CA	0.15	0.25	0.6	0.8	0.9	10	-	575	DL2 53%	+0.12	+0.030
30	(skip)	✓	✓	WL1	-	3.0	CA	0.1	0.35	0.78	0.6	0.9	30	-	575	MX2 78%	+0.05	-0.042
31	**(reuse)**	✓	✓	**WL1**	**-**	**3.0**	**CA**	**0.1**	**0.35**	**0.78**	**0.6**	**0.9**	**30**	**P**	**575**	**DL2 48%**	**+0.14**	**+0.048**
32	(train)	✓	✓	WL1	-	1.5	CA	0.3	0.3	0.3	0.6	0.8	12	P	575	DL2 76%	+0.10	+0.004
33	(skip)	✓	✓	WL1	-	1.5	CA	0.1	0.45	0.45	0.6	0.85	15	P	575	DL2 43%	+0.17	+0.078
34	(skip)	✓	✓	WL1	-	1.5	CA	0.1	0.6	0.5	0.6	0.85	10	P	575	DL2 42%	+0.09	-0.007
35	(skip)	✓	✓	WL1	-	1.5	CA	0.05	0.5	0.45	0.6	0.85	15	P	575	DL2 36%	+0.09	-0.003
36	(skip)	✓	✓	WL1	-	1.0	CA	0.1	0.45	0.45	0.6	0.85	15	P	575	DL2 44%	+0.14	+0.043
37	(train)	✓	✓	WL1	-	1.5	CA	0.05	0.45	0.45	0.6	0.85	15	P	575	DL2 56%	+0.12	+0.029

본실험: Reward shaping(λ_M/F/L) 및 IQL HP(γ/τ/β) 탐색. **#22부터 Counterfactual Augmented Transition 전환, #27부터 New Oracle(eval 575) 전환, #31부터 Pareto Knee Selection 적용**
Enc: (skip) = 이전 Encoder 재사용, (train) = 해당 run에서 신규 학습. A0 = A0 noop threshold.

실험결과 요약 – 최종실험

#	Enc	CB	FB	Proj	A0	Dist λ	Critic	λ_M	λ_F	λ_L	γ	τ	β	Sel	n	C3 주력	C3–C2 α	C3–BSA α
38	B512 E30 s1	✓	✓	WL1	-	1.5	CA	0.05	0.45	0.45	0.6	0.85	15	P	575	OE2 36%	**+0.11**	**+0.011**
39	B512 E30 s2	✓	✓	WL1	-	1.5	CA	0.05	0.45	0.45	0.6	0.85	15	P	575	DL2 56%	**+0.12**	**+0.029**
40	B512 E30 s3	✓	✓	WL1	-	1.5	CA	0.05	0.45	0.45	0.6	0.85	15	P	575	DL2 61%	**+0.08**	**-0.016**
41	B512 E30 s4	✓	✓	WL1	-	1.5	CA	0.05	0.45	0.45	0.6	0.85	15	P	575	DL2 34%	**+0.10**	**+0.007**
42	B512 E30 s5	✓	✓	WL1	-	1.5	CA	0.05	0.45	0.45	0.6	0.85	15	P	575	MX2 62%	**+0.18**	**+0.086**
43	s1/(s2)	✓	✓	WL1	-	1.5	CA	0.05	0.45	0.45	0.6	0.85	15	P	575	DL2 43%	**+0.17**	**+0.072**
44	s2/(s1)	✓	✓	WL1	-	1.5	CA	0.05	0.45	0.45	0.6	0.85	15	P	575	DL2 39%	**+0.12**	**+0.027**
μ±σ	**(동일)**	✓	✓	**WL1**	**–**	**1.5**	**CA**	**0.05**	**0.45**	**0.45**	**0.6**	**0.85**	**15**	**P**	**575**		**+0.13±0.03**	**+0.031**

최종실험: 동일 조건(M=0.05 F=0.45 L=0.45) 하 멀티시드 안정성 검증. C3–C2 α: +0.08 ~ +0.18 (평균 +0.13±0.03), C3–BSA α: –0.016 ~ +0.086 (평균 +0.031). 7개 seed 중 6개 rank 1/18.
Runs 43-44는 S3/S4-5 분리 seed 교차 실험.

실험결과 요약 – 18개 정책 전체 Oracle 원점수

정책	종류	α mean	α Δnoop	β mean	β Δnoop	γ mean	γ Δnoop
C0_noop	기준	**68.7583**	**+0.0000**	**64.8948**	**+0.0000**	**67.3464**	**+0.0000**
C2_weakest_component_rule	휴리스틱	**69.2639**	**+0.5056**	**65.0296**	**+0.1348**	**67.7481**	**+0.4017**
C3_candidate_iql	RL	**69.3702**	**+0.6119**	**64.9996**	**+0.1048**	**67.8450**	**+0.4986**
C3_q_argmax	RL변형	69.3106	+0.5524	64.9563	+0.0615	67.8503	+0.5039
C3_q_rerank_at_3	RL변형	69.3559	+0.5977	64.9776	+0.0829	67.8648	+0.5184
C3_q_rerank_at_5	RL변형	69.3380	+0.5798	64.9658	+0.0711	67.8723	+0.5259
C3_q_rerank_at_7	RL변형	69.3392	+0.5809	64.9609	+0.0661	67.8646	+0.5182
C3_q_rerank_at_9	RL변형	69.3243	+0.5660	64.9590	+0.0642	67.8634	+0.5171
MX2_liquidity_rescue	단일	69.3595	+0.6013	64.9188	+0.0240	67.9129	+0.5665
DL2_deleverage_moderate	단일	69.2782	+0.5199	64.9388	+0.0440	67.9304	+0.5840
OE2_cost_efficiency_moderate	단일	69.3282	+0.5700	65.0712	+0.1764	67.7192	+0.3728
MX1_cost_and_deleverage	단일	69.2586	+0.5003	65.0038	+0.1091	67.7852	+0.4389
WC2_supplier_financing	단일	69.2377	+0.4795	64.8807	-0.0140	67.7628	+0.4164
WC1_working_capital_tightening	단일	69.0650	+0.3068	64.9132	+0.0184	67.6153	+0.2690
DL1_deleverage_mild	단일	69.0363	+0.2781	64.9198	+0.0250	67.6904	+0.3440
OE1_cost_efficiency_mild	단일	69.0646	+0.3064	64.9836	+0.0889	67.5207	+0.1744
CX1_capex_discipline	단일	68.9584	+0.2002	64.9075	+0.0128	67.5328	+0.1864
RF1_short_debt_refinance	단일	68.8823	+0.1241	64.9086	+0.0138	67.5057	+0.1593

src: multi_oracle_policy_eval.parquet (s1, n=575) · 파생: BSA=MX2(최고 단일) · C3−BSA(α)=+0.0106 · C3−C2(α)=+0.1063 · 단일 9종 αΔnoop 내림차순

실험결과 요약 – Encoder Sweep

ID	batch	epoch	mask	seed	best val_loss	사용 run
E_B256_EP30_SEED0	256	30	0.3	0	1.4404	①사전실험, ②β=1, ③~⑦초기실험
E_B256_EP50_SEED42	256	49	0.3	42	1.1325	B256_E50_P50/P65/P75
E_B512_EP15_SEED1	512	15	0.15	1	1.6641	B512_E15_P50
E_B512_EP30_SEED1	512	30	0.15	1	1.3815	B512_E30_*, cell_001/002, phase0/1, cross_attn
E_B512_EP50_SEED42	512	50	0.3	42	1.2201	B512_E50_P65/P75

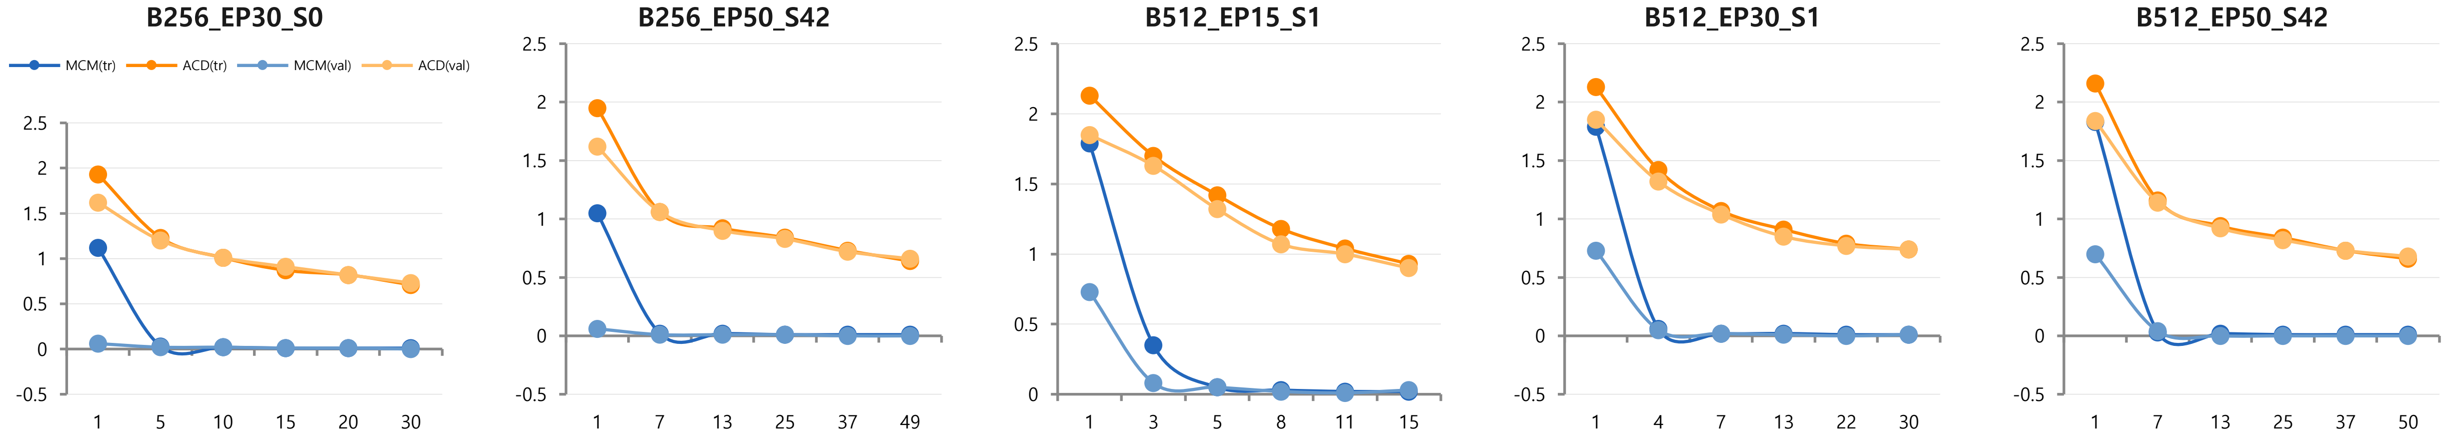

best val_loss 비교

진단

- Encoder가 학습하는 Representation은 IQL 단계에서 Critic 및 Actor가 선택하는 Action의 종류에 지대한 영향을 미침
- 그러나 학습이 잘된(loss ↓) Encoder가 무조건 우수한 IQL 성능으로 이어지는 것은 아님. 오히려 Epoch이 낮아질수록 성능이 증가(Epoch 15 > 30 > 50)
- Batch 256 대비 512가 다소 안정적인 것으로 보이며, Epoch 15는 multi-seed 안정성이 떨어져 **Batch 512 epoch 30 Encoder**를 최종 선택하였음

사전실험 - ① first run

Hyperparameter 설정

Stage	항목	값
2	Transition	Observed-only 3,159
2	Reward	notch Δ (sparse)
3	Encoder	d=256, 30ep, mask=0.3
4	BC 보정 / target	없음 / Soft Target
5	γ / τ / β / CQL	0.8 / 0.9 / 10 / 0.0
5	Critic / Enc finetune	Linear(공유) / X
6	Eval	421 firm · α/β/γ

Stage 3 Loss

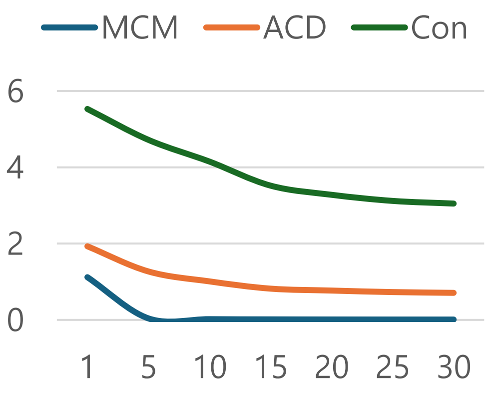

Stage 4 Loss

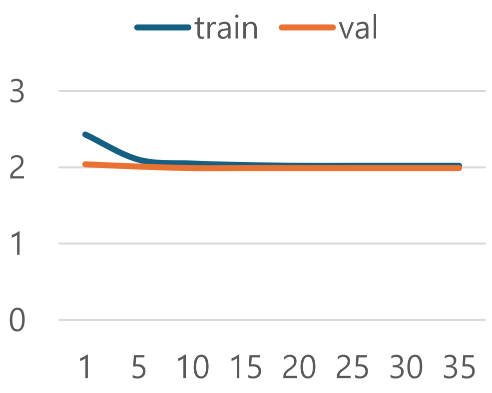

Stage 5 Loss

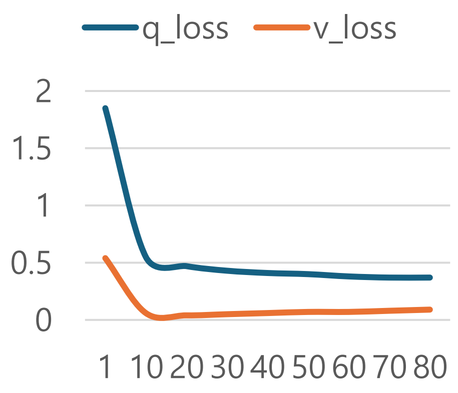

Stage 4 BC 행동 분포(%)

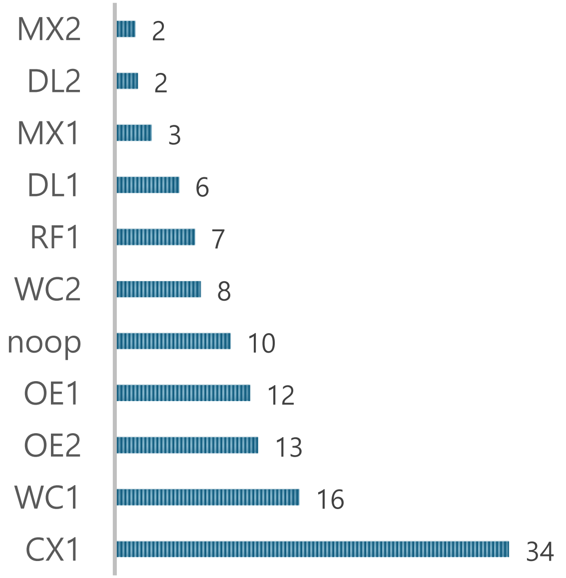

Stage 5 C3(Actor) 행동 분포(%)

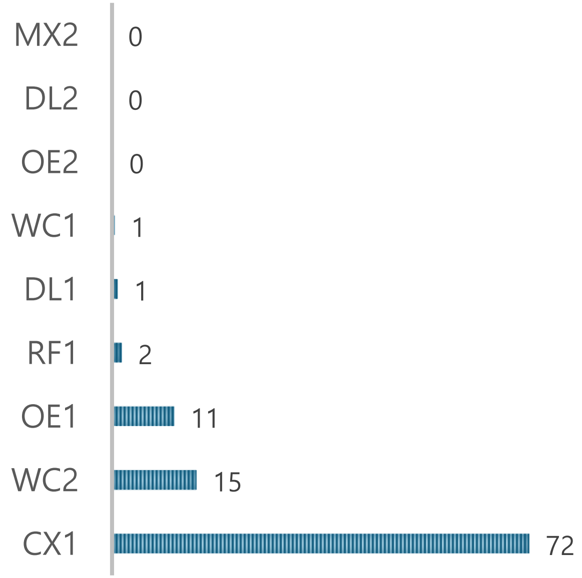

Stage 6 평가 결과 - Oracle α Δnoop

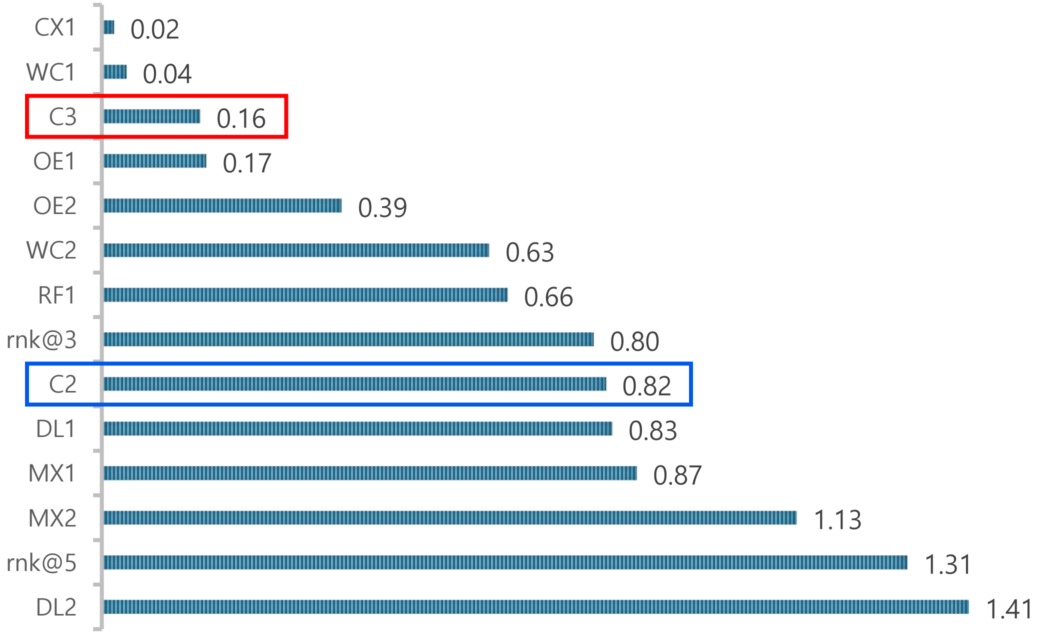

사전실험 - ② Stage 5 IQL β 변경(10→1)

Hyperparameter (변경점: β 10→1)

Stage	항목	값
2	Transition	Observed-only 3,159
3	Encoder	1st run 재사용
4	BC	1st run 재사용 (보정 없음)
5	γ / τ / CQL	0.8 / 0.9 / 0.0 (동일)
5	β (AWR)	**1.0 (← 10.0에서 변경)**
5	Critic / batch / ep	Linear / 256 / 80
6	Eval	421 firm · α/β/γ

Stage 5 학습 (β=1.0)

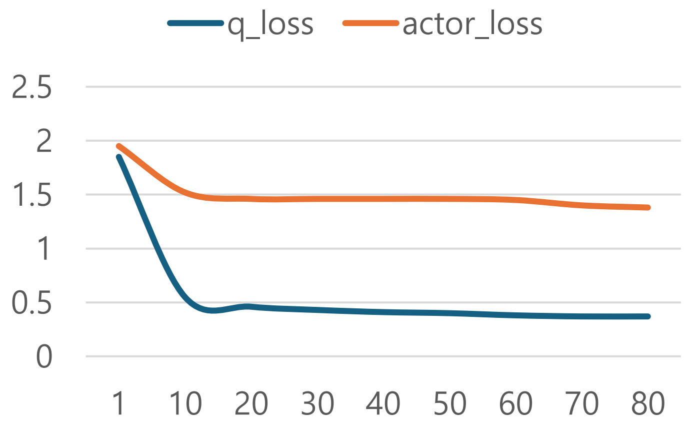

β=10 vs β=1 비교

지표	β=10 (1st run)	β=1 (이 run)
actor_loss (final)	3.581	1.384
entropy (final)	1.752	1.821
CX1 집중도	**71.5%**	**77.4%**
C3 Δnoop (α)	**+0.160**	**+0.235**
C3 vs C2 (α)	**−0.659**	**−0.584**
DL2 선택	0건	0건

Stage 4 BC 행동 분포(%)

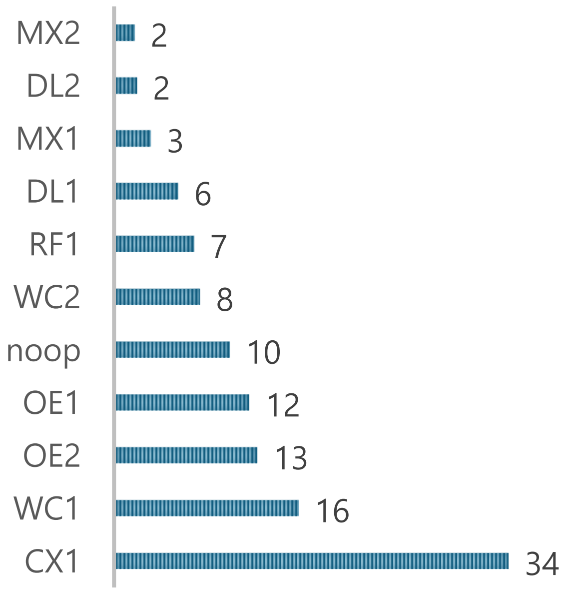

Stage 5 C3(Actor) 행동 분포(%)

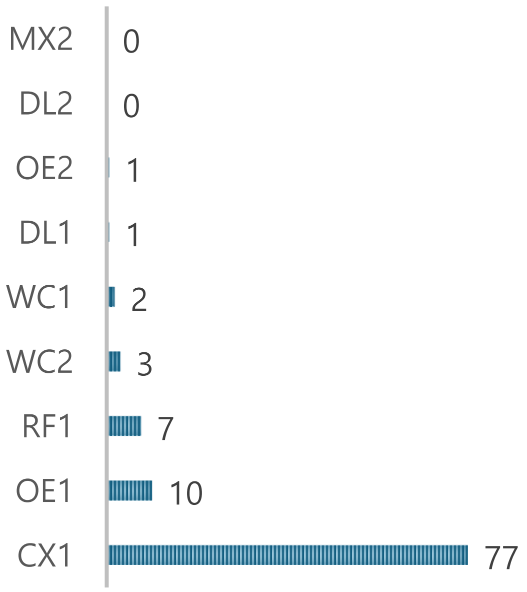

Stage 6 — Oracle α Δnoop 순위

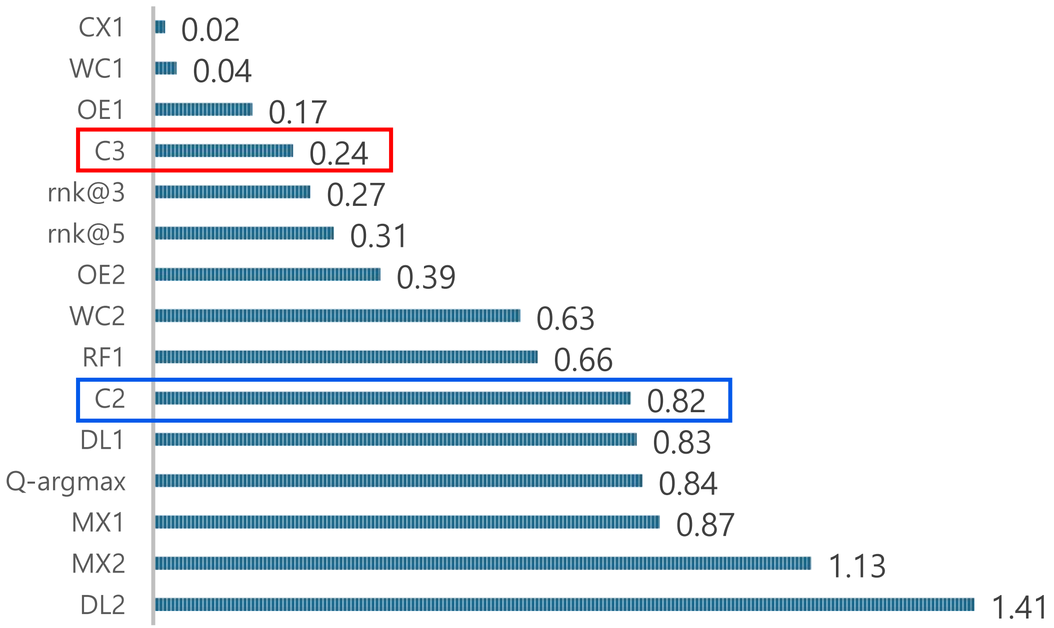

사전실험 - ③ BC Class Balance 도입

Hyperparameter (변경점: BC Class Balance)

Stage	항목	값
2	Transition	Observed-only 3,159
3	Encoder	1st run 재사용
4	BC Class Balance	β=0.999 (신규 도입)
4	Family Balance	없음
4	Projection	기존 방식 (weighted L1 이전)
5	γ/τ/β/CQL	0.8/0.9/10/0.0 (동일)
6	Eval	421 firm · α/β/γ

Stage 5 학습 (1st run과 동일 HP)

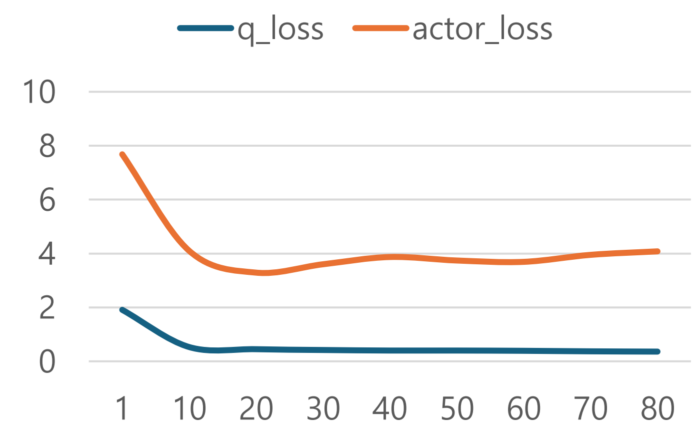

BC 분포 변화 (Class Balance 효과)

후보	1st run	이 run	가중치
A0_noop	10%	28% ↑	0.68
CX1	34%	13% ↓	0.72
OE2	12%	17%	0.79
DL2	2.0%	4.4% ↑	1.57
MX2	1.8%	1.3%	1.09
DL1	5.6%	2.7%	1.40

Stage 4 BC 행동 분포(Class balanced) (%)

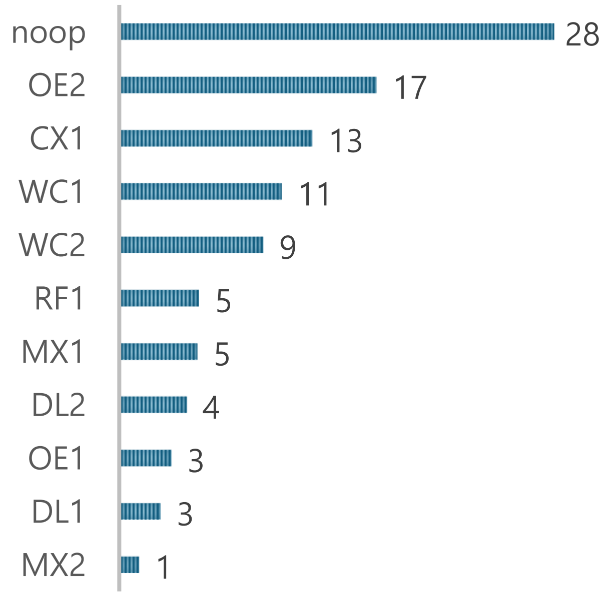

Stage 5 C3(Actor) 행동 분포(%)

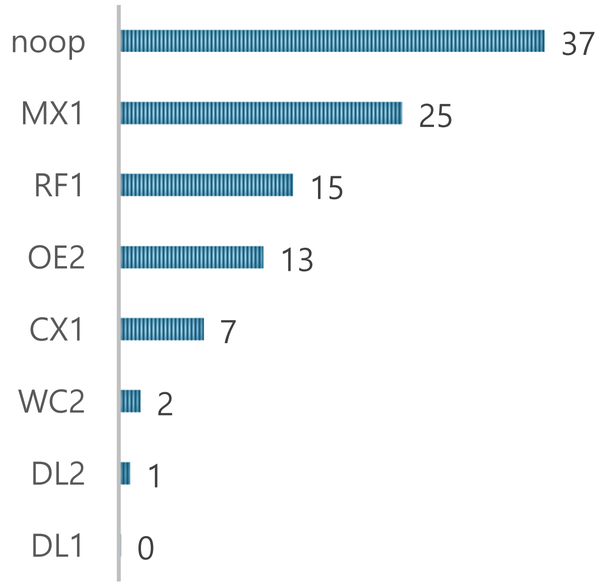

Stage 6 — Oracle α Δnoop 순위

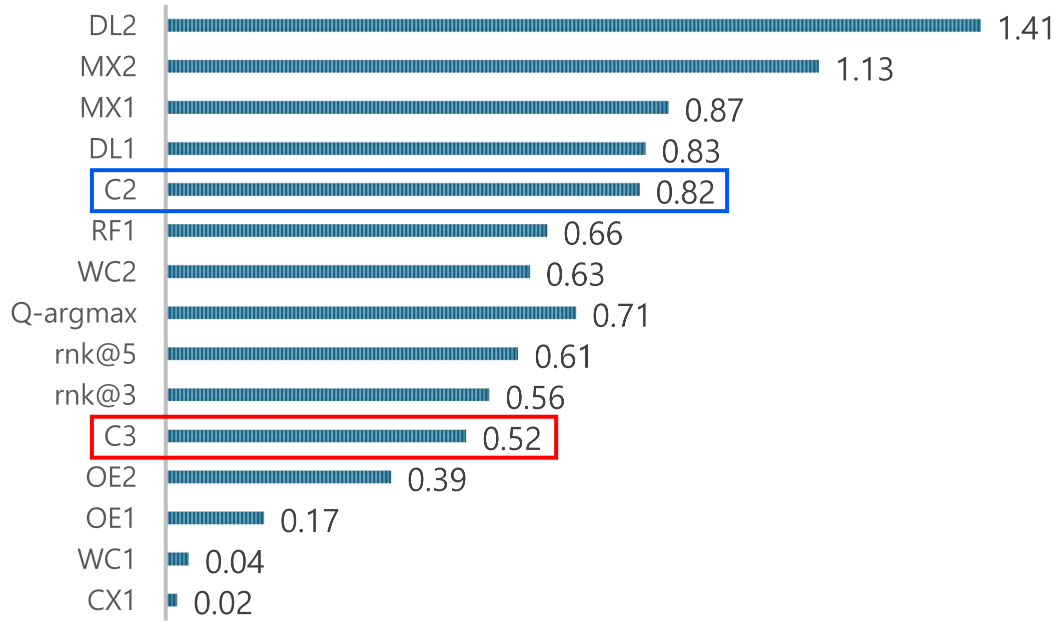

사전실험 - ④ L1 Projection 도입

Hyperparameter (변경점: L1 Projection)

Stage	항목	값
2	Transition	Observed-only 3,159
3	Encoder	1st run 재사용
4	Projection	**L1 방식 (신규 도입)**
4	Class Balance	코드 존재, 가중치 1.0 (미적용)
4	A0_noop 임계치	없음 (적용 전)
5	γ/τ/β/CQL	0.8/0.9/10/0.0 (동일)
6	Eval	421 firm · α/β/γ

Stage 5 학습

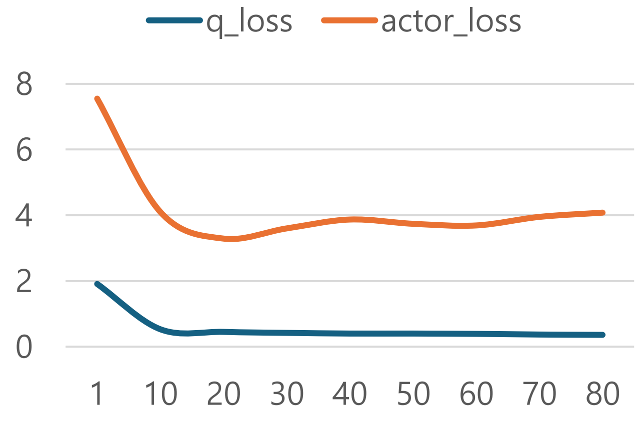

③ vs ④ 비교 (L1 Projection 효과)

지표	③ (Class Bal)	④ (L1 Proj)
Projection	기존 방식	**L1 (신규)**
Class Balance	β=0.999 적용	가중치 1.0
noop BC 비율	28%	28% (동일)
CX1 BC 비율	13%	13% (동일)
C3 noop 비율	37%	42%
C3−C0 (α)	**+0.523**	**+0.533**
C3−C2 (α)	**−0.296**	**−0.286**

Stage 4 BC 행동 분포(%)

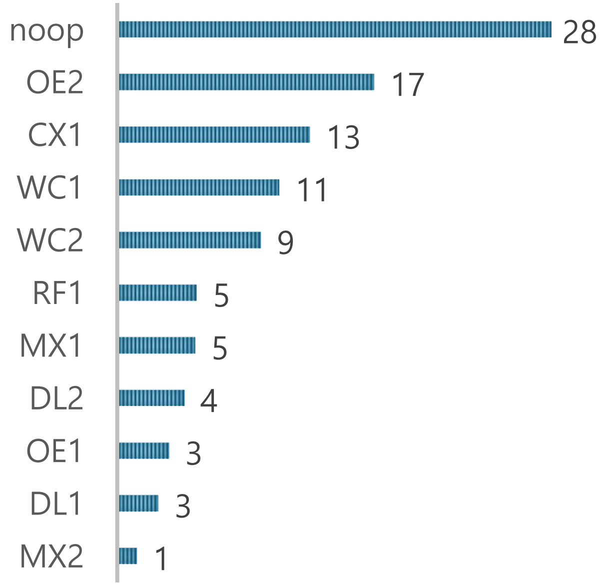

Stage 5 C3(Actor) 행동 분포(%)

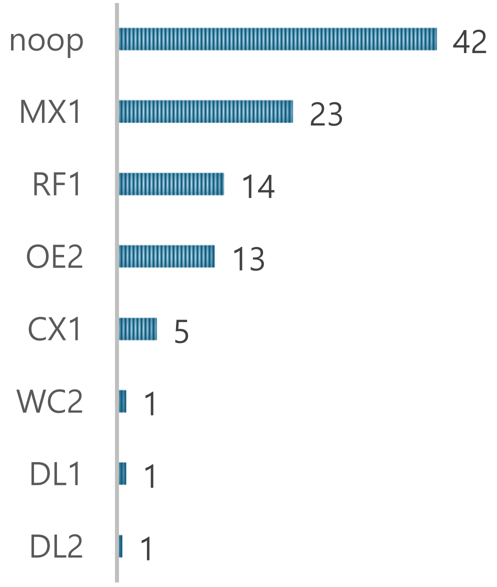

Stage 6 — Oracle α Δnoop 순위

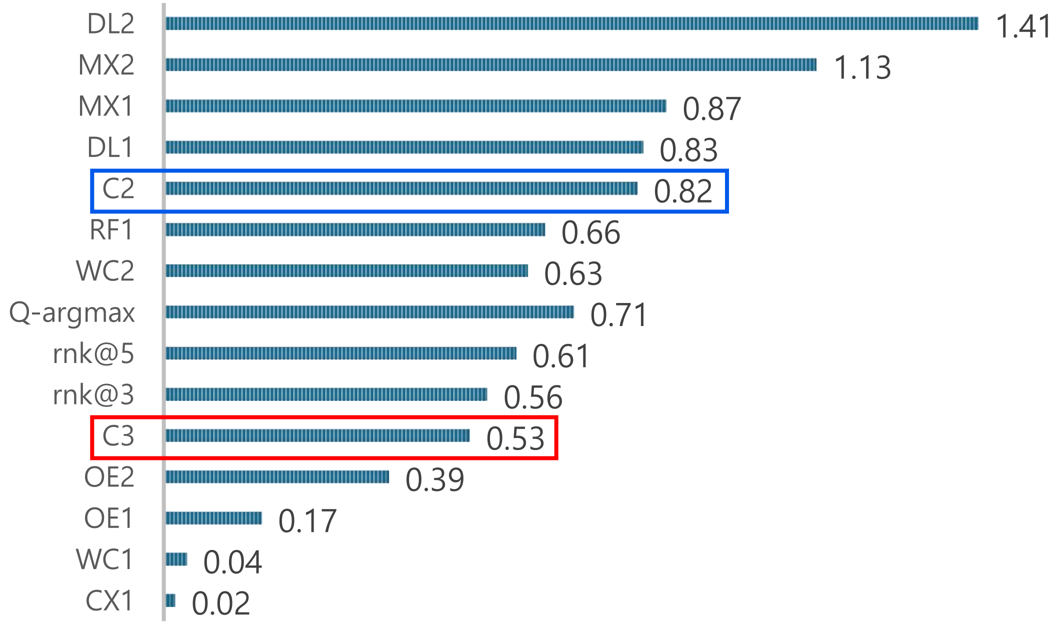

사전실험 - ⑤ - A0 Threshold 도입

Hyperparameter (변경점: A0 margin=0.05)

Stage	항목	값
2	Transition	Observed-only 3,159
3	Encoder	1st run 재사용
4	Projection	L1
4	A0 margin threshold	**0.05 (신규 도입)**
4	Class / Family Balance	**가중치 1.0 / 없음**
5	γ/τ/β/CQL	0.8/0.9/10/0.0 (동일)
6	Eval	421 firm · α/β/γ

④ vs ⑤ — A0 Threshold 효과

지표	④ (A0 없음)	⑤ (A0 제거)
BC noop	28%	**0% (제거됨)**
BC CX1	13%	**31% ↑**
C3 noop	42%	0%
C3 CX1	5%	**49% ↑**
C3 DL2	0.7%	0.5%
C3−C0 (α)	+0.533	**+0.334 ↓**
C3−C2 (α)	**−0.286**	**−0.485 ↓**

Stage 5 학습

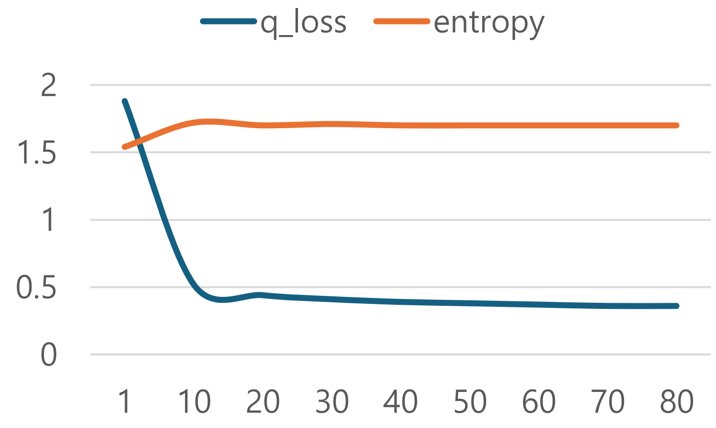

Stage 4 BC 행동 분포(%)

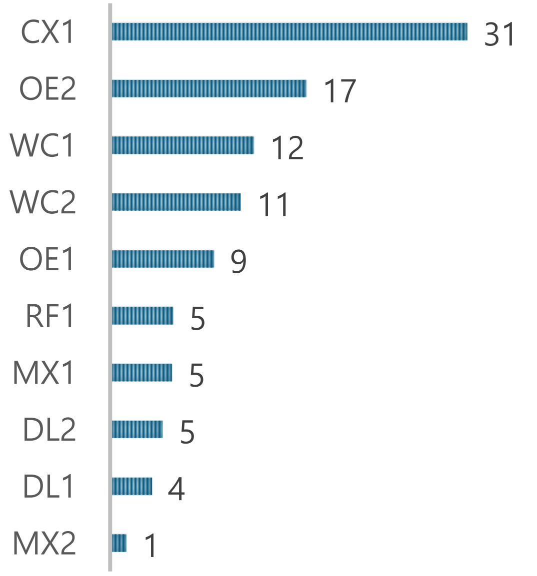

Stage 5 C3(Actor) 행동 분포(%)

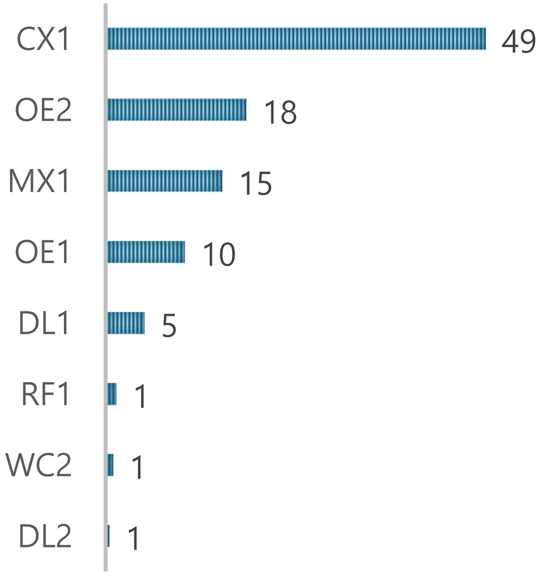

Stage 6 - Oracle α Δnoop 순위

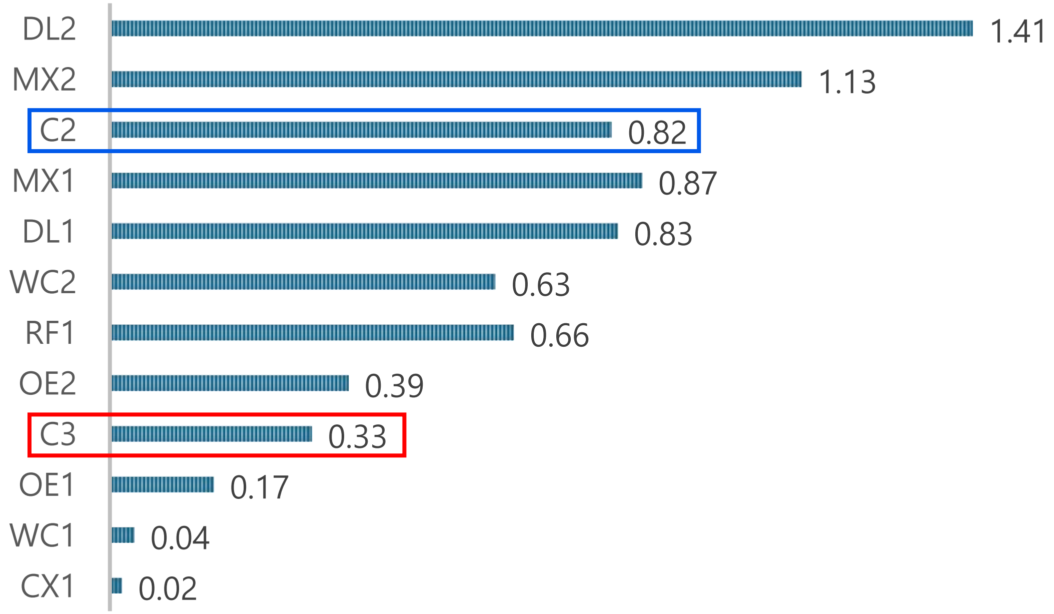

사전실험 - ⑥ Weighted L1 Projection + Standard BC

Hyperparameter 설정

Stage	항목	값
2	Transition	**Observed-only 3,159**
3	Encoder	1st run 재사용
4	Projection	**Weighted L1 (도입)**
4	Class Balance	**코드 존재, 미적용**
4	Family Balance	**없음**
5	γ/τ/β/CQL	0.8/0.9/10/0.0
6	Eval	421 firm · α/β/γ

Stage 3 Loss (1st run)

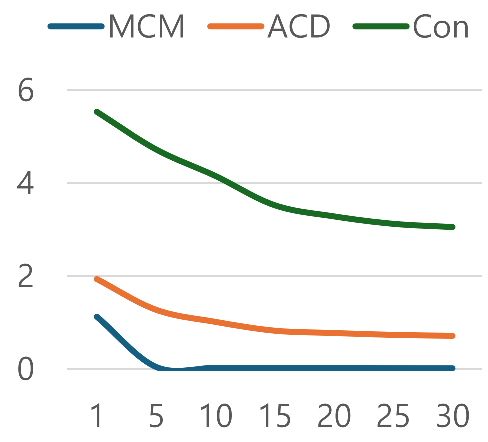

Stage 4 Loss

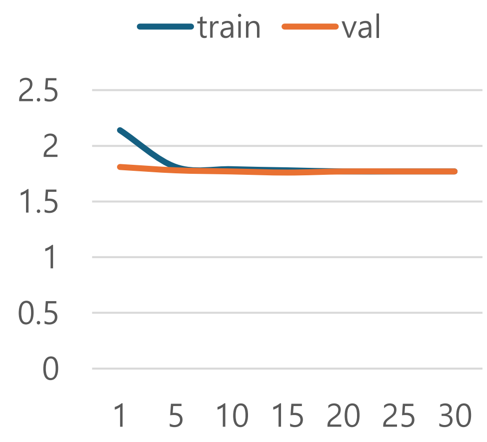

Stage 5 Loss

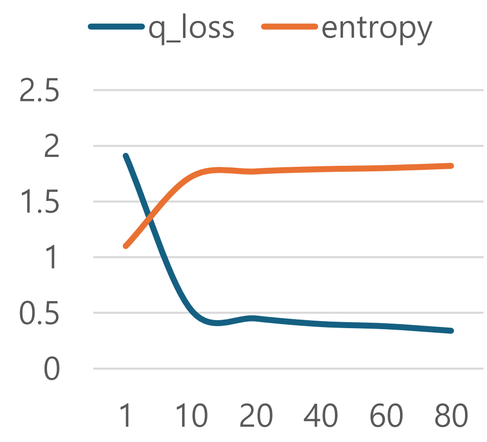

Stage 4 BC 행동 분포(%)

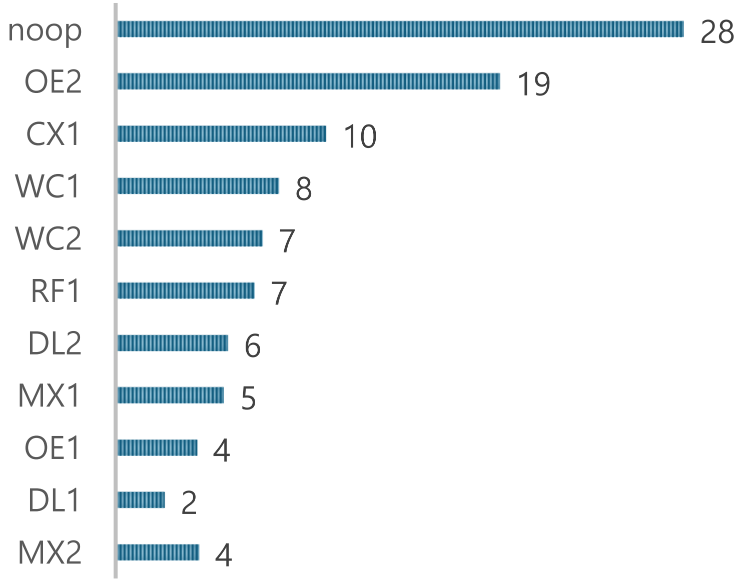

Stage 5 C3(Actor) 행동 분포(%)

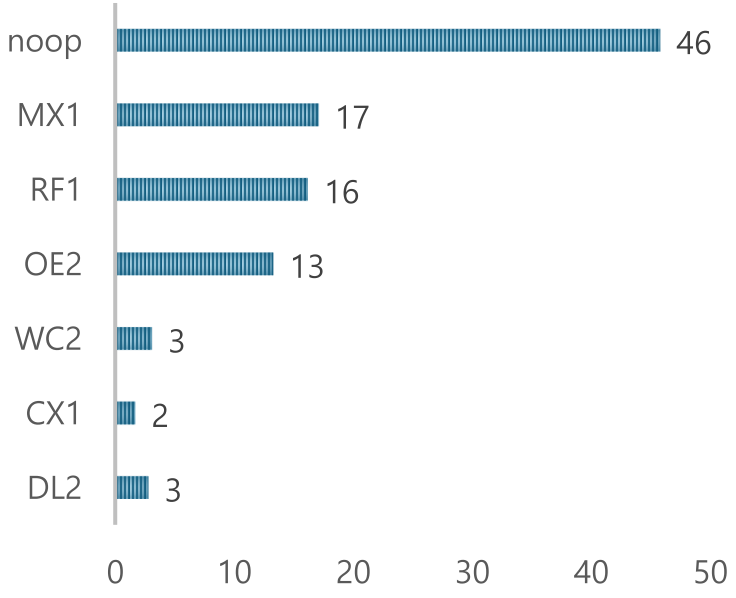

Stage 6 평가 결과 - Oracle α Δnoop

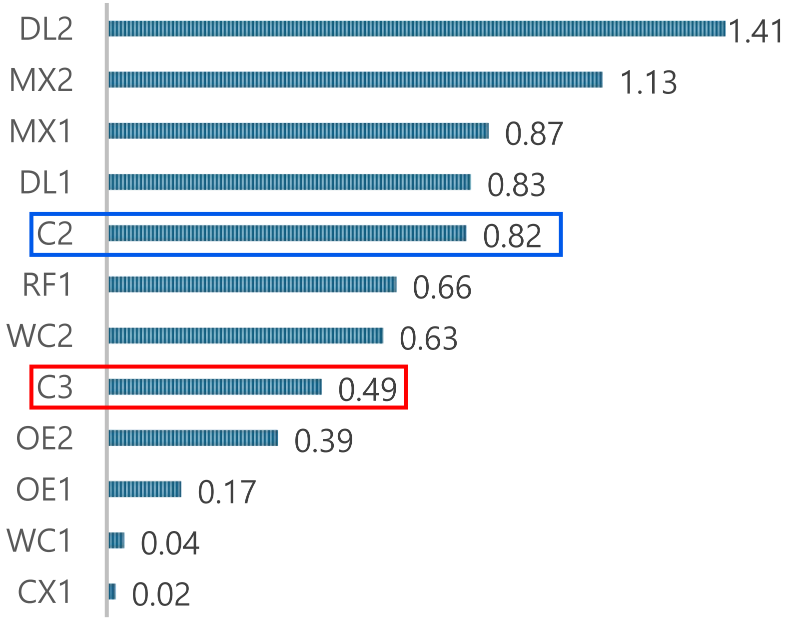

사전실험 - ⑦ Weighted L1 + Class Balance BC

Hyperparameter 설정

Stage	항목	값
2	Transition	**Observed-only 3,159**
3	Encoder	1st run 재사용
4	Projection	Weighted L1
4	Class Balance	**β=0.999 (실효 적용)**
4	Family Balance	**없음**
5	γ/τ/β/CQL	0.8/0.9/10/0.0
6	Eval	421 firm · α/β/γ

Stage 3 Loss (1st run)

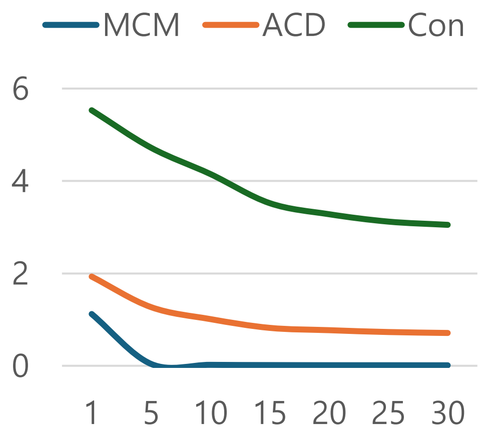

Stage 4 Loss

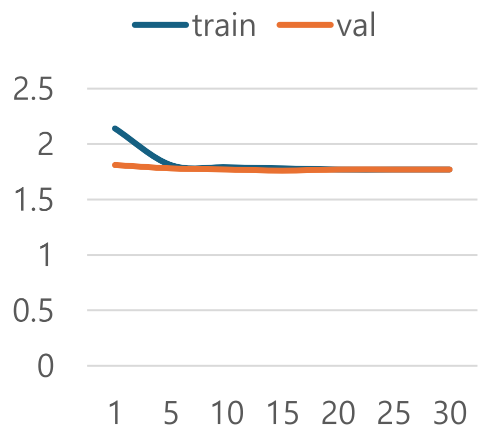

Stage 5 Loss

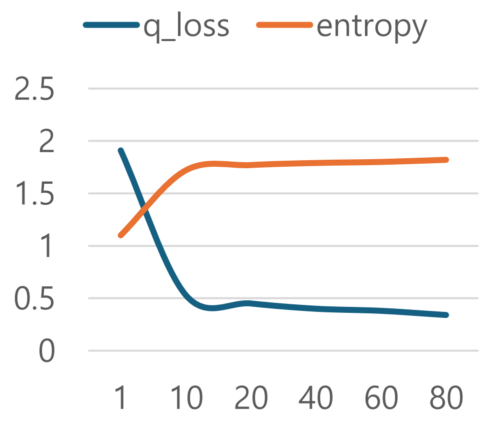

Stage 4 BC 행동 분포(%)

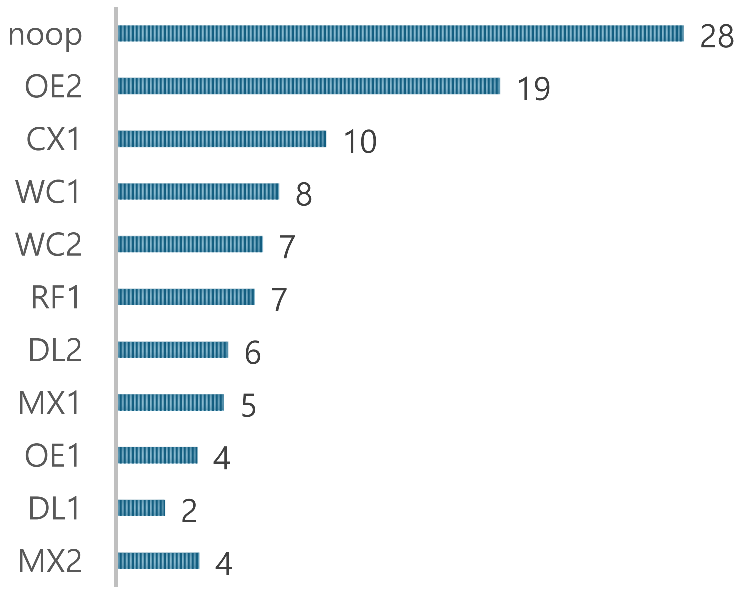

Stage 5 C3(Actor) 행동 분포(%)

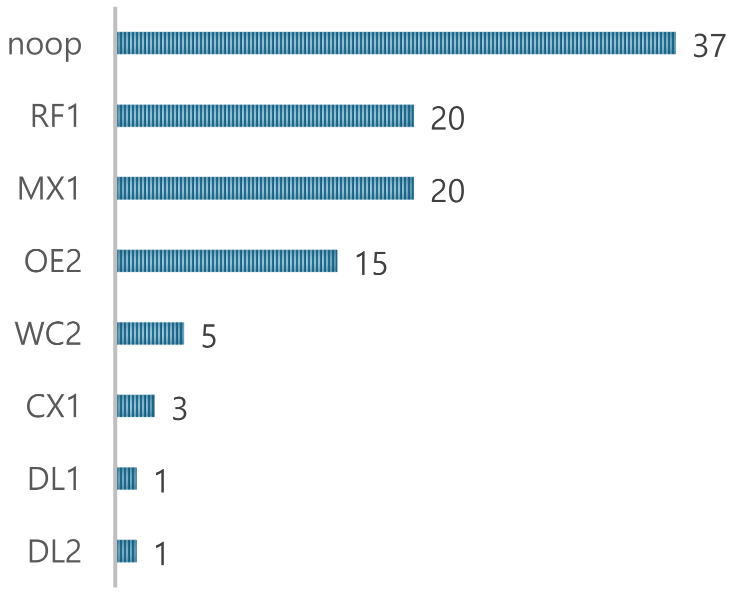

Stage 6 평가 결과 - Oracle α Δnoop

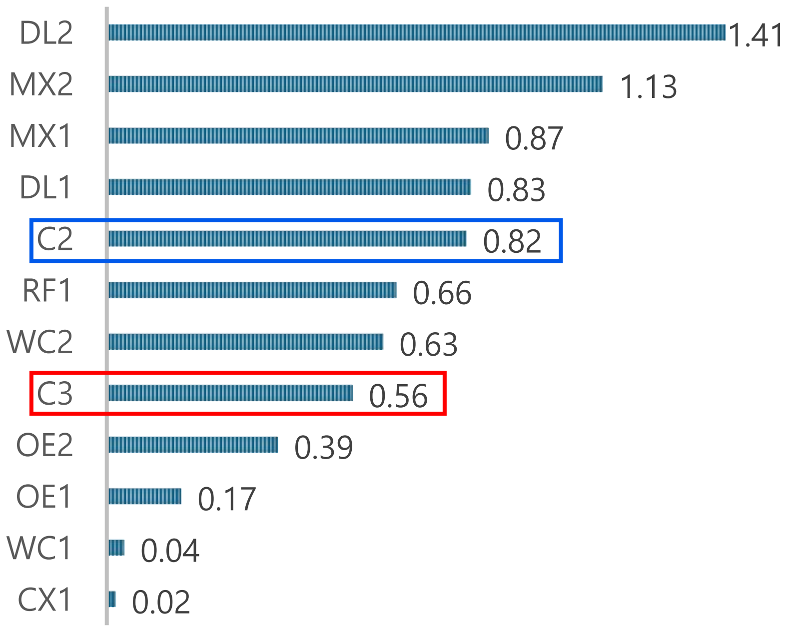

사전실험 - ⑧ WL1 + CB + Actor Distillation (CE λ=2.0)

Hyperparameter 설정

Stage	항목	값
2	Transition	**Observed-only 3,159**
3	Encoder	1st run 재사용
4	Projection	Weighted L1
4	Class Balance	**β=0.999 (실효 적용)**
5	Actor Distillation	**CE λ=2.0 (신규 도입)**
5	γ/τ/β	0.8/0.9/10
6	Eval	421 firm · α/β/γ

Stage 3 Loss (1st run)

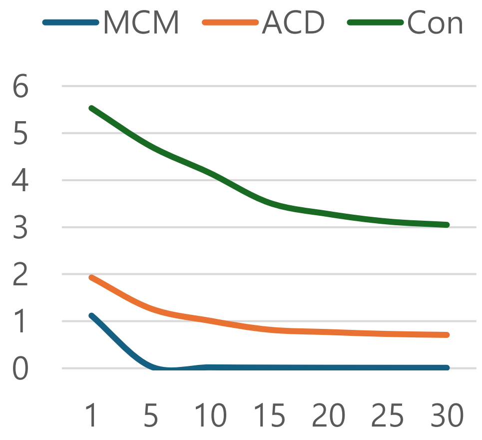

Stage 4 Loss

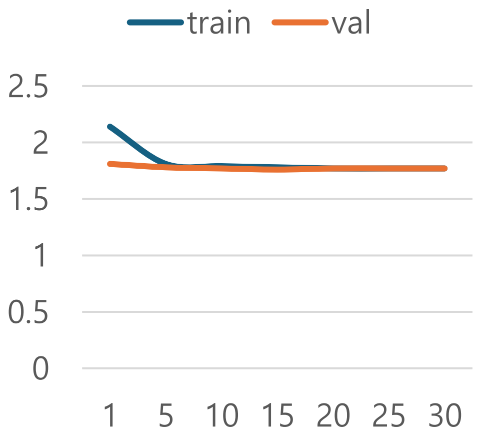

Stage 5 Loss

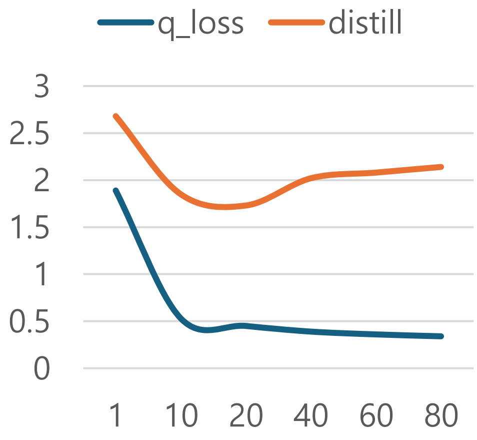

Stage 4 BC 행동 분포(%)

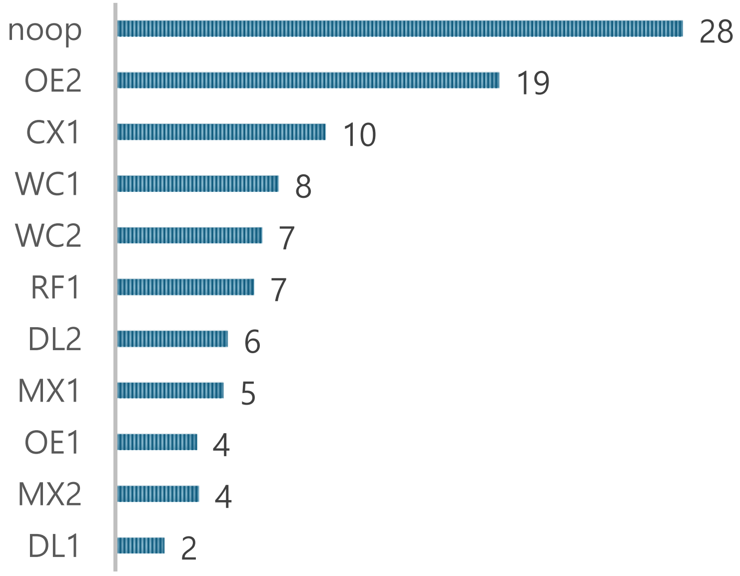

Stage 5 C3(Actor) 행동 분포(%)

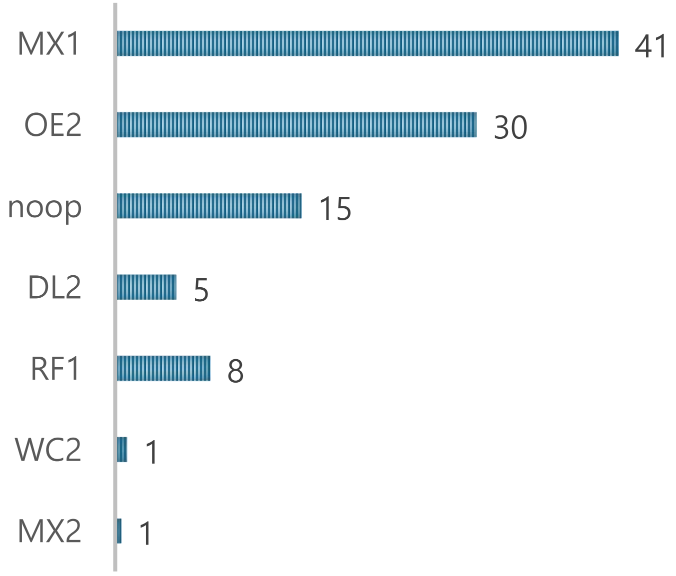

Stage 6 평가 결과 — Oracle α Δnoop

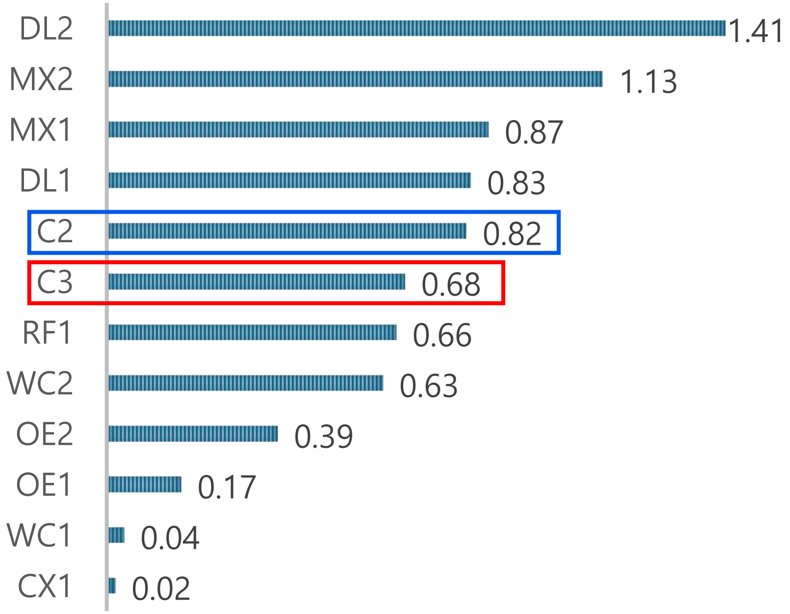

사전실험 - ⑨ WL1 + CB + Distillation (λ=0.3)

Hyperparameter 설정

Stage	항목	값
2	Transition	**Observed-only 3,159**
3	Encoder	1st run 재사용
4	Projection	Weighted L1
4	Class Balance	**β=0.999 (실효 적용)**
5	Distill CE λ	**0.3 (약한 증류)**
5	γ/τ/β	0.8/0.9/10
6	Eval	421 firm · α/β/γ

Stage 3 Loss (1st run)

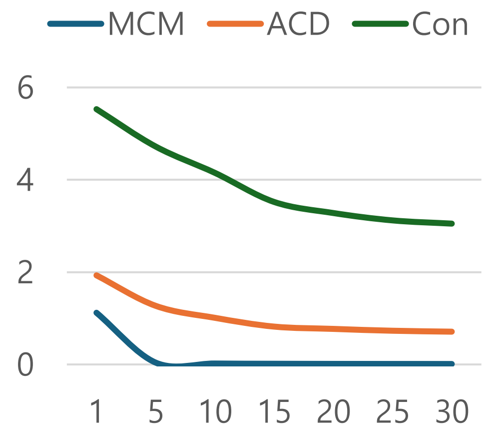

Stage 4 Loss

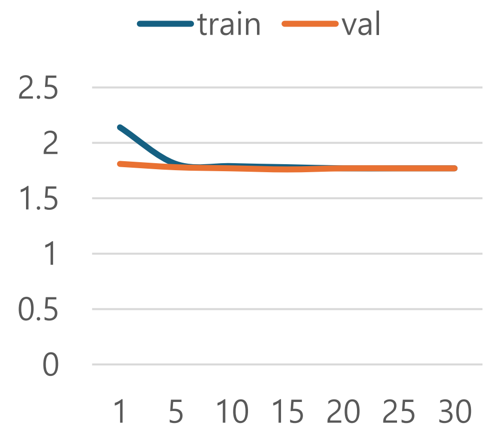

Stage 5 Loss

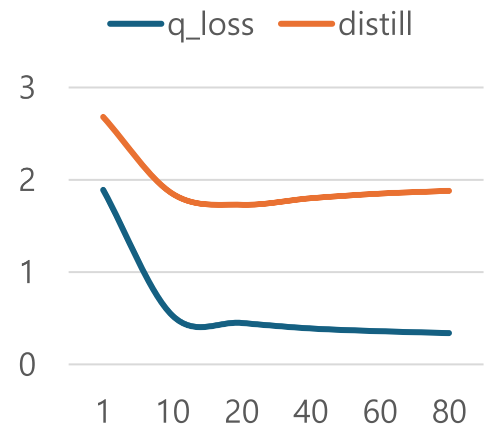

Stage 4 BC 행동 분포(%)

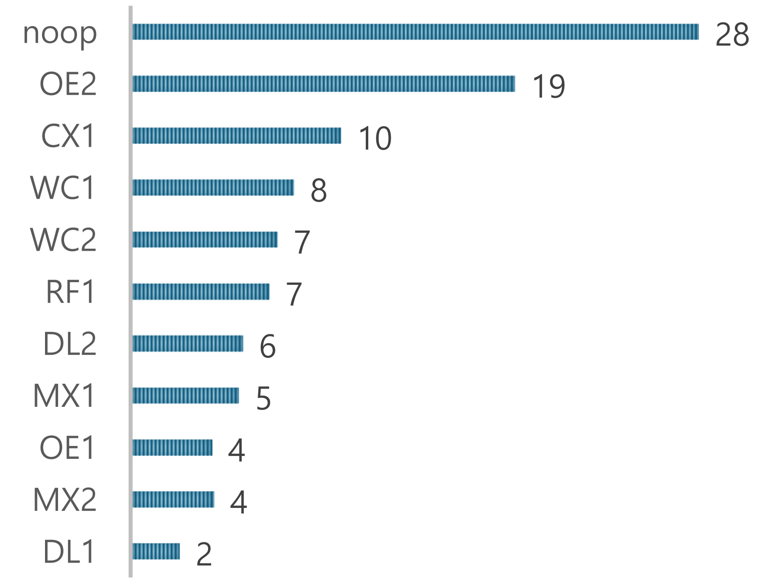

Stage 5 C3(Actor) 행동 분포(%)

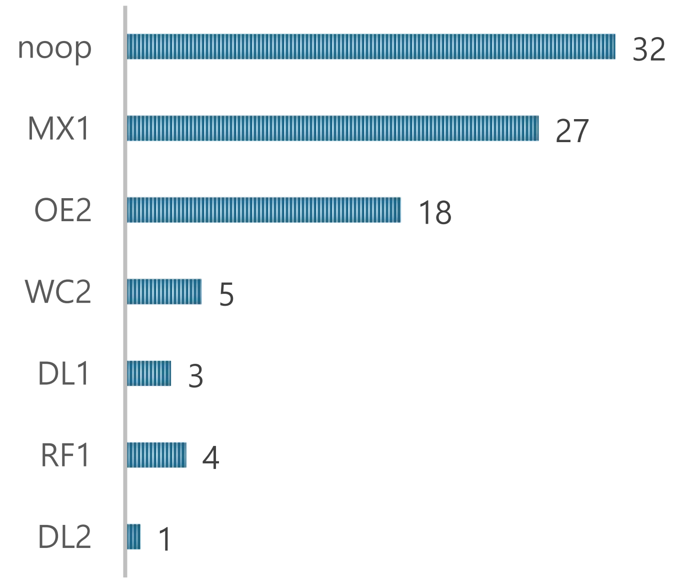

Stage 6 평가 결과 — Oracle α Δnoop

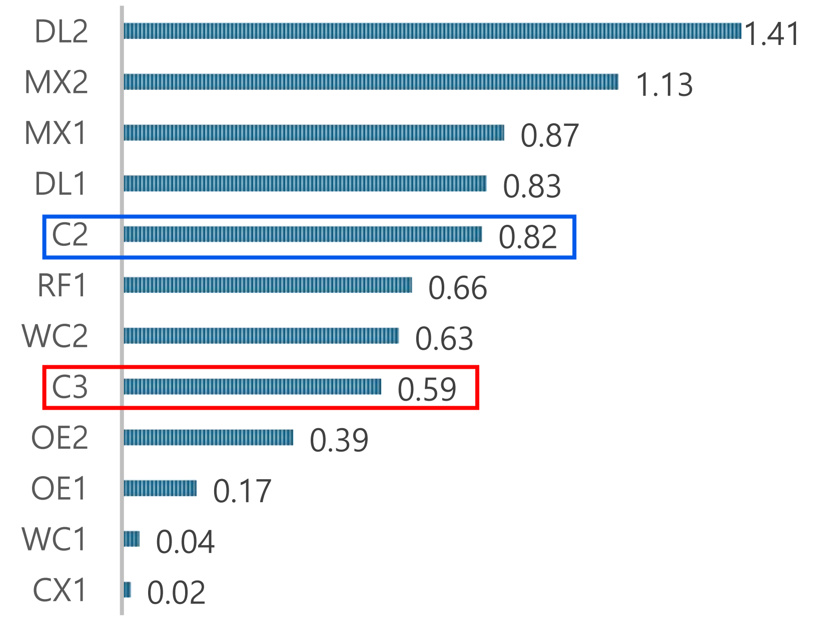

사전실험 - ⑩ WL1 + CB + Distillation (λ=1.0)

Hyperparameter 설정

Stage	항목	값
2	Transition	Observed-only 3,159
3	Encoder	1st run 재사용
4	Projection	Weighted L1
4	Class Balance	β=0.999 (실효 적용)
5	Distill CE λ	1.0 (중간 증류)
5	γ/τ/β	0.8/0.9/10
6	Eval	421 firm · α/β/γ

Stage 3 Loss (1st run)

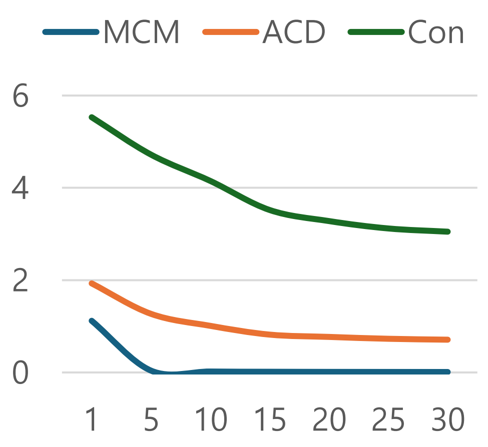

Stage 4 Loss

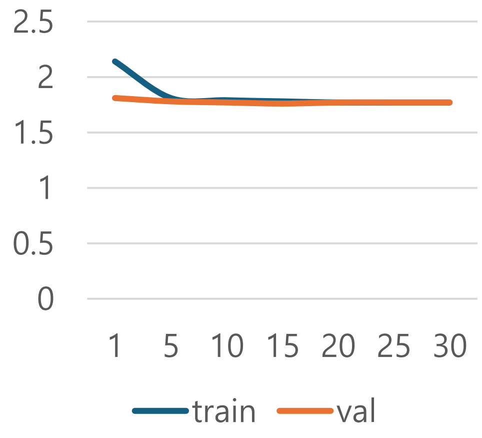

Stage 5 Loss

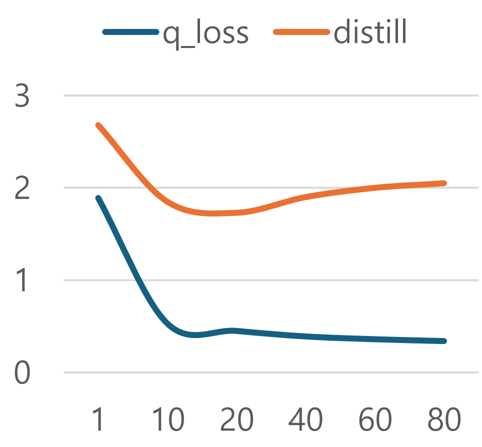

Stage 4 BC 행동 분포(%)

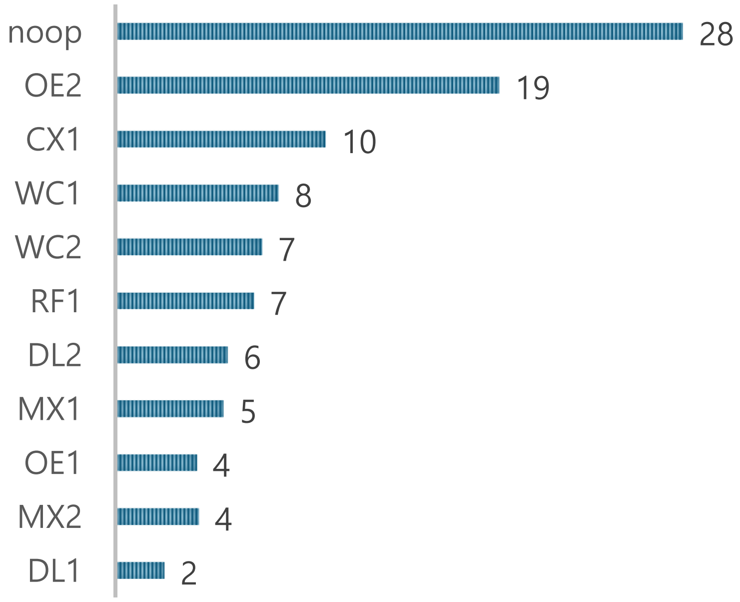

Stage 5 C3(Actor) 행동 분포(%)

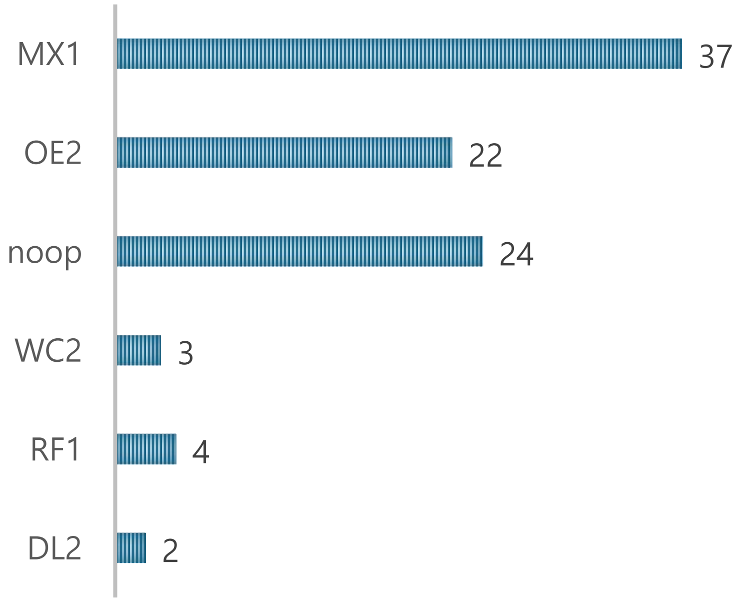

Stage 6 평가 결과 - Oracle α Δnoop

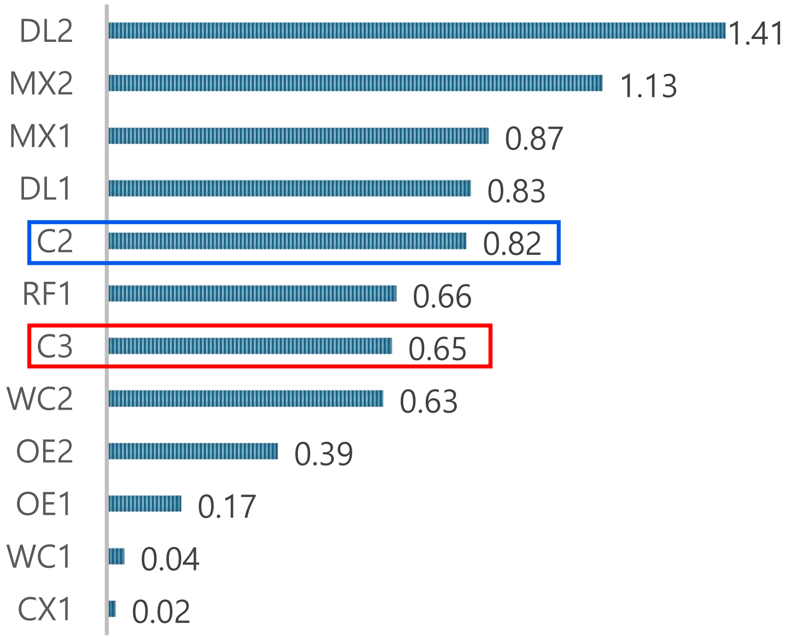

사전실험 – ⑪ Standard BC + Distillation (λ=1.0)

Hyperparameter 설정

Stage	항목	값
2	Transition	**Observed-only 3,159**
3	Encoder	1st run 재사용
4	Projection	구 방식 (1st run)
4	BC	**Standard (균형 없음)**
5	Distill CE λ	1.0
5	γ/τ/β	0.8/0.9/10
6	Eval	421 firm · α/β/γ

Stage 3 Loss (1st run)

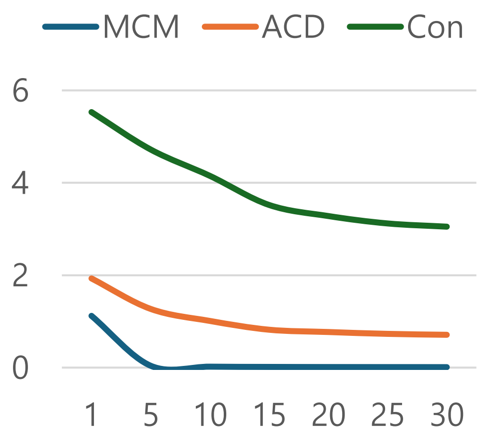

Stage 4 Loss

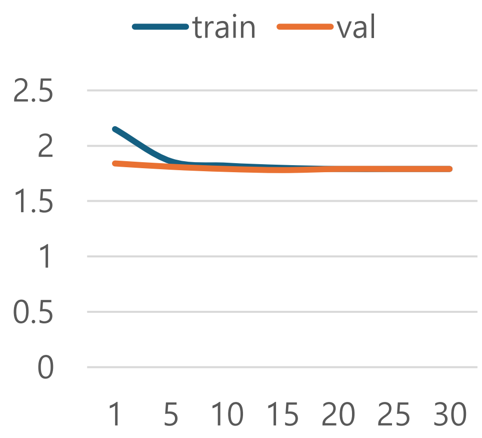

Stage 5 Loss

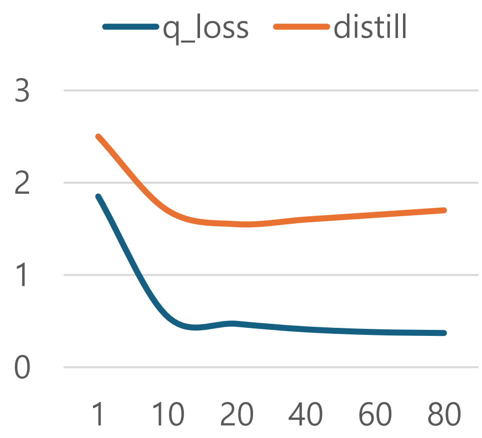

Stage 4 BC 행동 분포(%)

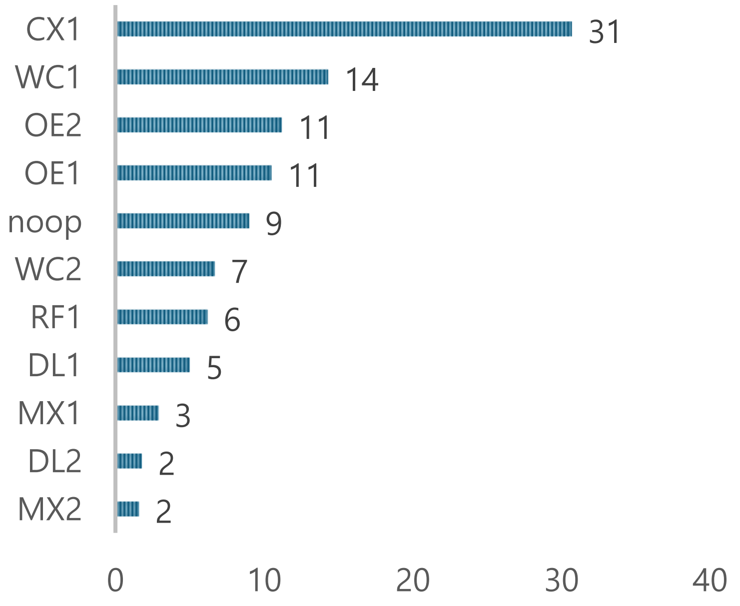

Stage 5 C3(Actor) 행동 분포(%)

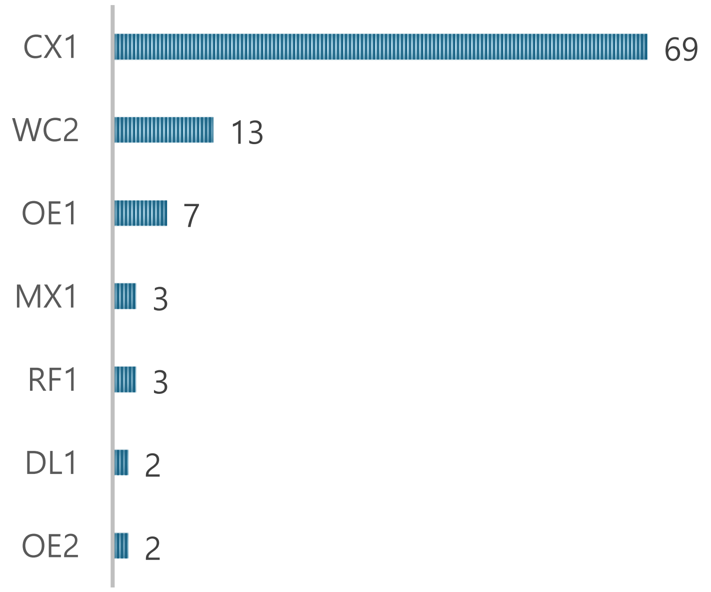

Stage 6 평가 결과 - Oracle α Δnoop

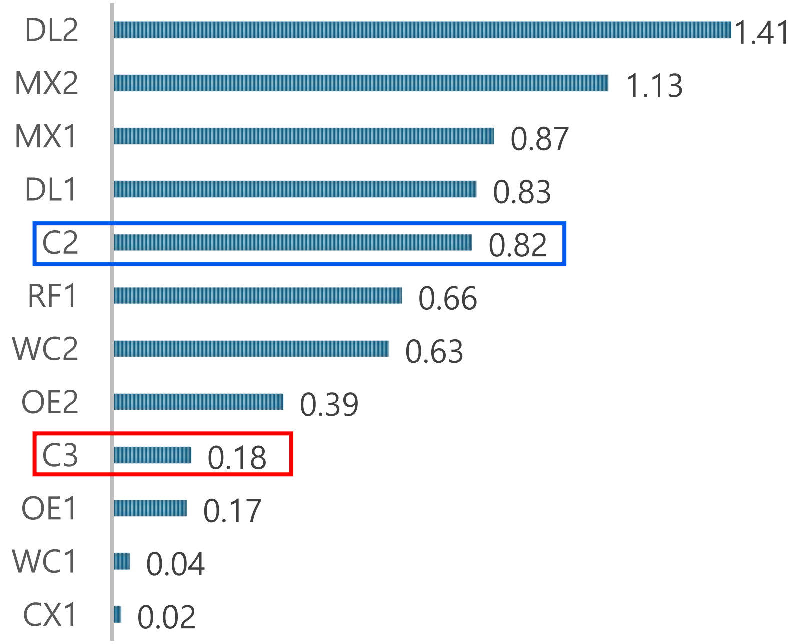

사전실험 – 12) Encoder Batch 256 Epoch 30

Hyperparameter

Stage	항목	값
2	Transition	Observed-only 2251
3	Encoder	학습 (Batch 256, 30 epoch)
4	CB / Projection	β=0.999 / Weighted L1
5	γ/τ/β	0.8/0.9/10.0
5	Distill λ	1.0
6	Eval	421 firm

Stage 3 Loss (Batch 256, 30 epoch)

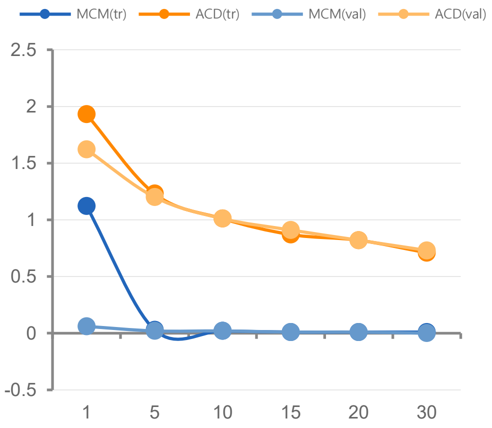

Stage 4 Loss (80ep)

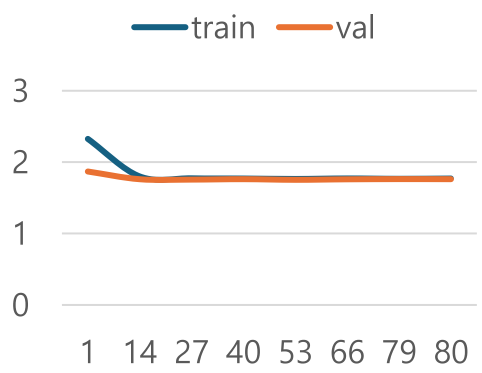

Stage 5 Loss (150ep)

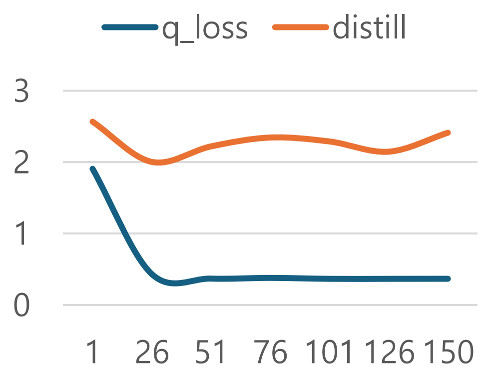

Stage 4 BC 행동 분포(%)

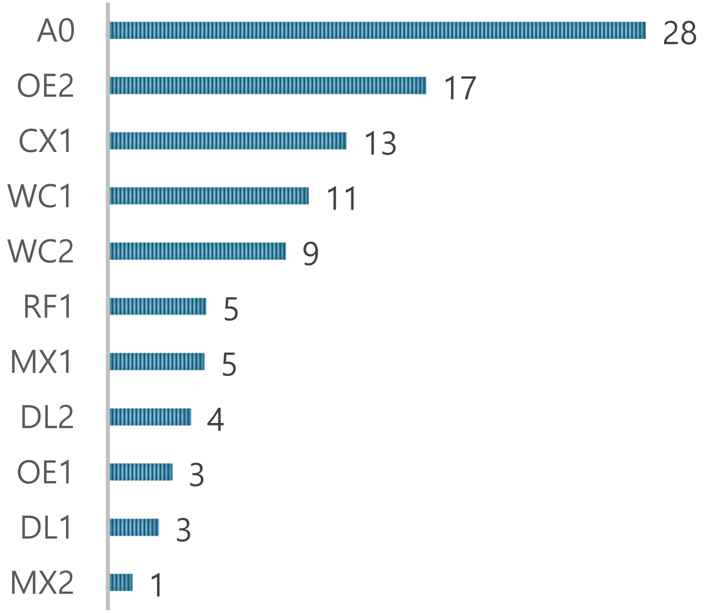

Stage 5 C3(Actor) 행동 분포(%)

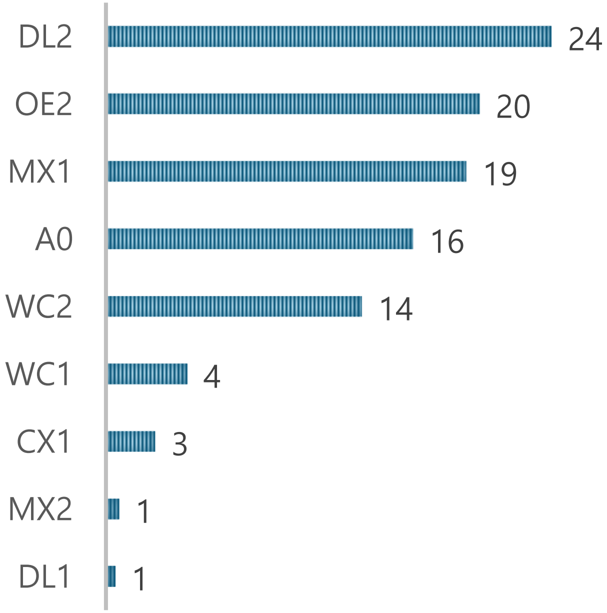

Stage 6 평가 결과 - Oracle α Δnoop

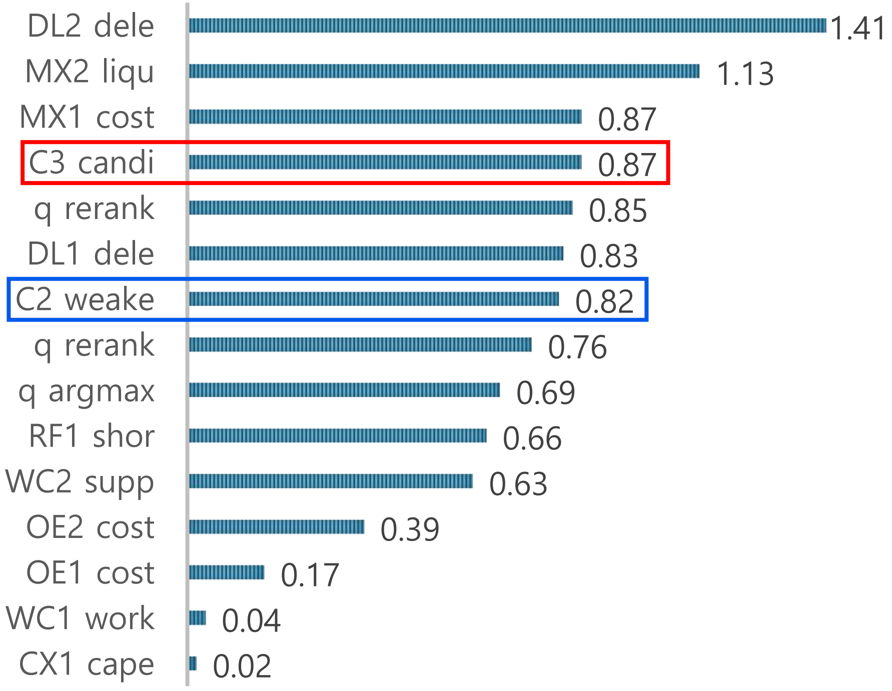

사전실험 – 13) Encoder Batch 256 Epoch 30 – seed 2030

Hyperparameter

Stage	항목	값
3	Encoder	**d=256, 30ep, mask=0.15 , seed=2030**
4	CB/P/batch	β=0.999, P50, batch=512
5	γ / τ / β	0.8 / 0.9 / 10.0
5	Critic	linear
5	Distill	CE λ=1.0
5	n / ep / seed	2251 / 150 / 2030
6	Eval	421 firm

Stage 3 (30ep)

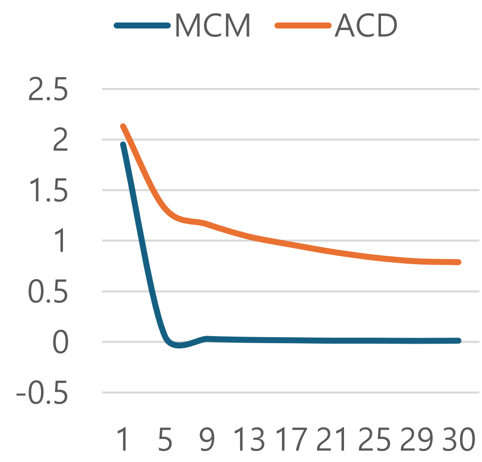

Stage 4 (80ep)

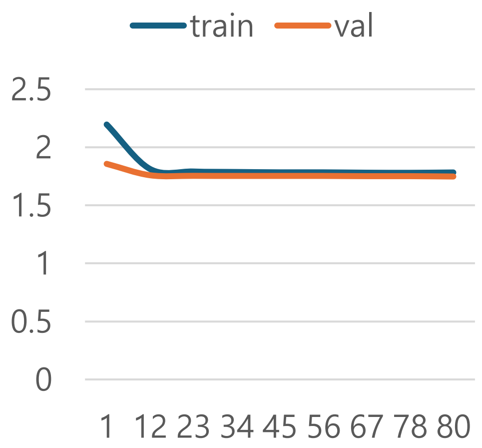

Stage 5 (150ep)

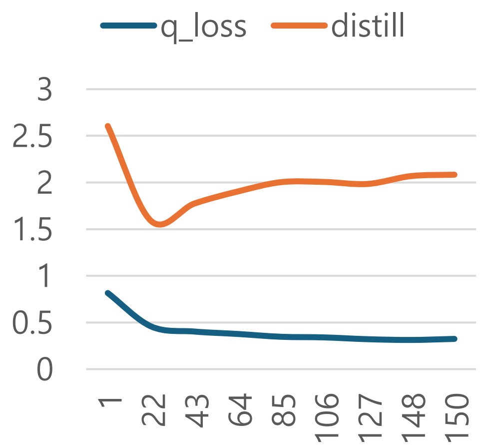

Stage 4 BC 행동 분포(%)

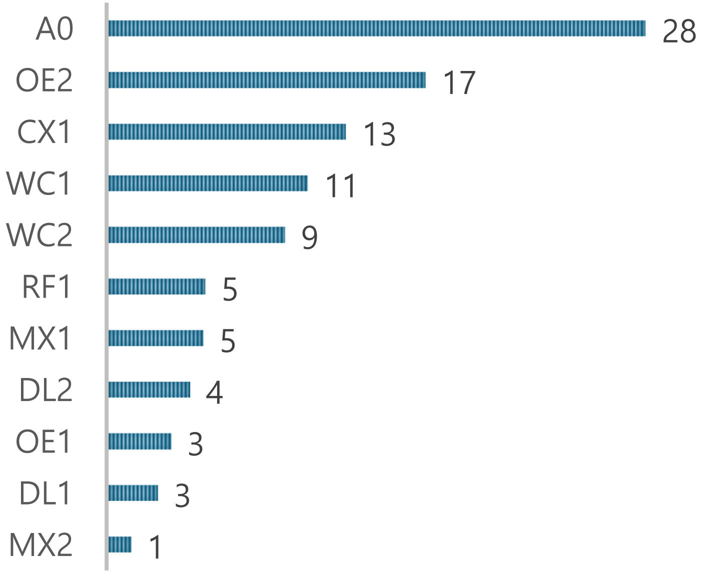

Stage 5 C3(Actor) 행동 분포(%)

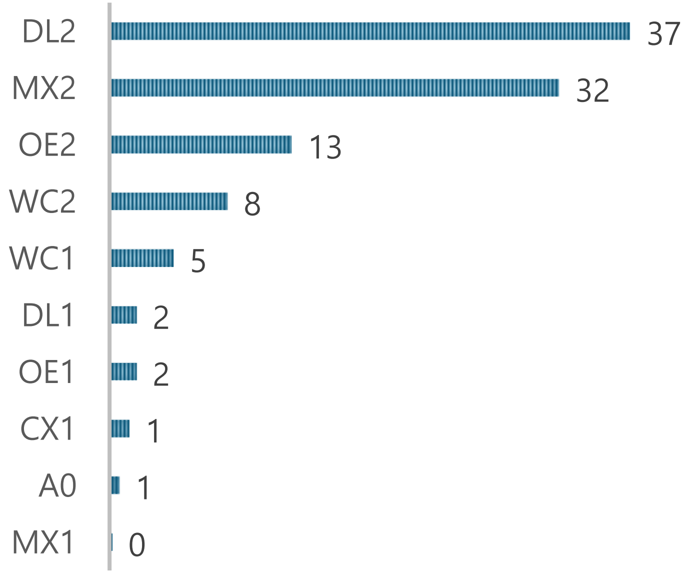

Stage 6 평가 결과 - Oracle α Δnoop

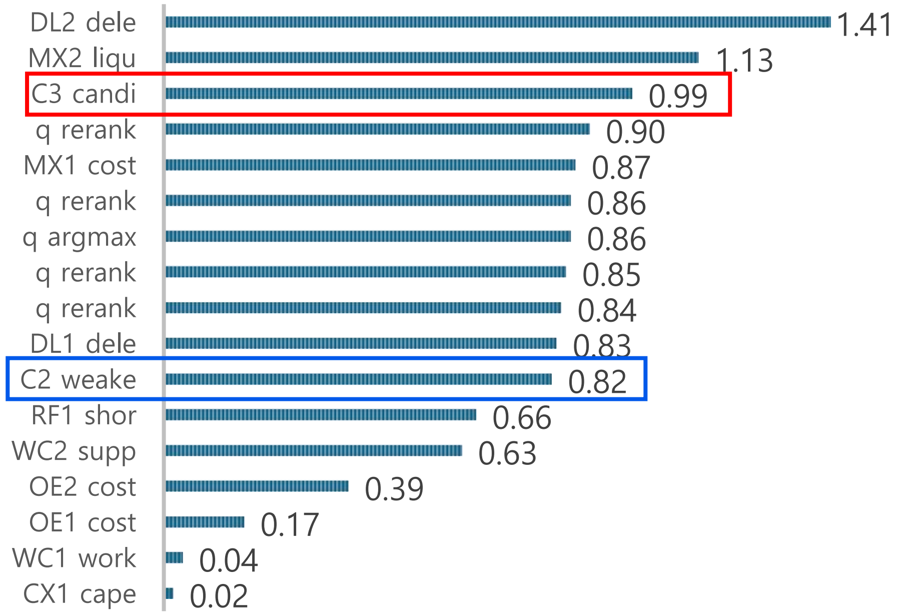

사전실험 – 14) Encoder Batch 256 Epoch 50

Hyperparameter

Stage	항목	값
2	Transition	Observed-only 2251
3	Encoder	**학습 (Batch 256, 50 epoch)**
4	CB / Proj	β=0.999 / Weighted L1
5	γ/τ/β	0.8/0.9/10.0
5	Distill λ	1.0
6	Eval	421 firm

Stage 3 Loss (Batch 256, 50 epoch)

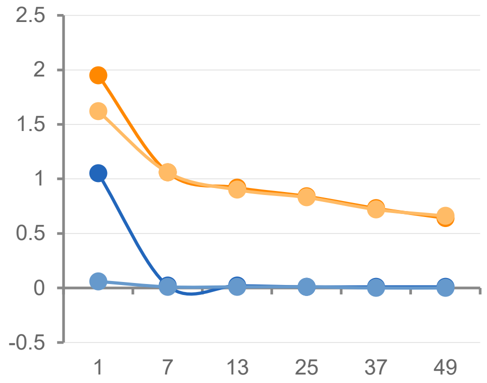

Stage 4 Loss (80ep)

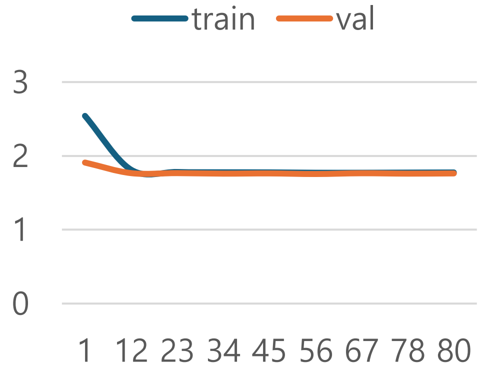

Stage 5 Loss (150ep)

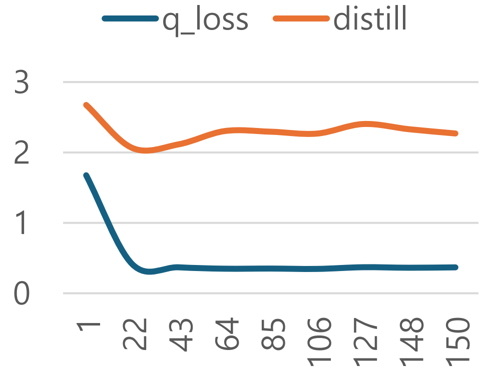

Stage 4 BC 행동 분포(%)

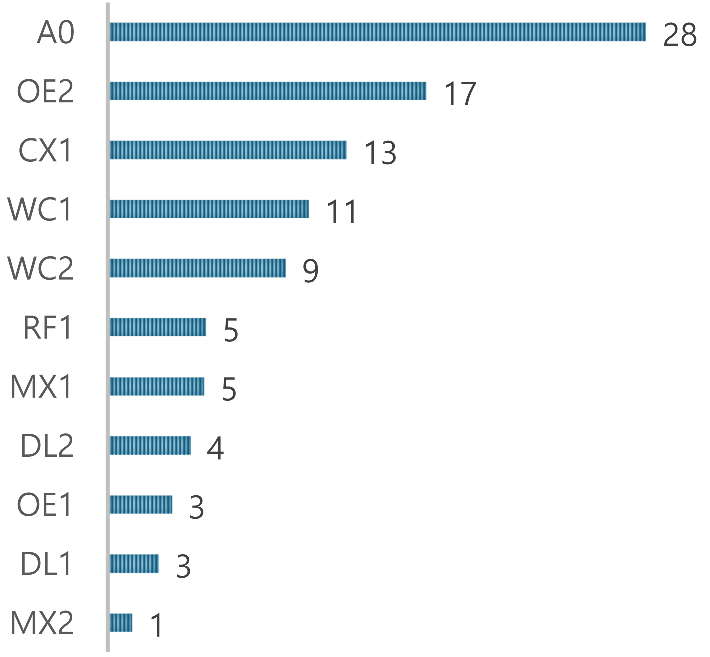

Stage 5 C3(Actor) 행동 분포(%)

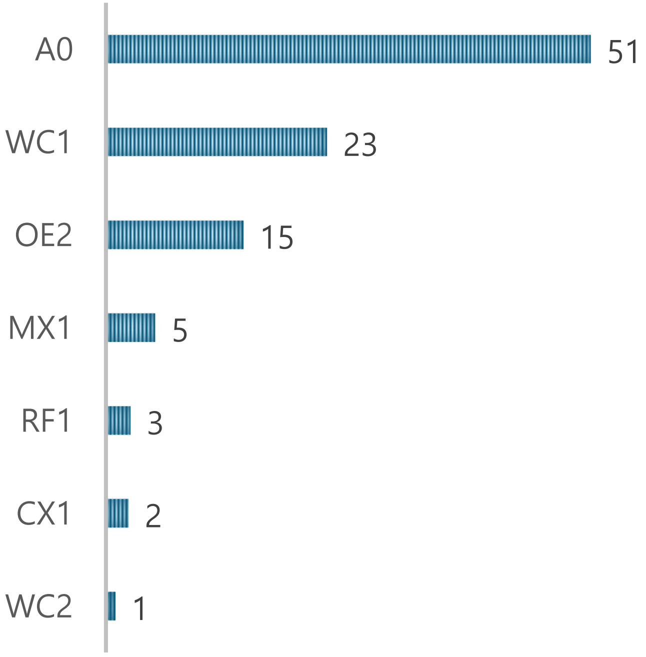

Stage 6 평가 결과 - Oracle α Δnoop

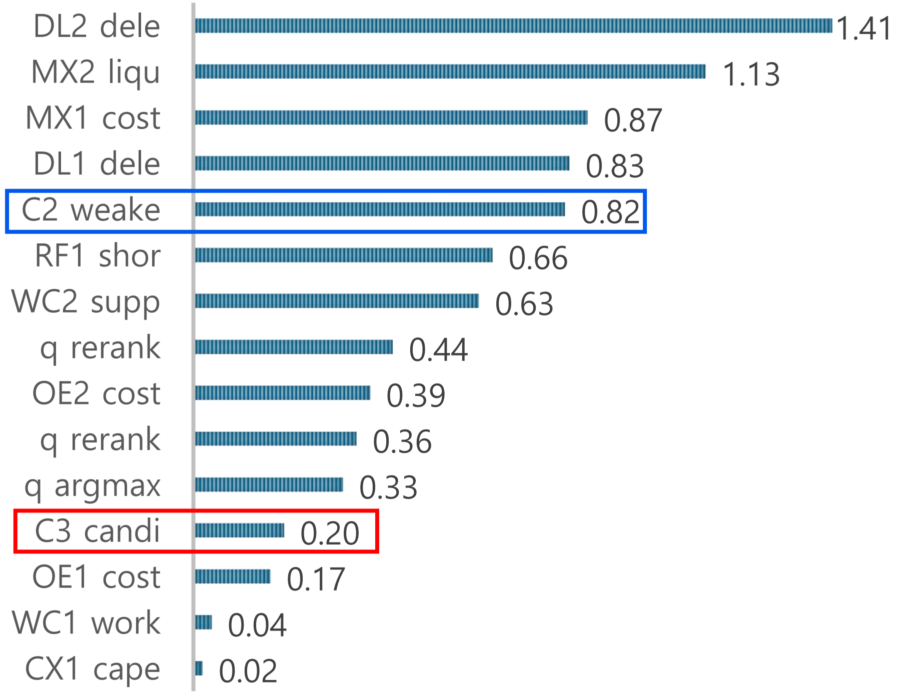

사전실험 – 15) Encoder Batch 512 Epoch 15

Hyperparameter

Stage	항목	값
2	Transition	Observed-only 2251
3	Encoder	**학습 (Batch 512, 15 epoch)**
4	CB / Projection	β=0.999 / Weighted L1
5	γ/τ/β	0.8/0.9/10.0
5	Distill λ	1.0
6	Eval	421 firm

Stage 3 Loss (Batch 512, 15 epoch)

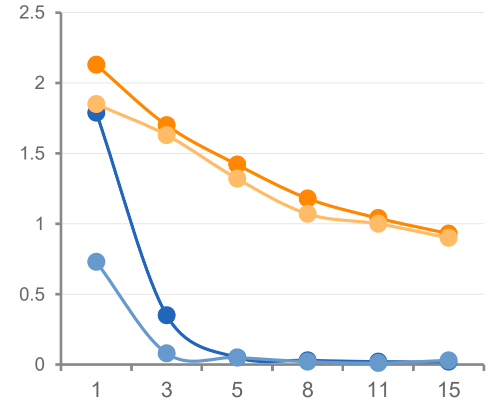

Stage 4 Loss (80ep)

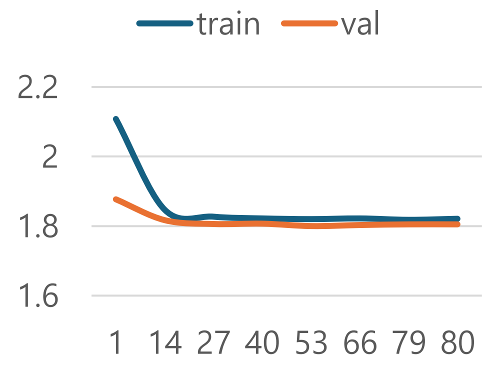

Stage 5 Loss (150ep)

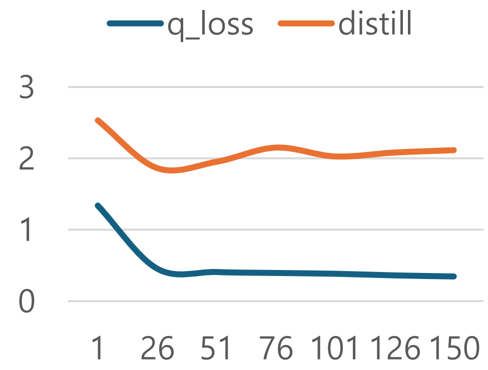

Stage 4 BC 행동 분포(%)

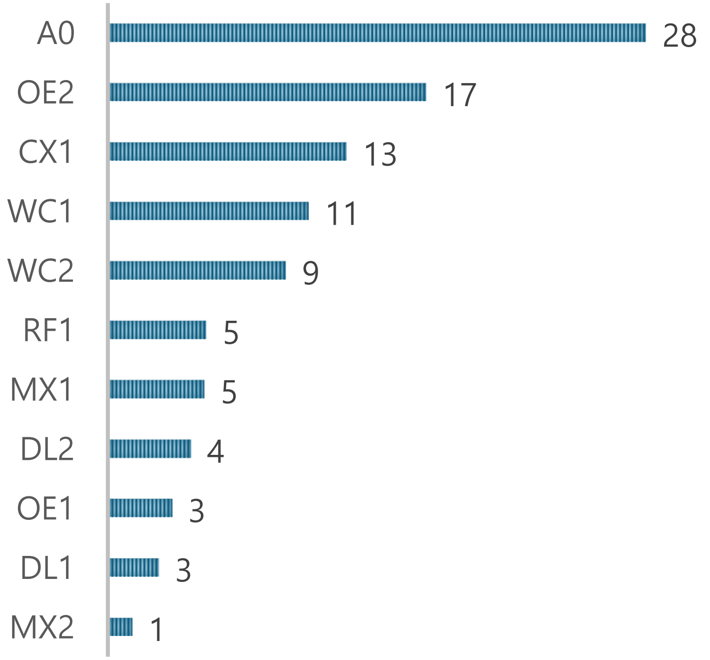

Stage 5 C3(Actor) 행동 분포(%)

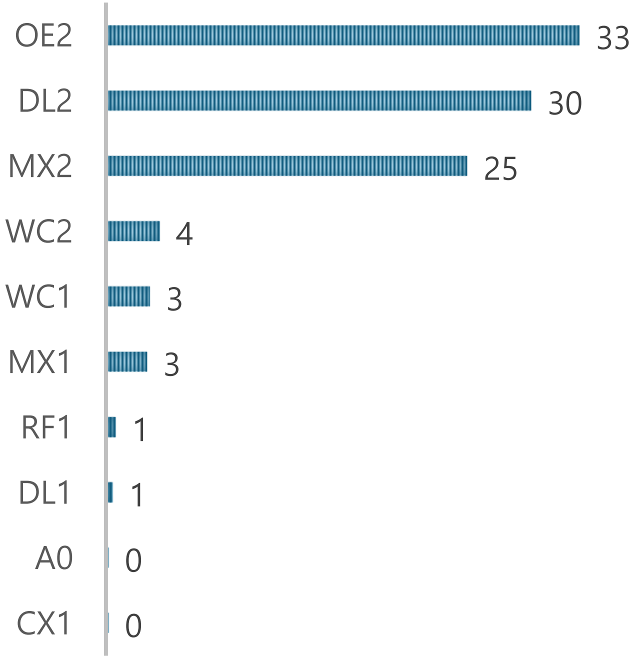

Stage 6 평가 결과 - Oracle α Δnoop

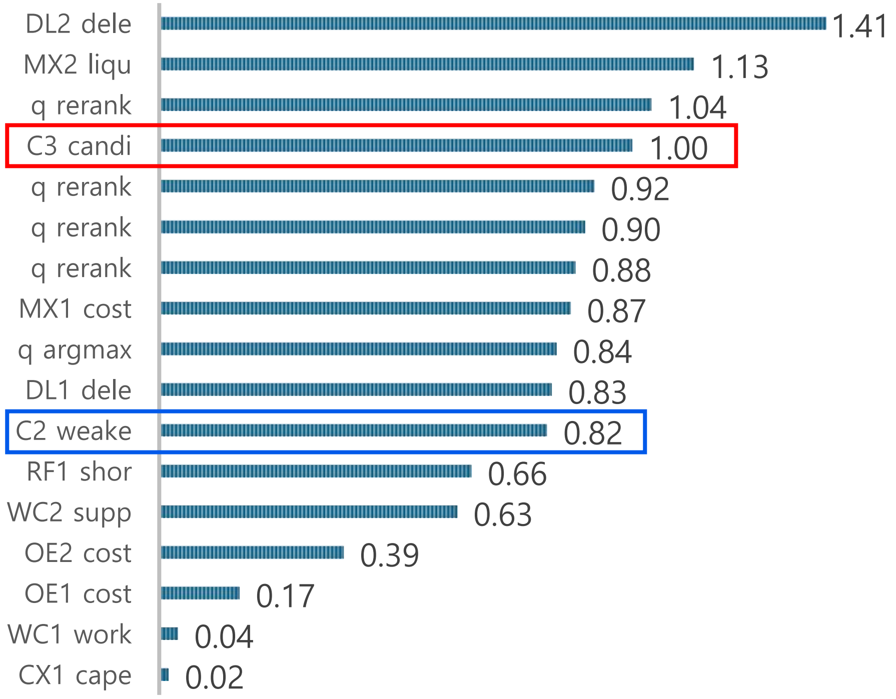

사전실험 – 16) Encoder Batch 512 Epoch 30

Hyperparameter

Stage	항목	값
2	Transition	Observed-only 2251
3	Encoder	학습 (Batch 512, 30 epoch)
4	CB / Projection	β=0.999 / Weighted L1
5	γ/τ/β	0.8/0.9/10.0
5	Distill λ	1.0
6	Eval	421 firm

Stage 3 Loss (Batch 512, 30 epoch)

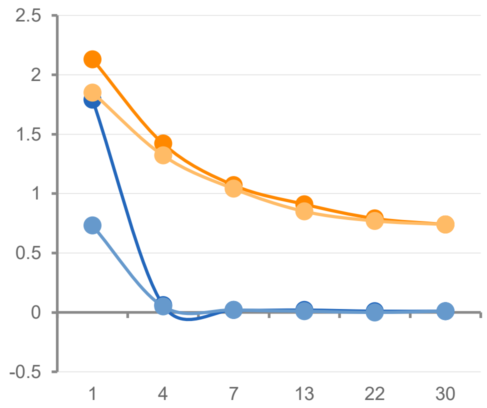

Stage 4 Loss (80ep)

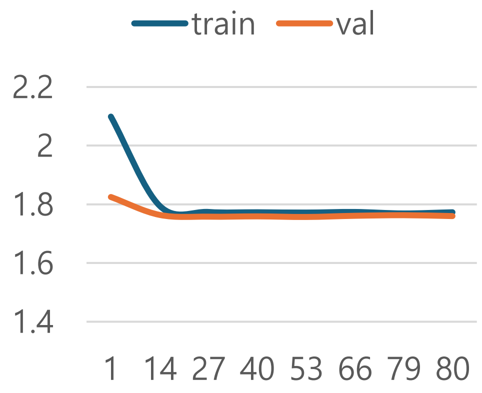

Stage 5 Loss (150ep)

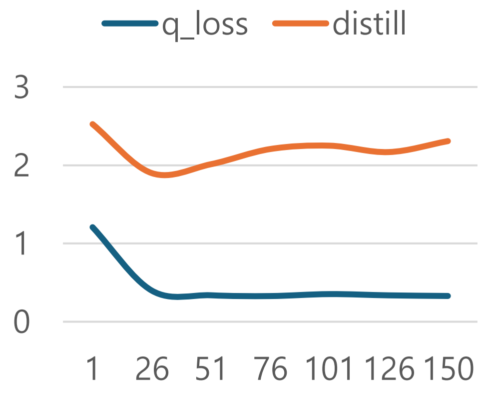

Stage 4 BC 행동 분포(%)

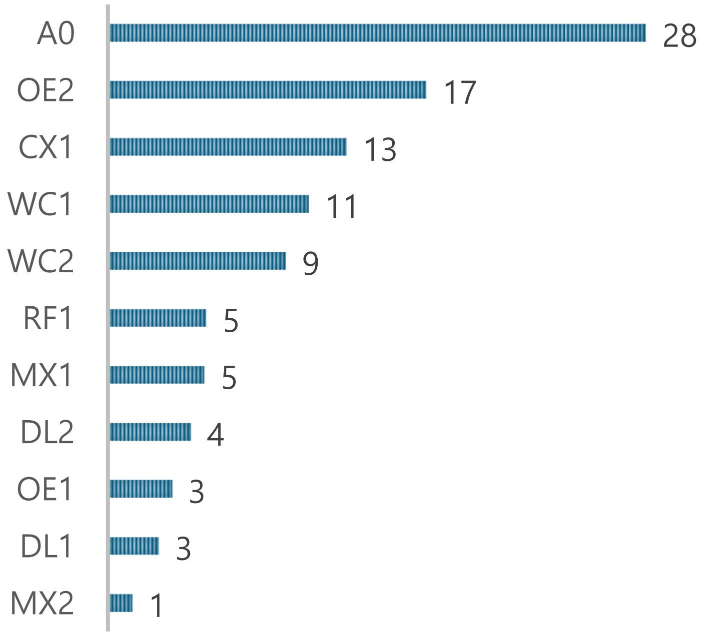

Stage 5 C3(Actor) 행동 분포(%)

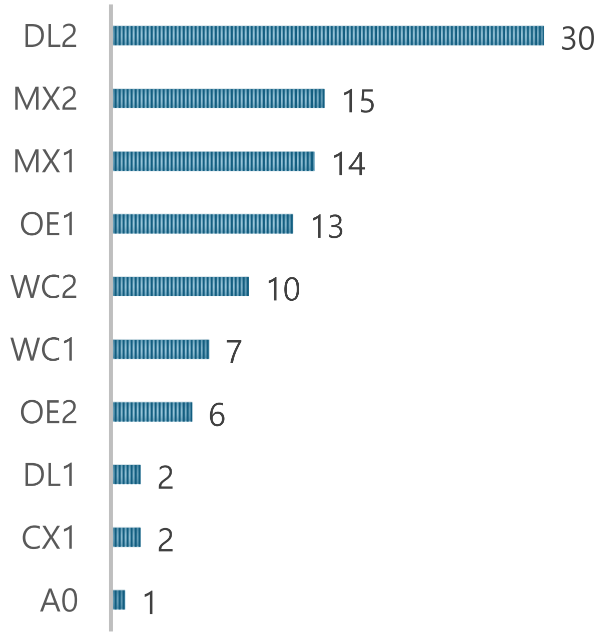

Stage 6 평가 결과 - Oracle α Δnoop

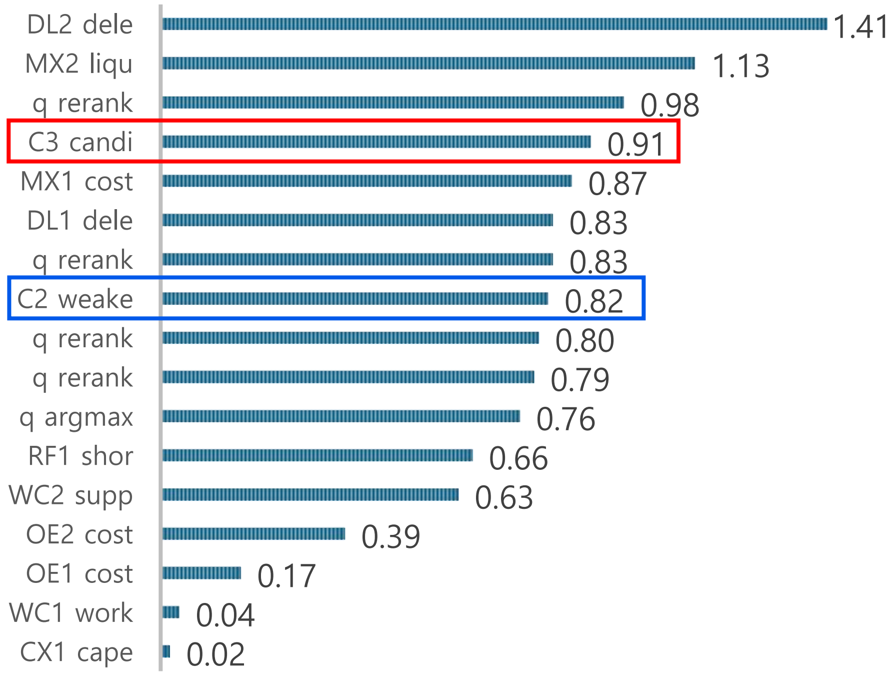

사전실험 – 17) Encoder Batch 512 Epoch 50 P65

Hyperparameter

Stage	항목	값
2	Transition	Observed-only 2251
3	Encoder	학습 (Batch 512, 50 epoch)
4	CB / Projection	β=0.999 / Weighted L1
5	γ/τ/β	0.8/0.9/10.0
5	Distill λ	1.0
6	Eval	421 firm

Stage 3 Loss (Batch 512, 50 epoch)

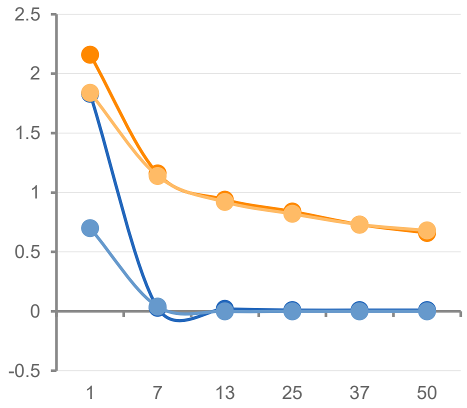

Stage 4 Loss (80ep)

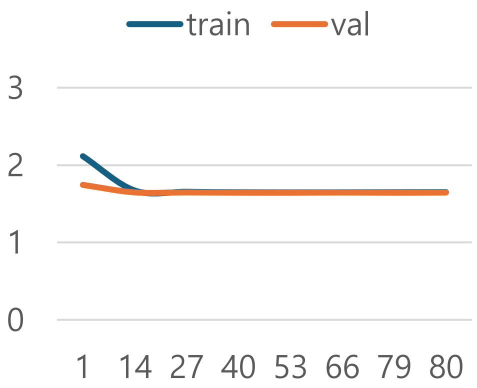

Stage 5 Loss (150ep)

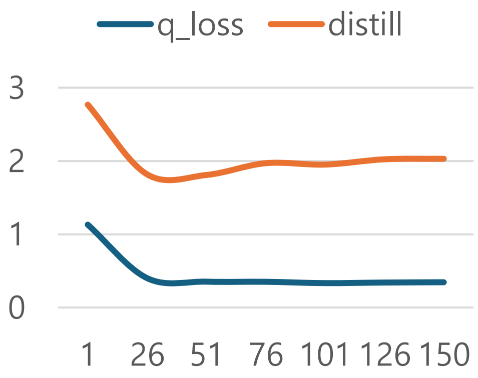

Stage 4 BC 행동 분포(%)

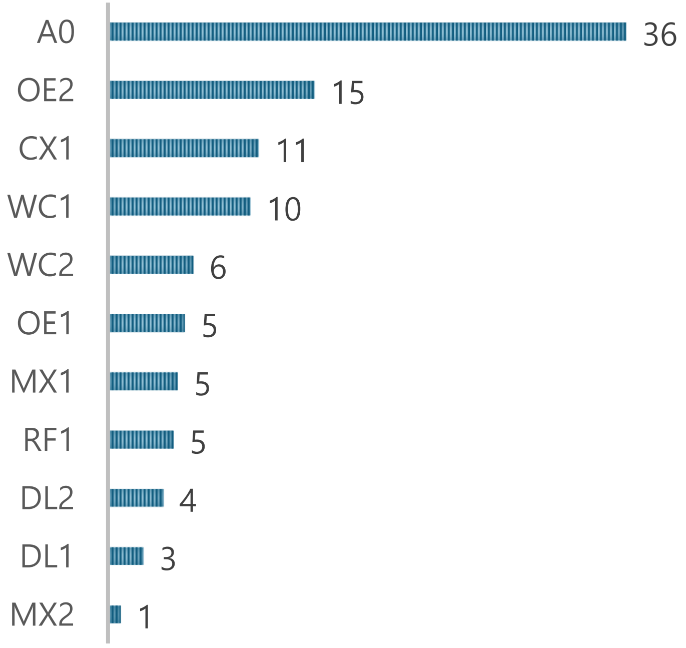

Stage 5 C3(Actor) 행동 분포(%)

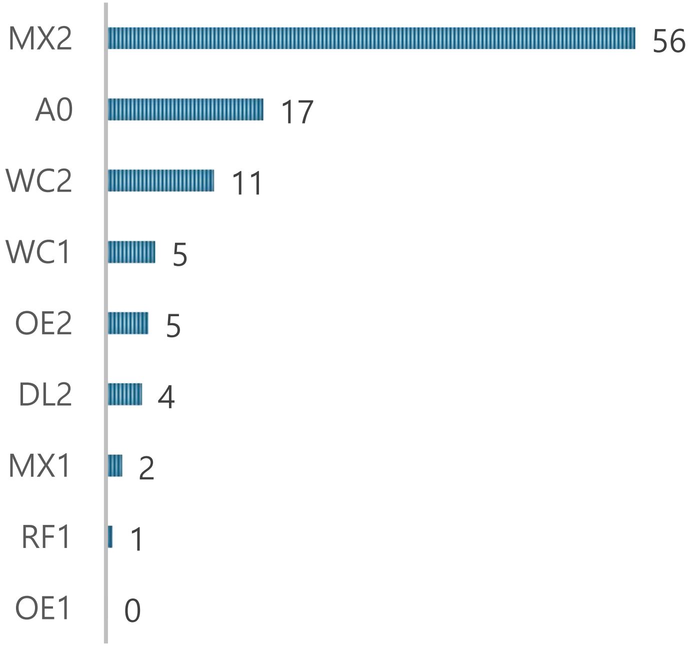

Stage 6 평가 결과 - Oracle α Δnoop

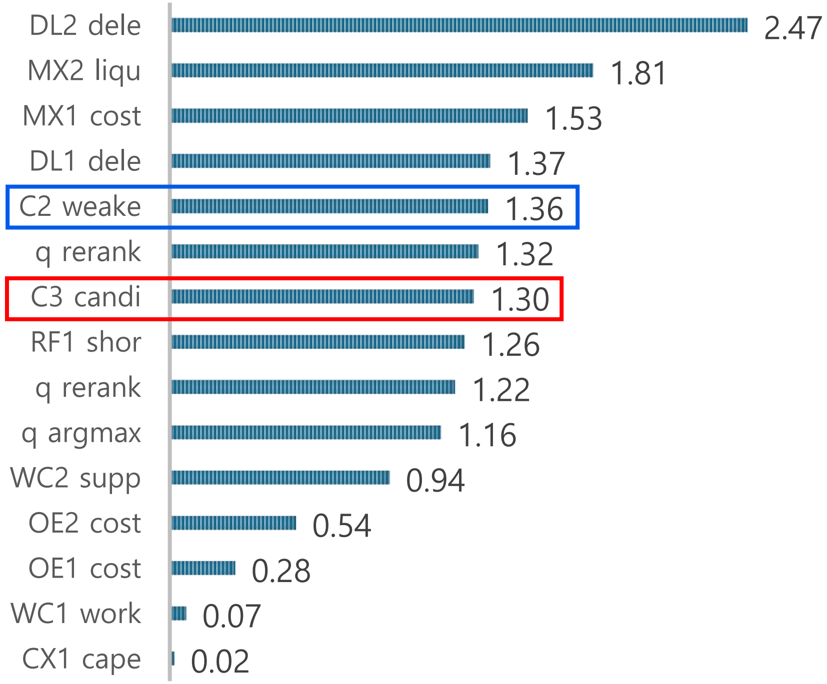

사전실험 – 18) Encoder Batch 256 Epoch 30 Critic head Cross Atten.

Hyperparameter

Stage	항목	값
3	Encoder	d=256, 30ep, mask=0.15 , seed=1
4	CB/P/batch	β=0.999, P50, batch=512
5	γ / τ / β	0.8 / 0.9 / 10.0
5	Critic	cross_attention, blocks= 2, heads=4
5	Distill	CE λ=1.0
5	n / ep / seed	2251 / 150 / 1
6	Eval	421 firm

Stage 3 (30ep)

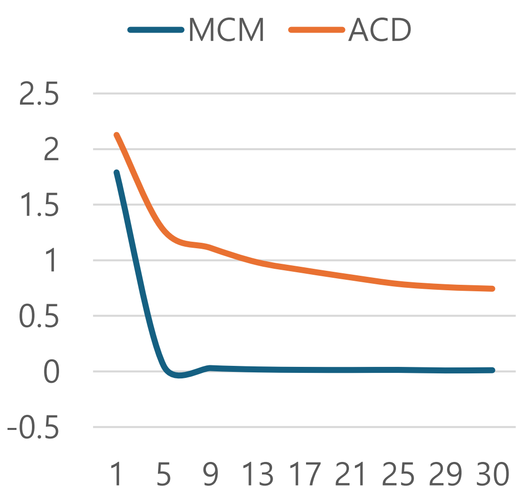

Stage 4 (80ep)

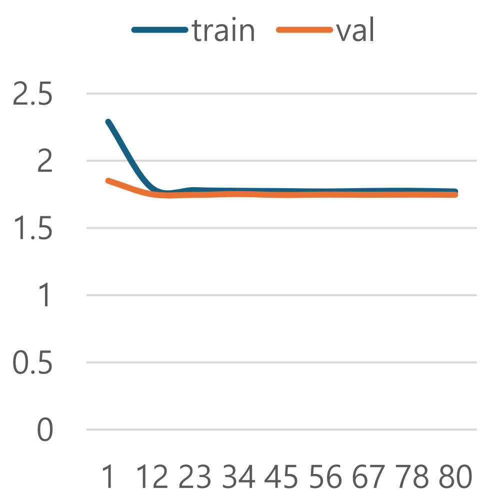

Stage 5 (150ep)

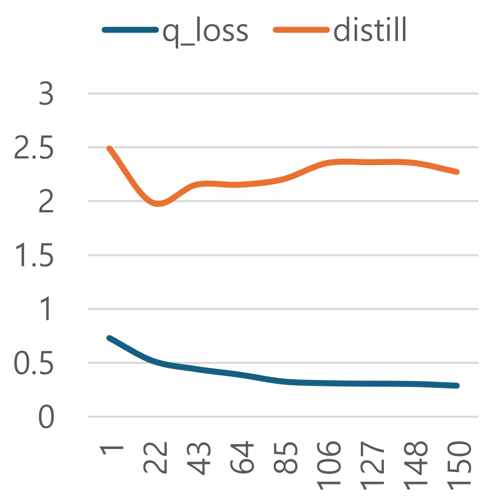

Stage 4 BC 행동 분포(%)

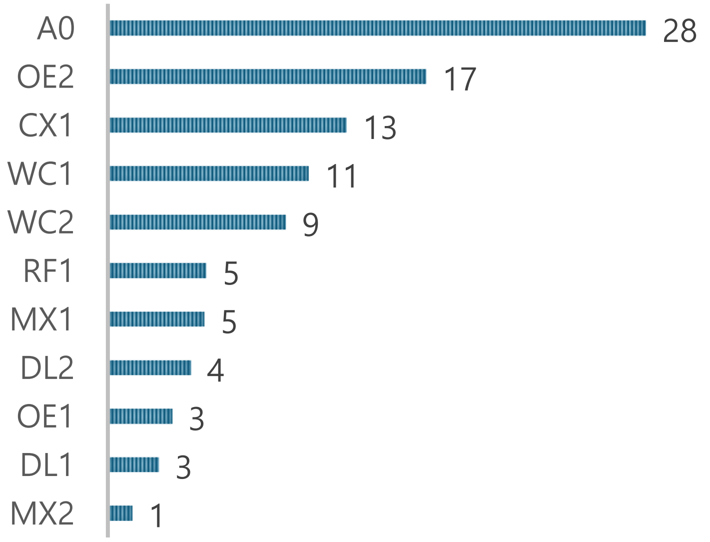

Stage 5 C3(Actor) 행동 분포(%)

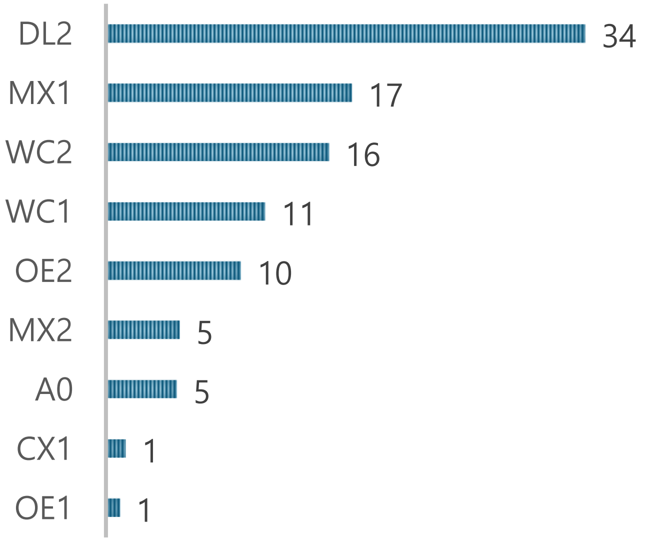

Stage 6 평가 결과 - Oracle α Δnoop

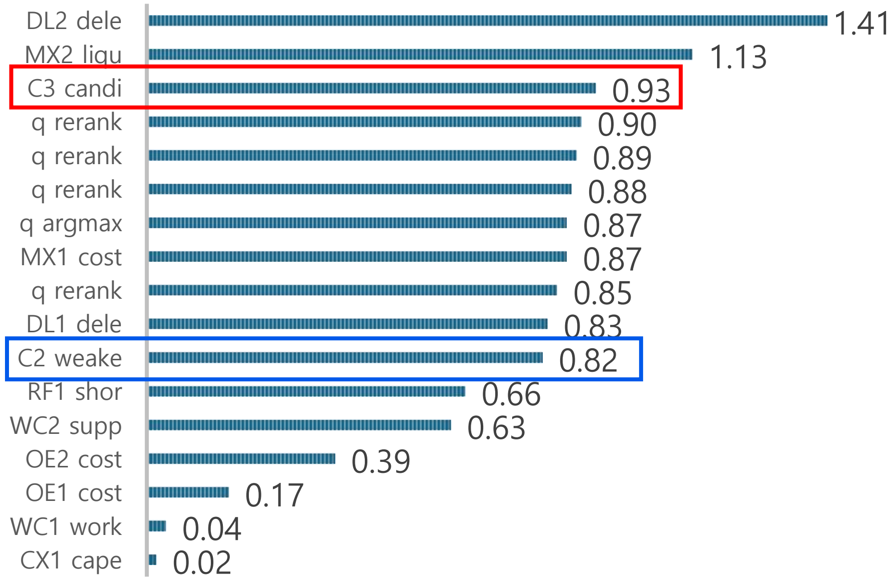

본 실험 – 19) Reward Shaping – Merton 0.5 FCFF 0.1 Liquidity 0

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.5 F=0.1 L=-
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	Batch 512 30ep
4	CB / FB	β=0.999 / 없음
5	γ/τ/β	0.8 / 0.9 / 10
5	Distill / Critic	λ=1 / linear
5·6	S5 / Eval	train (lr=0.0003) / 421

Stage 3 Loss (30ep)

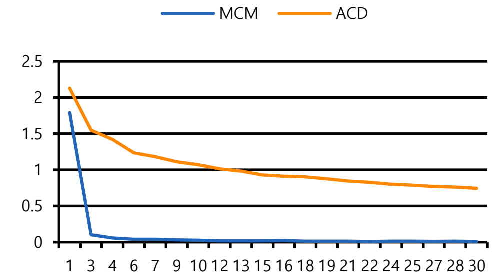

Stage 4 Loss (80ep)

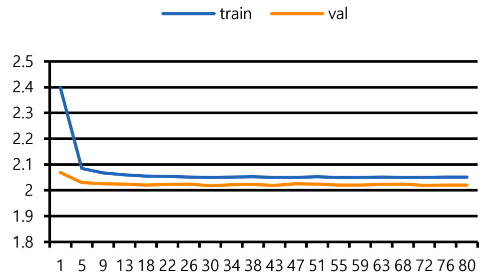

Stage 5 Loss (150ep)

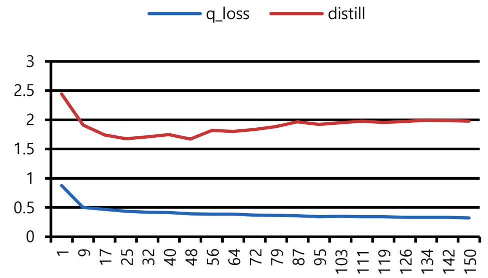

Stage 4 BC 행동 분포(%)

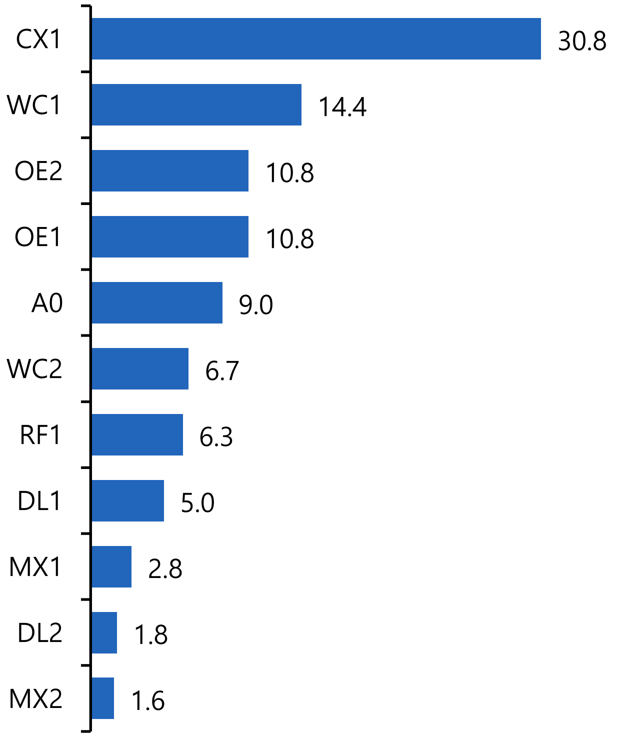

Stage 5 C3(Actor) 행동 분포(%)

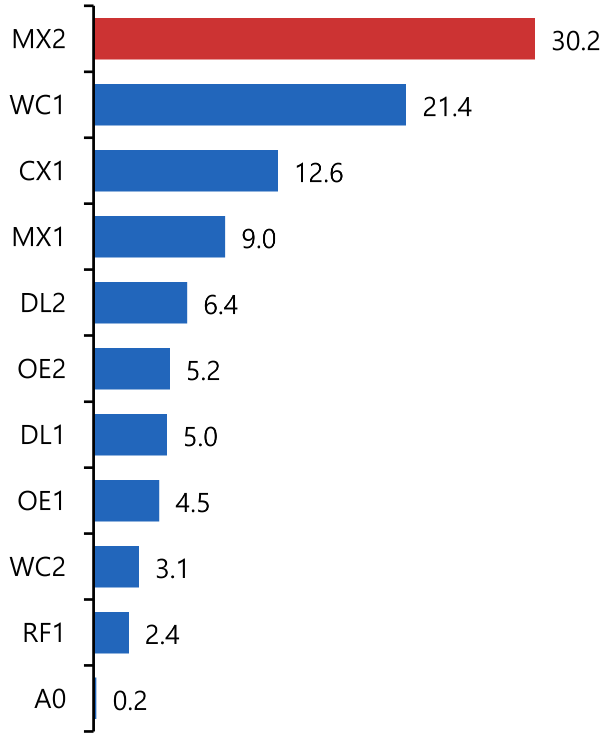

Stage 6 평가 결과 - Oracle α Δnoop

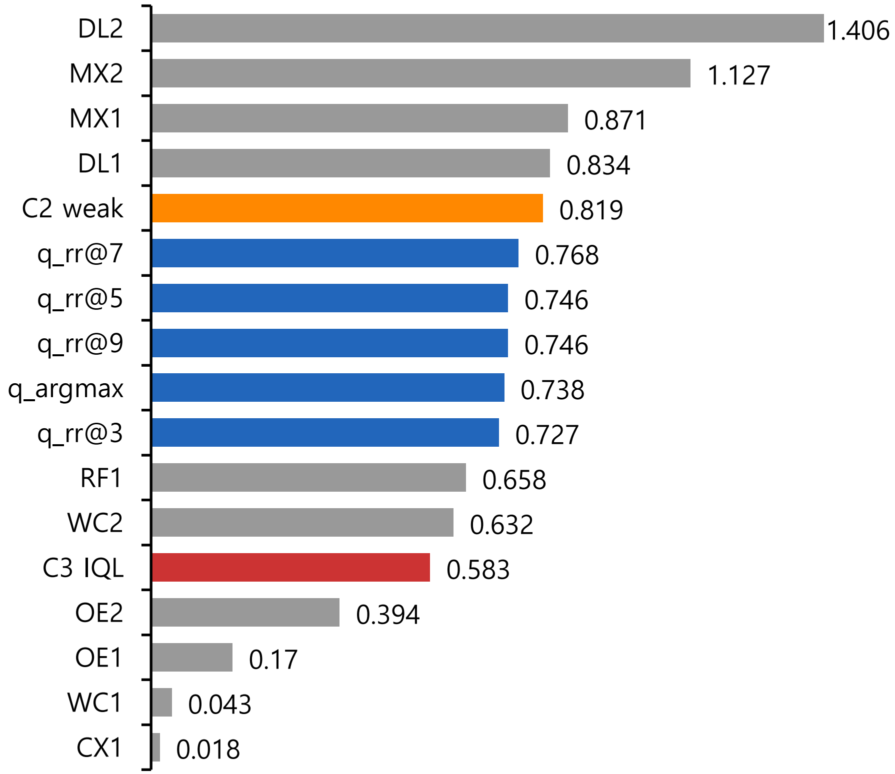

본 실험 – 20) Reward Shaping – M 0.5 F 0.1 L 0 Distill 3

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.5 F=0.1 L=-
2·4	Mode	S2:skip / S4:skip_reuse_active
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / 없음
5	γ/τ/β	0.8 / 0.9 / 10
5	Distill / Critic	λ=3 / linear
5·6	S5 / Eval	train (lr=0.0003) / 421

Stage 3 Loss (30ep)

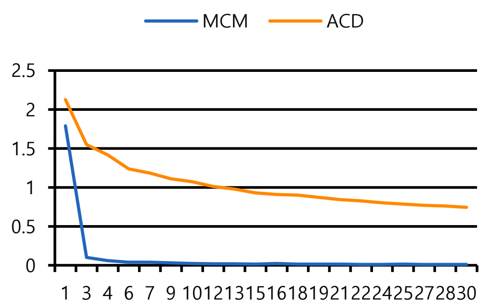

Stage 4 Loss (80ep)

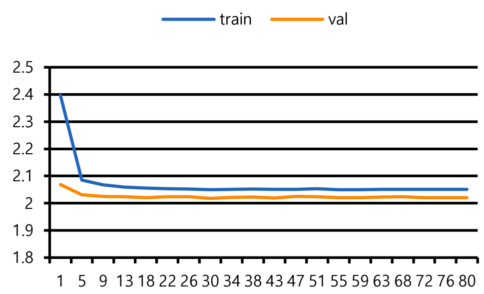

Stage 5 Loss (150ep)

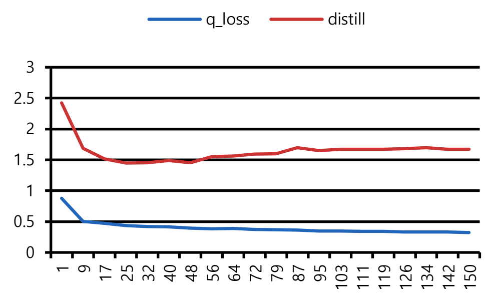

Stage 4 BC 행동 분포(%)

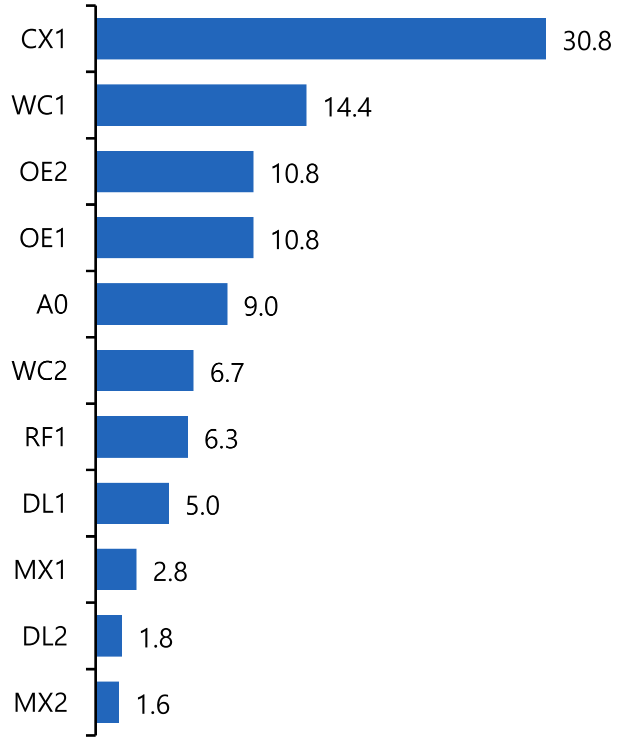

Stage 5 C3(Actor) 행동 분포(%)

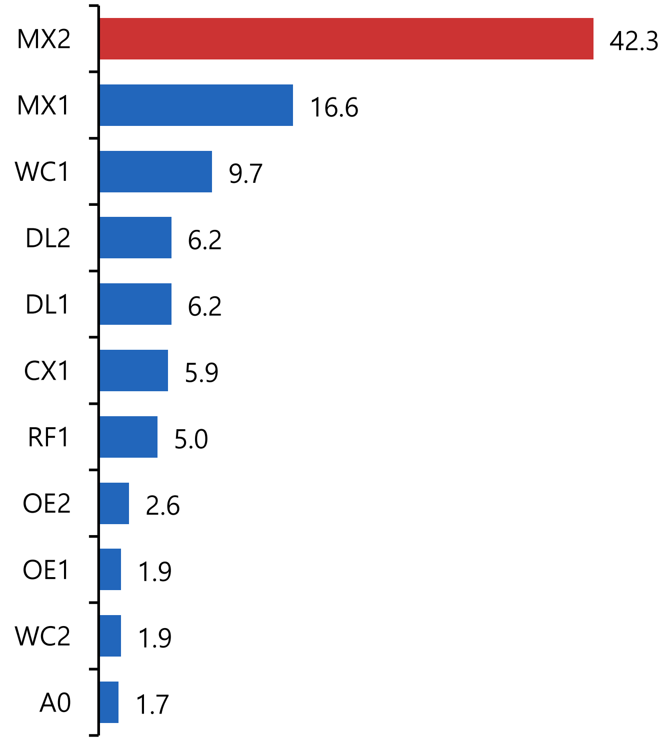

Stage 6 평가 결과 - Oracle α Δnoop

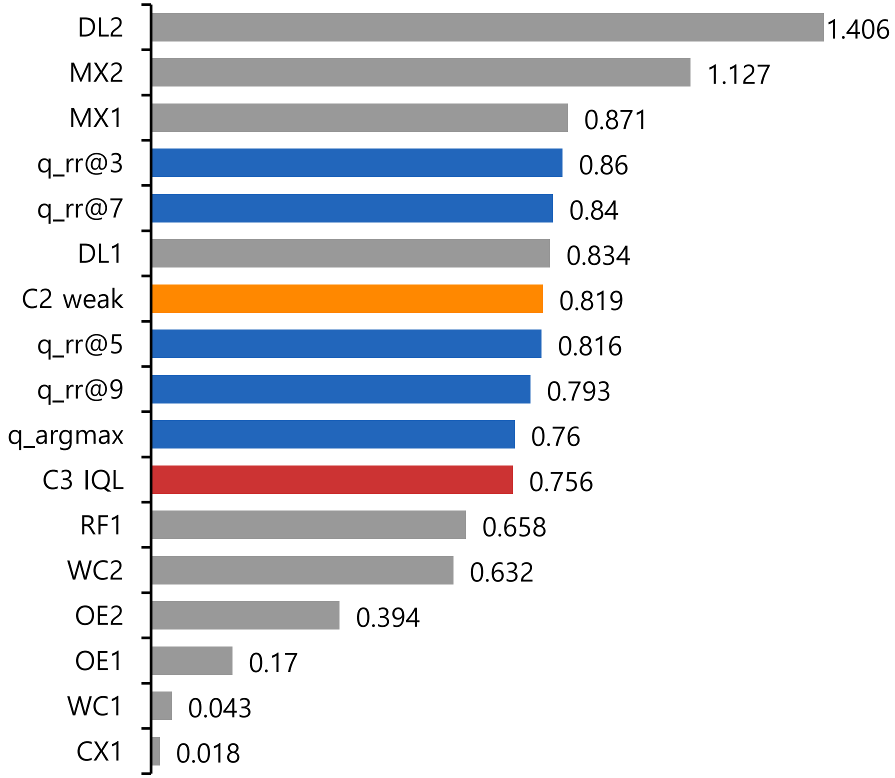

본 실험 – 21) Reward Shaping – M 0.5 F 0.1 L 0 Distill 3 Tau 0.7

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.5 F=0.1 L=-
2·4	Mode	S2:skip / S4:skip_reuse_active
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / 없음
5	γ/τ/β	0.8 / 0.7 / 10
5	Distill / Critic	λ=3 / linear
5·6	S5 / Eval	train (lr=0.0003) / 421

Stage 3 Loss (30ep)

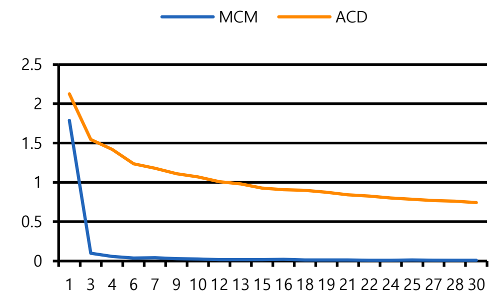

Stage 4 Loss (80ep)

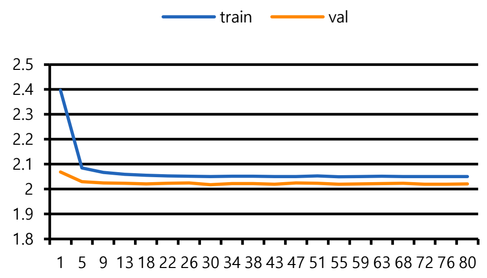

Stage 5 Loss (150ep)

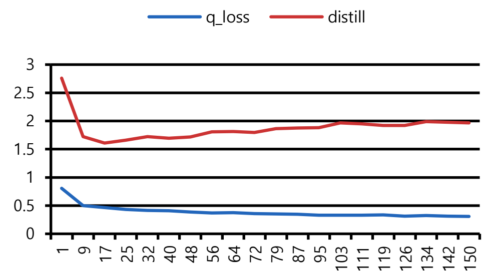

Stage 4 BC 행동 분포(%)

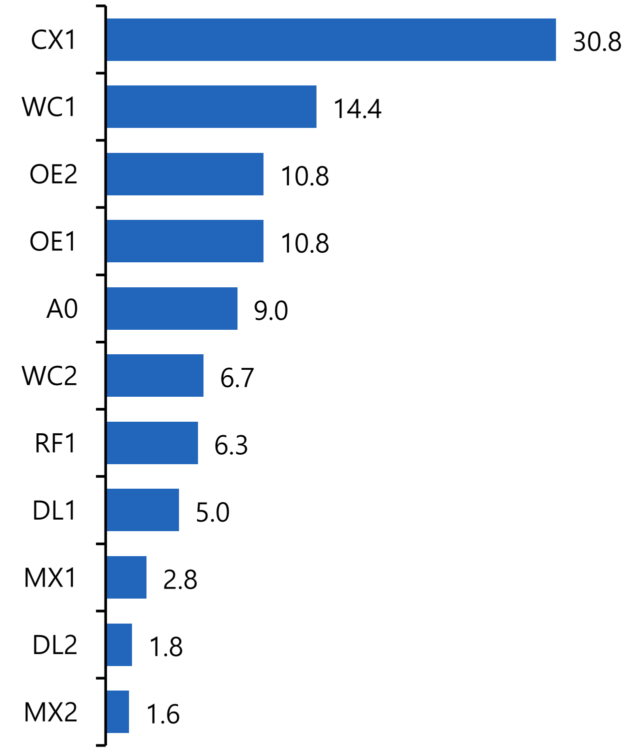

Stage 5 C3(Actor) 행동 분포(%)

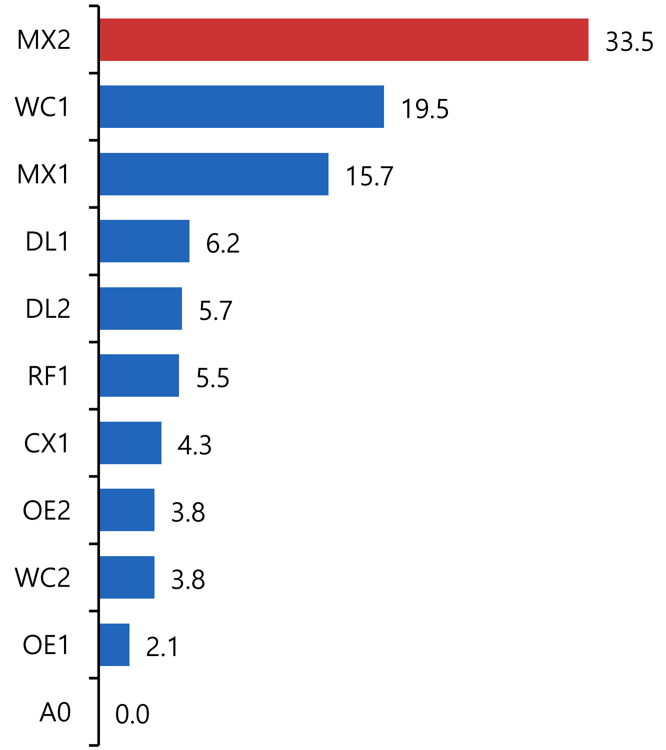

Stage 6 평가 결과 - Oracle α Δnoop

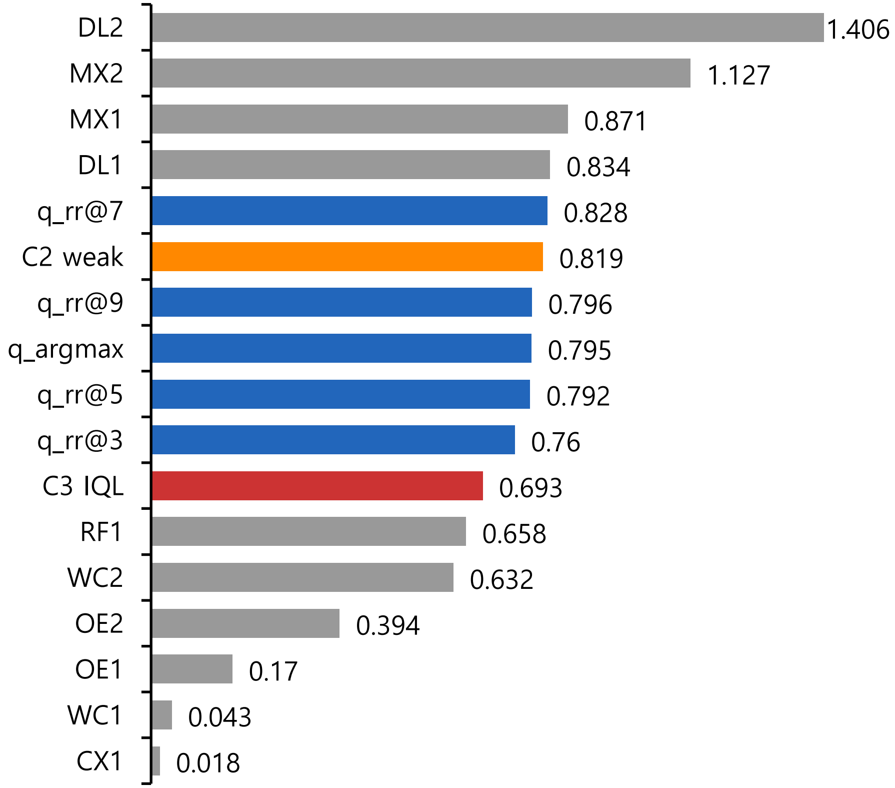

본 실험 – 22) Counterfacutal M 0.1 F 0.2 L 0 Distill 3 Family Balanced Cross Atten.

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.1 F=0.2 L=-
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.8 / 0.9 / 10
5	Distill / Critic	λ=3 / cross_attention
5·6	S5 / Eval	train (lr=0.0001) / 421

Stage 3 Loss (30ep)

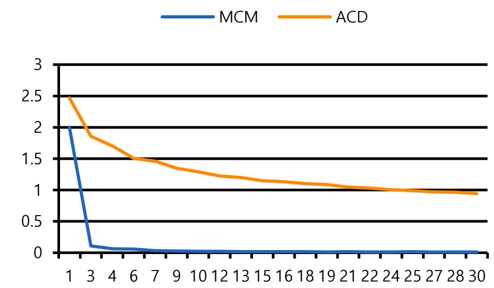

Stage 4 Loss (80ep)

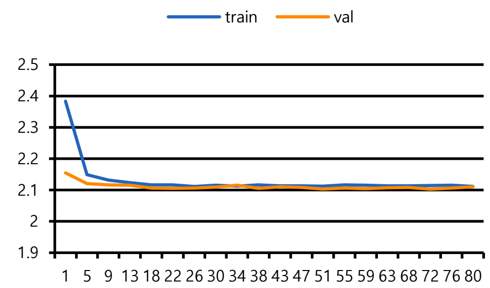

Stage 5 Loss (80ep)

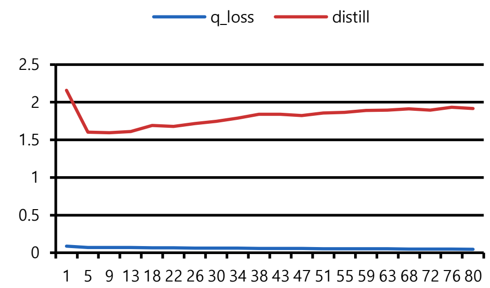

Stage 4 BC 행동 분포(%)

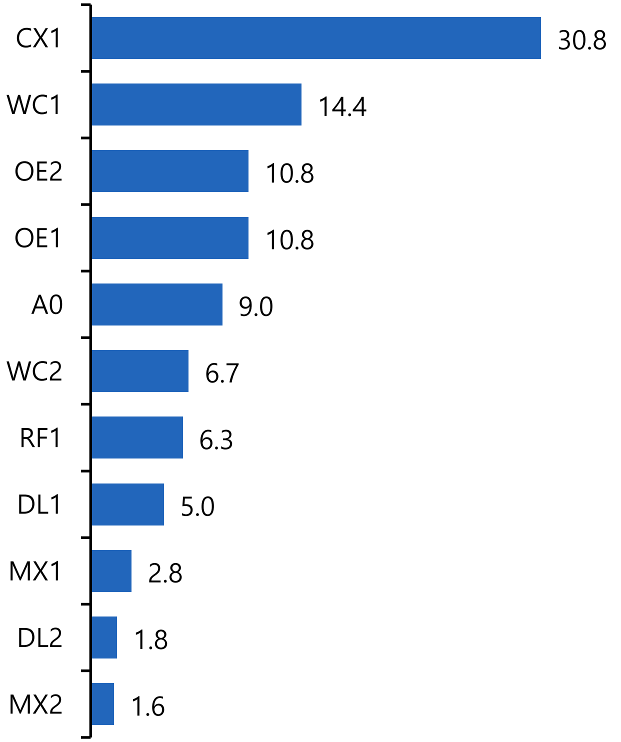

Stage 5 C3(Actor) 행동 분포(%)

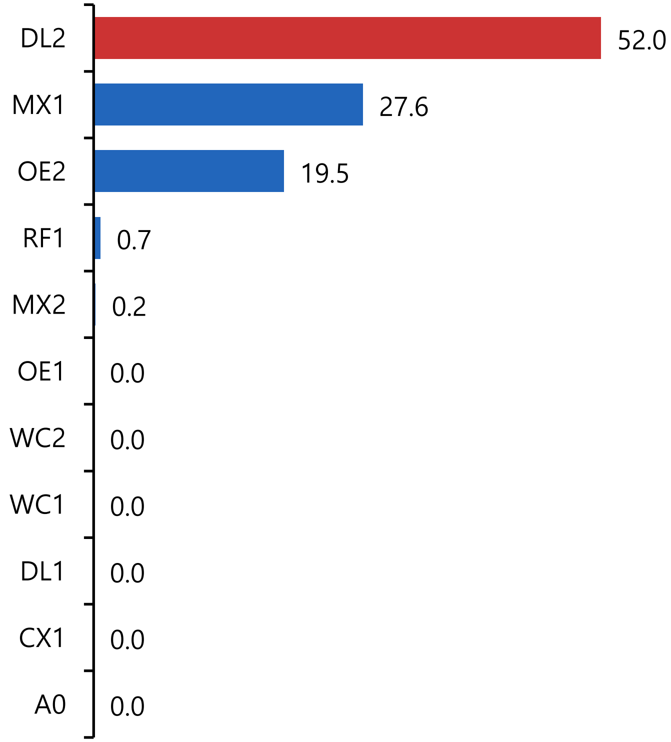

Stage 6 평가 결과 - Oracle α Δnoop

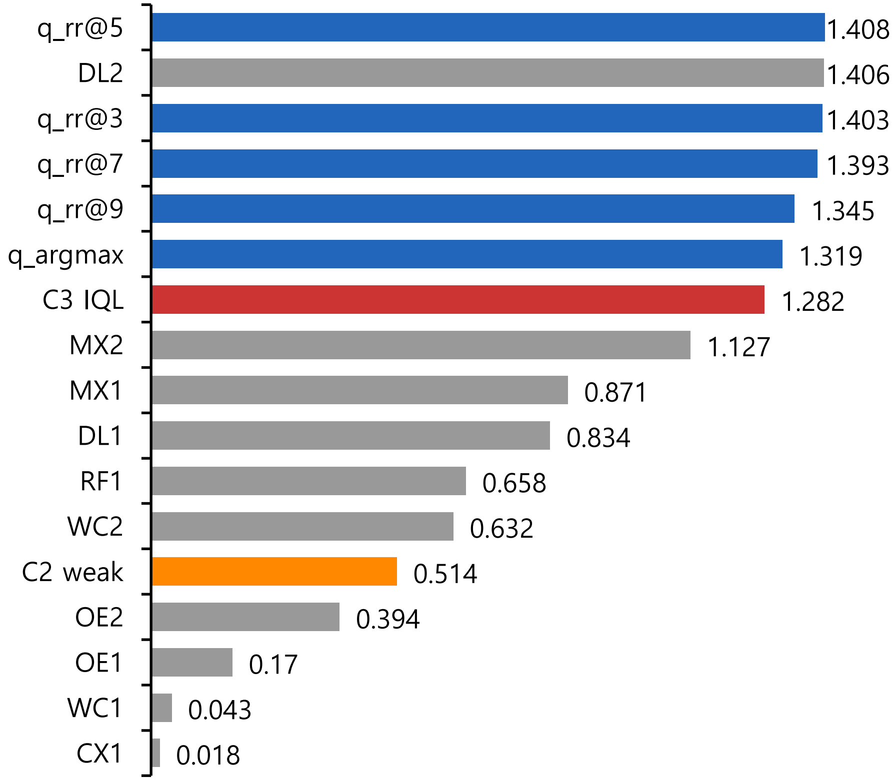

본 실험 – 23) M 0.15 F 0.15 L 0.15

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.15 F=0.15 L=0.15
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.8 / 0.9 / 10
5	Distill / Critic	λ=3 / cross_attention
5·6	S5 / Eval	train (lr=0.0001) / 421

Stage 3 Loss (30ep)

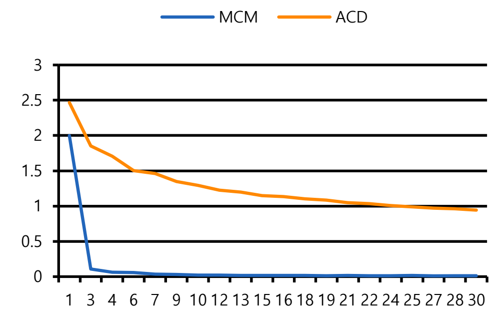

Stage 4 Loss (80ep)

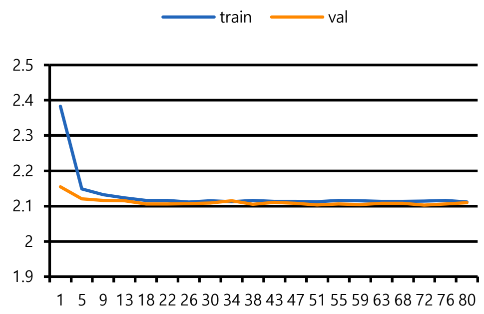

Stage 5 Loss (80ep)

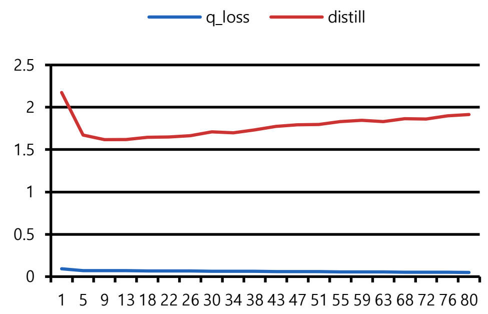

Stage 4 BC 행동 분포(%)

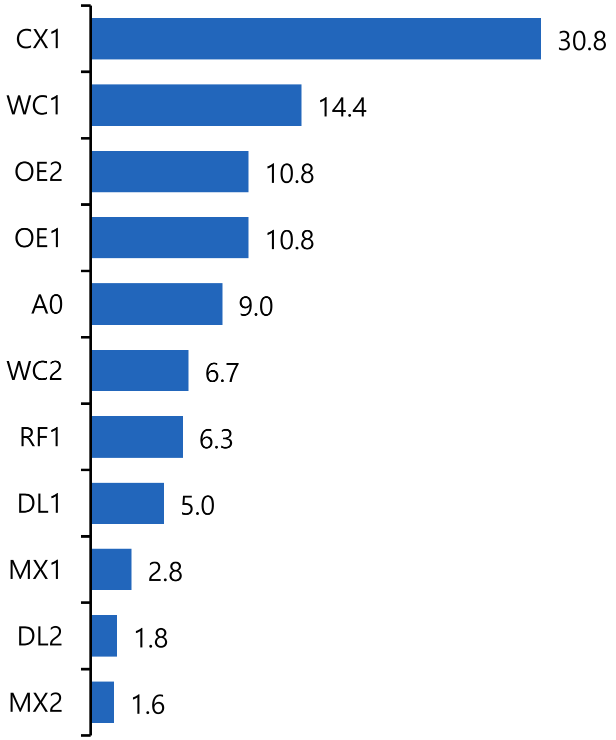

Stage 5 C3(Actor) 행동 분포(%)

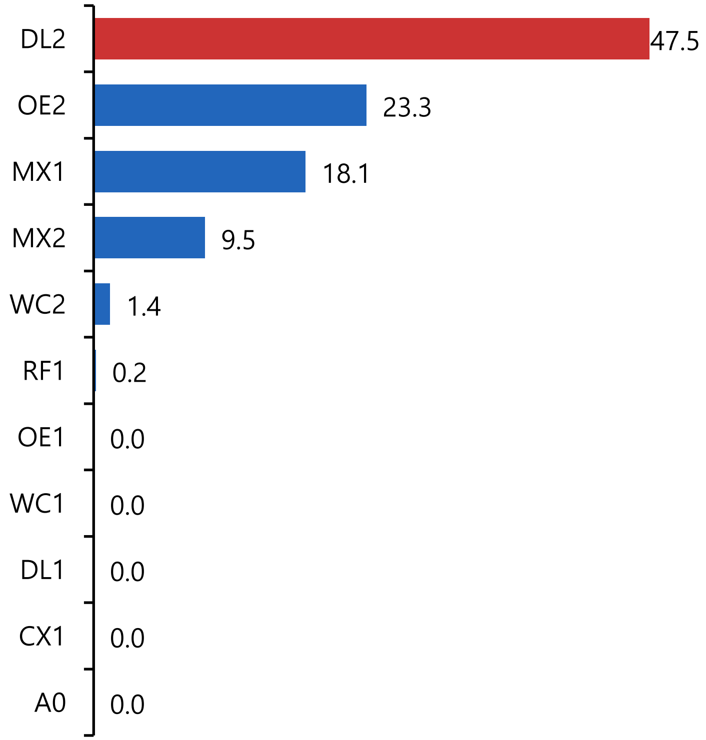

Stage 6 평가 결과 - Oracle α Δnoop

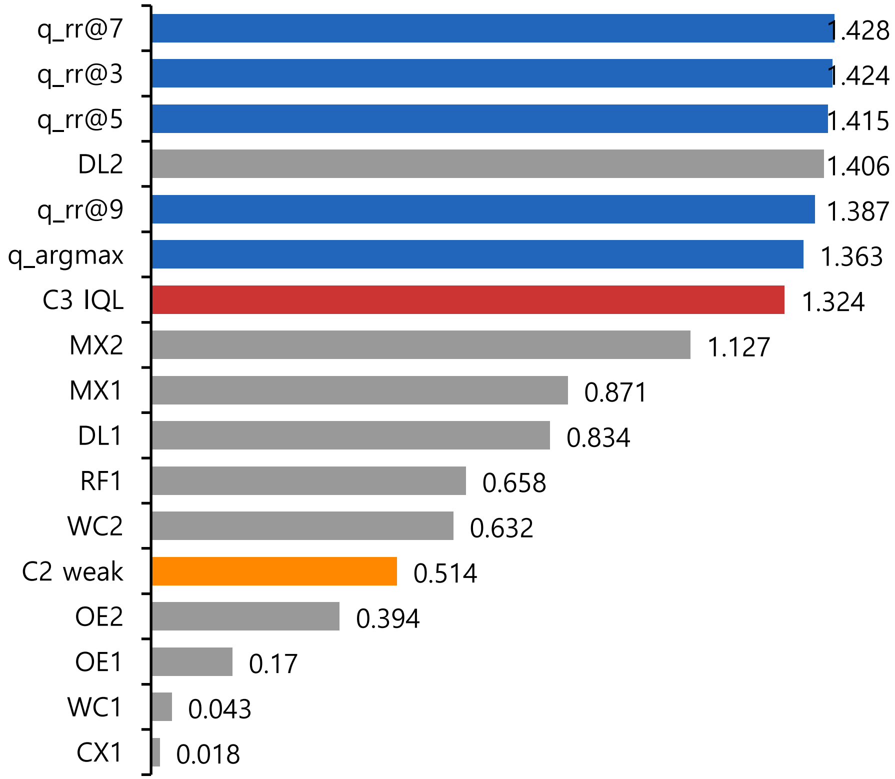

본 실험 – 24) M 0.15 F 0.10 L 0.50 Gamma 0.75 Beta 15

Hyperparameter

Stage	항목	값
2	Reward	**ρ=0 M=0.15 F=0.1 L=0.5**
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	**0.75 / 0.9 / 15**
5	Distill / Critic	λ=3 / cross_attention
5·6	S5 / Eval	train (lr=0.0001) / 421

Stage 3 Loss (30ep)

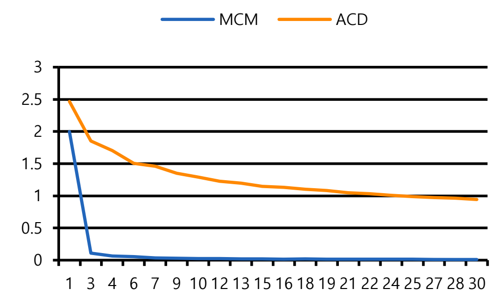

Stage 4 Loss (80ep)

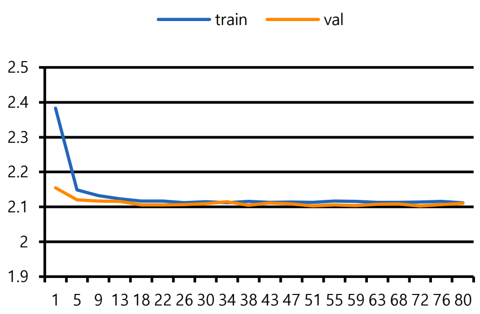

Stage 5 Loss (80ep)

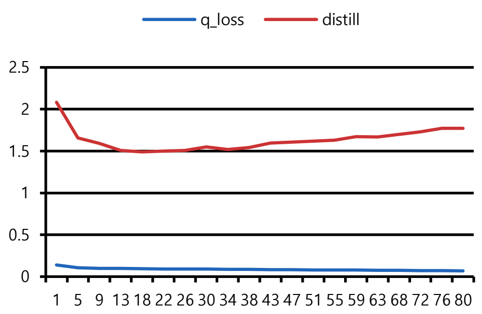

Stage 4 BC 행동 분포(%)

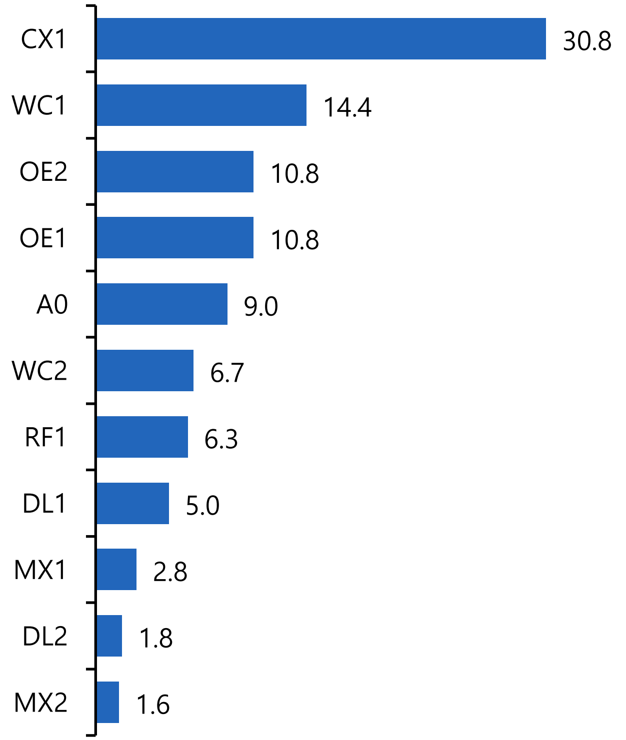

Stage 5 C3(Actor) 행동 분포(%)

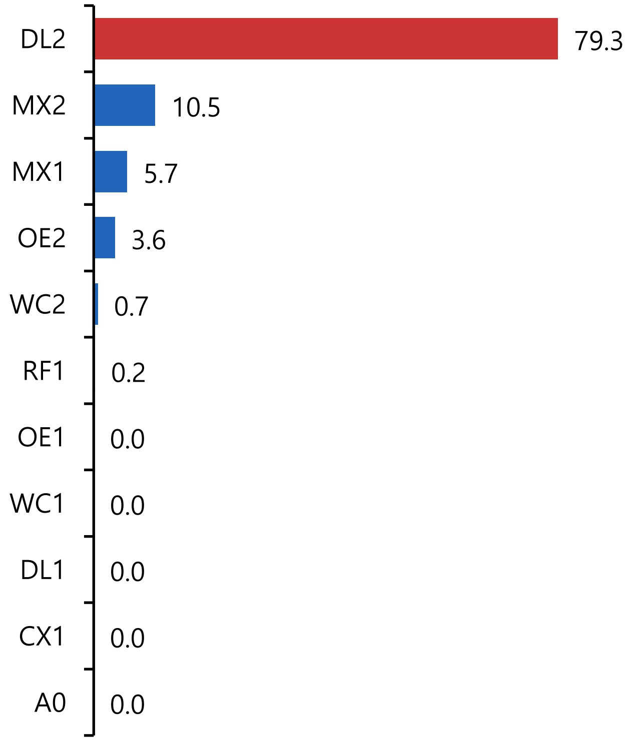

Stage 6 평가 결과 - Oracle α Δnoop

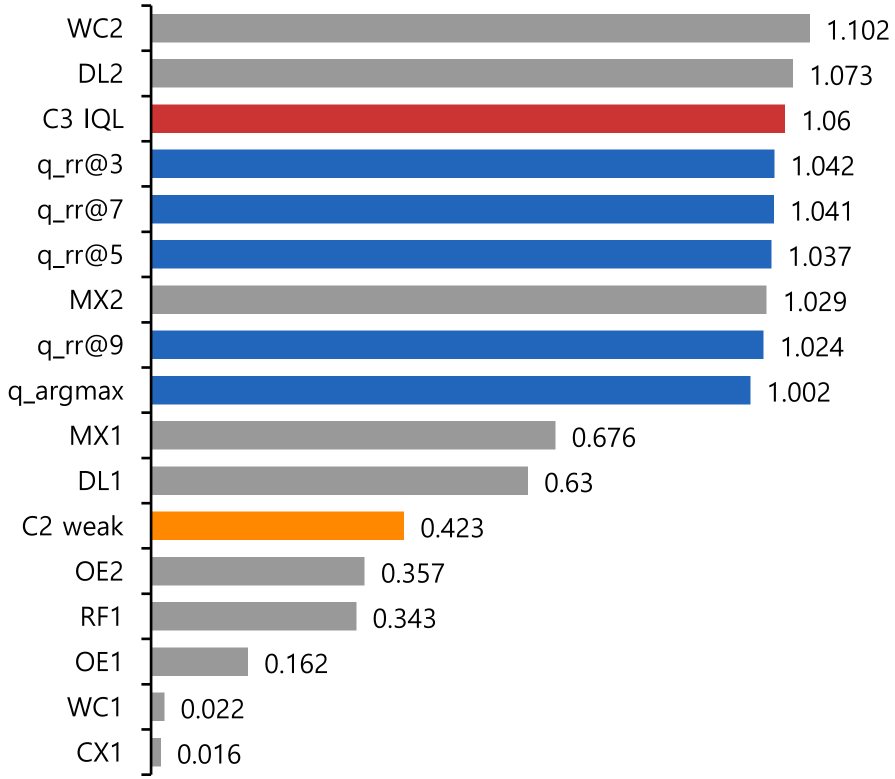

본 실험 – 25) M 0.15 F 0.10 L 0.50 tau 0.7 beta 6

Hyperparameter

Stage	항목	값
2	Reward	**ρ=0 M=0.15 F=0.1 L=0.5**
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	**0.75 / 0.7 / 6**
5	Distill / Critic	λ=3 / cross_attention
5·6	S5 / Eval	train (lr=0.0001) / 421

Stage 3 Loss (30ep)

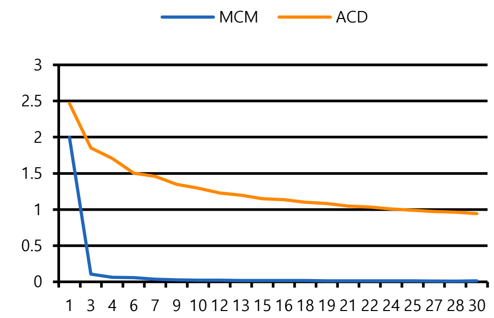

Stage 4 Loss (80ep)

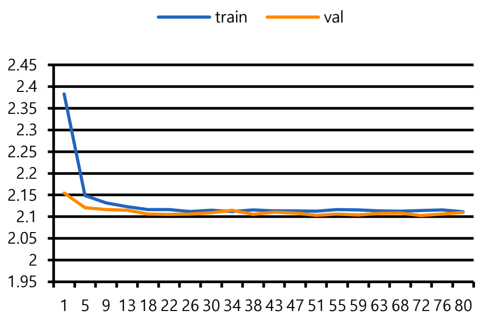

Stage 5 Loss (80ep)

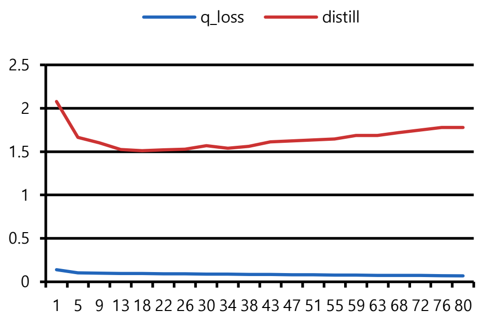

Stage 4 BC 행동 분포(%)

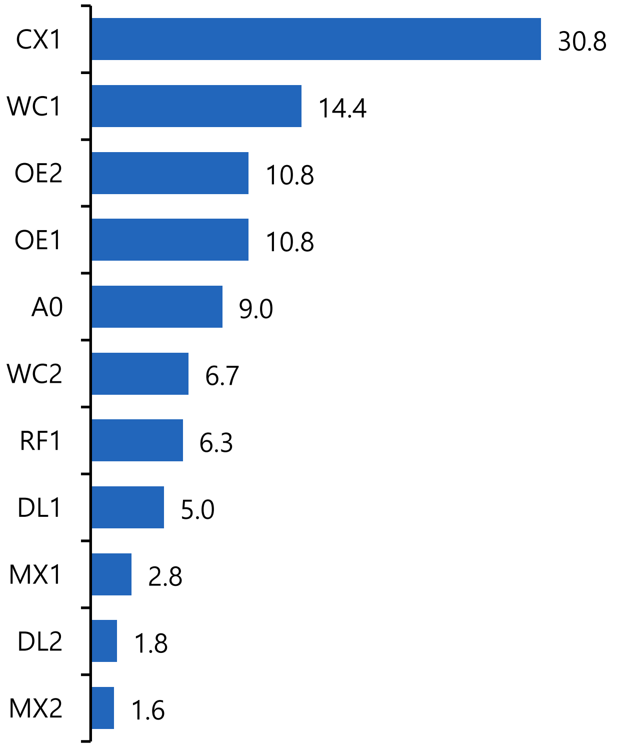

Stage 5 C3(Actor) 행동 분포(%)

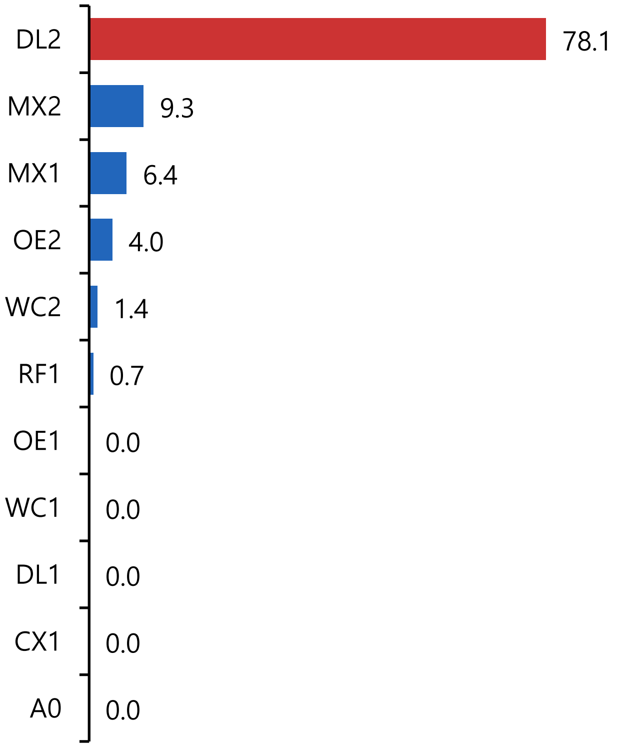

Stage 6 평가 결과 - Oracle α Δnoop

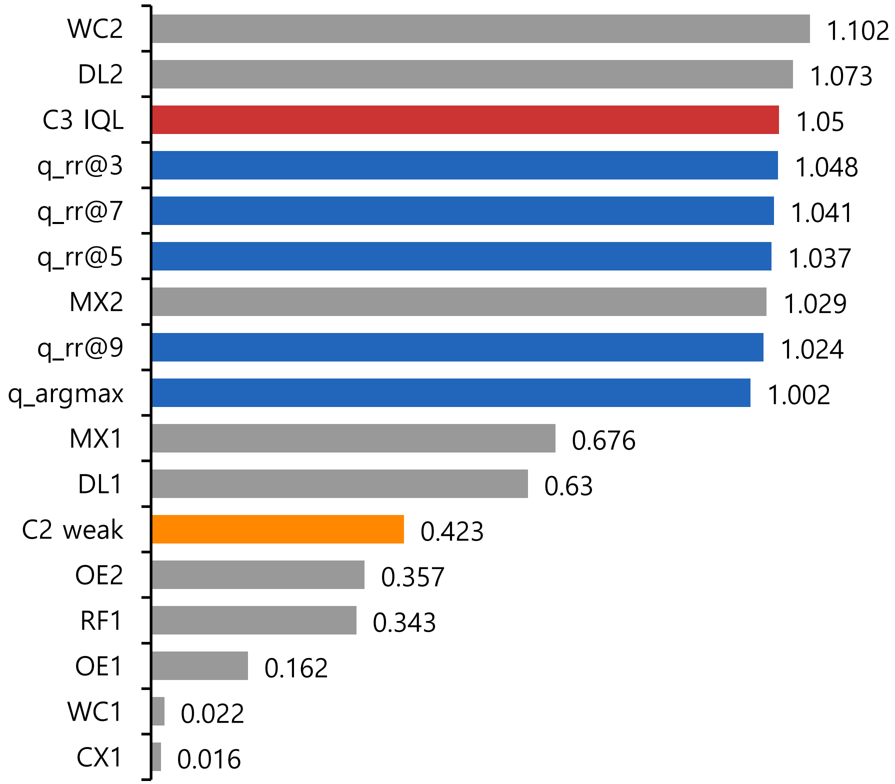

본 실험 – 26) M 0.05 F 0 L 0.50

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0 L=0.5
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.75 / 0.7 / 6
5	Distill / Critic	λ=3 / cross_attention
5·6	S5 / Eval	train (lr=0.0001) / 421

Stage 3 Loss (30ep)

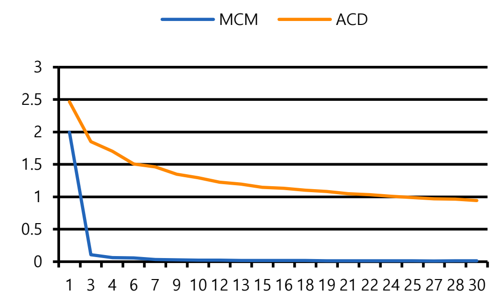

Stage 4 Loss (80ep)

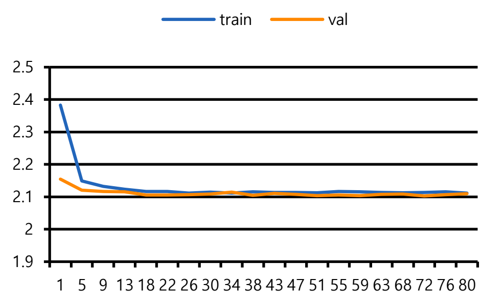

Stage 5 Loss (80ep)

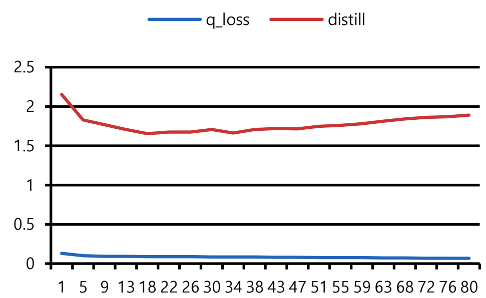

Stage 4 BC 행동 분포(%)

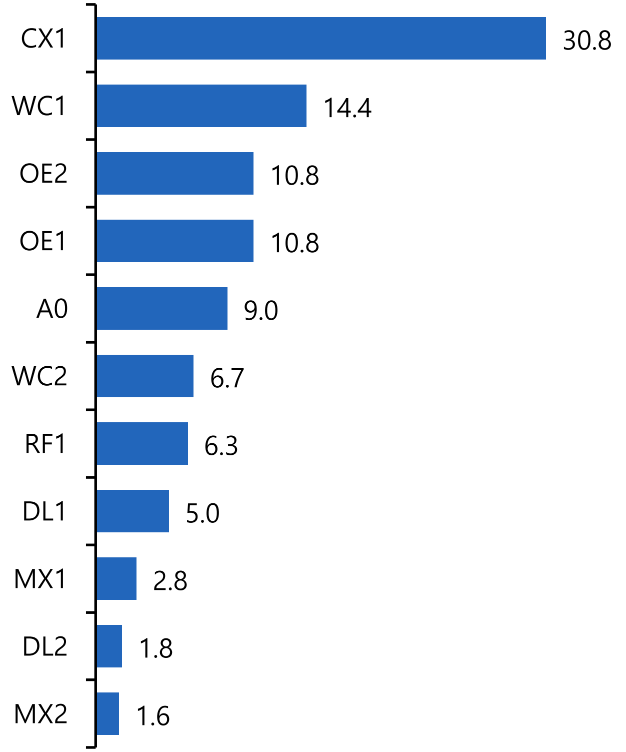

Stage 5 C3(Actor) 행동 분포(%)

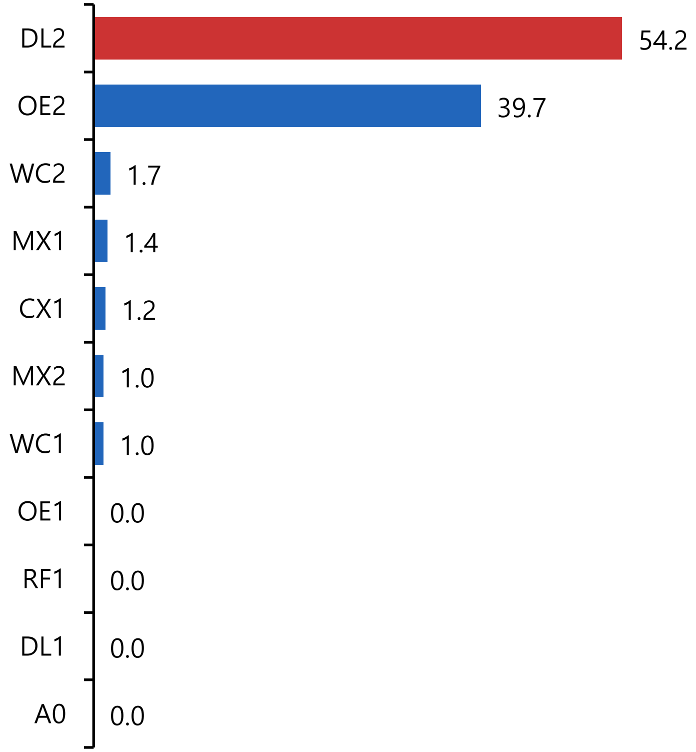

Stage 6 평가 결과 - Oracle α Δnoop

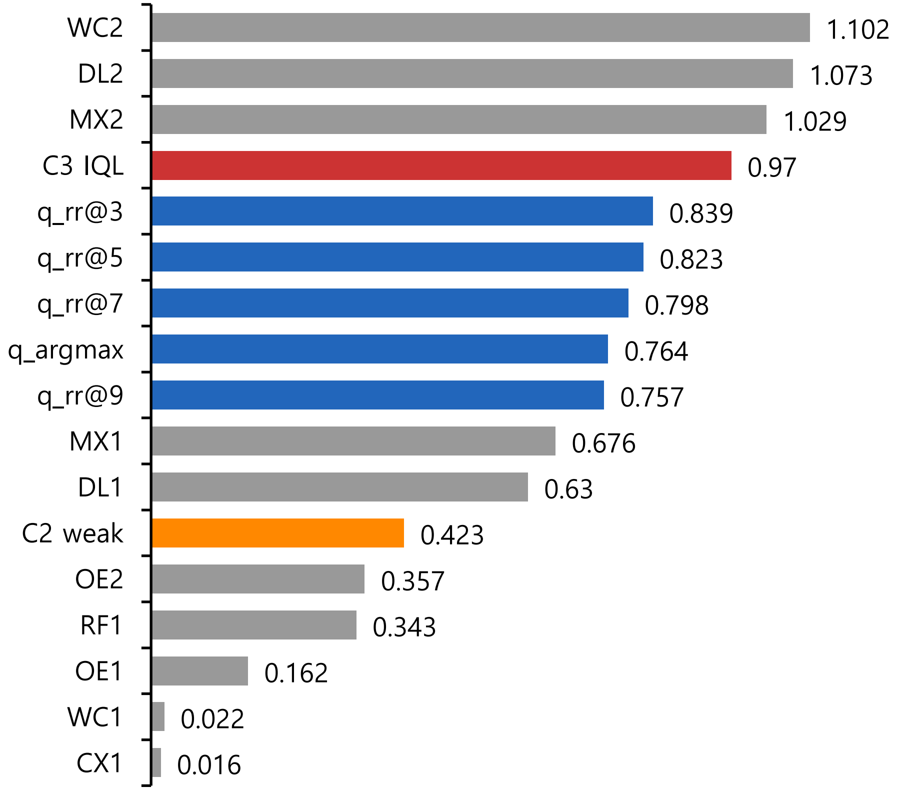

본 실험 – 27) M 0.15, F 0.20 L 0.05 Distill 1.0 New Oracle

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.15 F=0.2 L=0.05
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.75 / 0.7 / 6
5	Distill / Critic	λ=1 / cross_attention
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

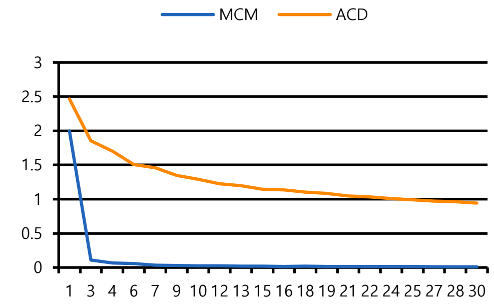

Stage 4 Loss (80ep)

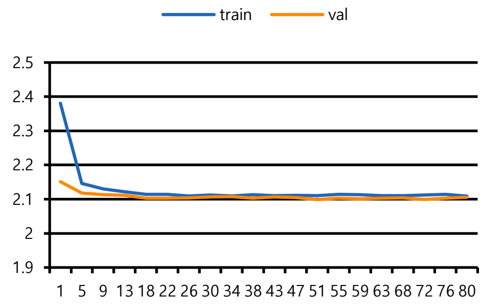

Stage 5 Loss (80ep)

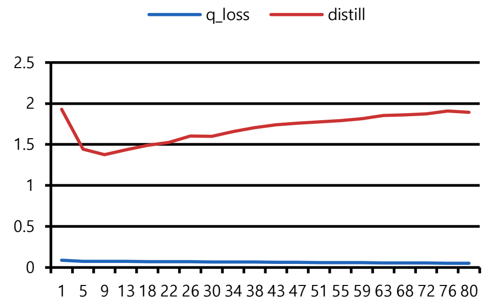

Stage 4 BC 행동 분포(%)

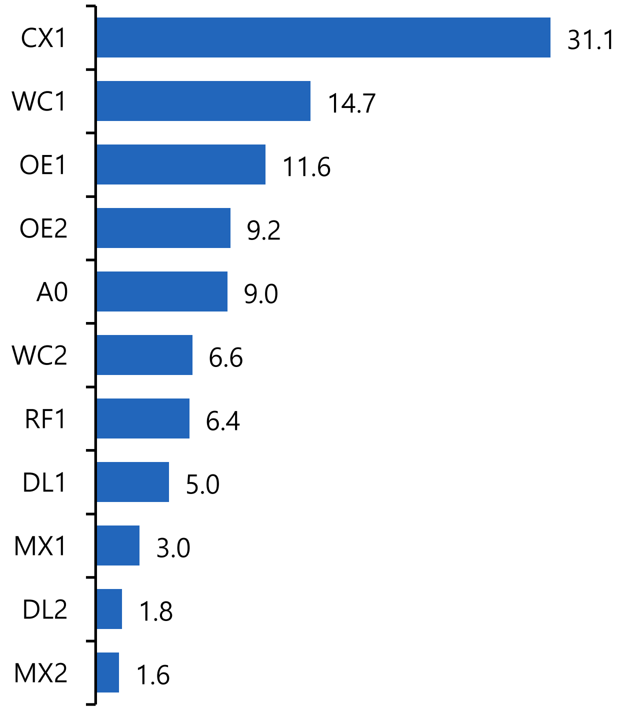

Stage 5 C3(Actor) 행동 분포(%)

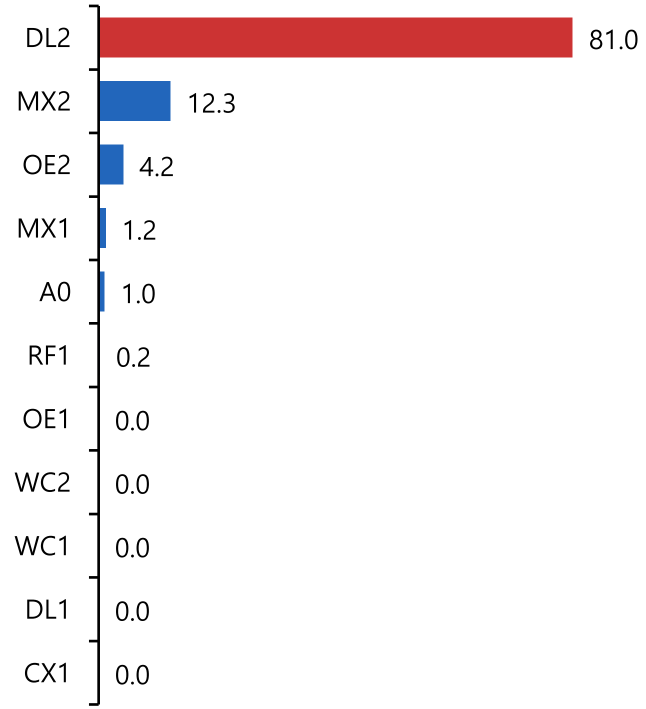

Stage 6 평가 결과 - Oracle α Δnoop

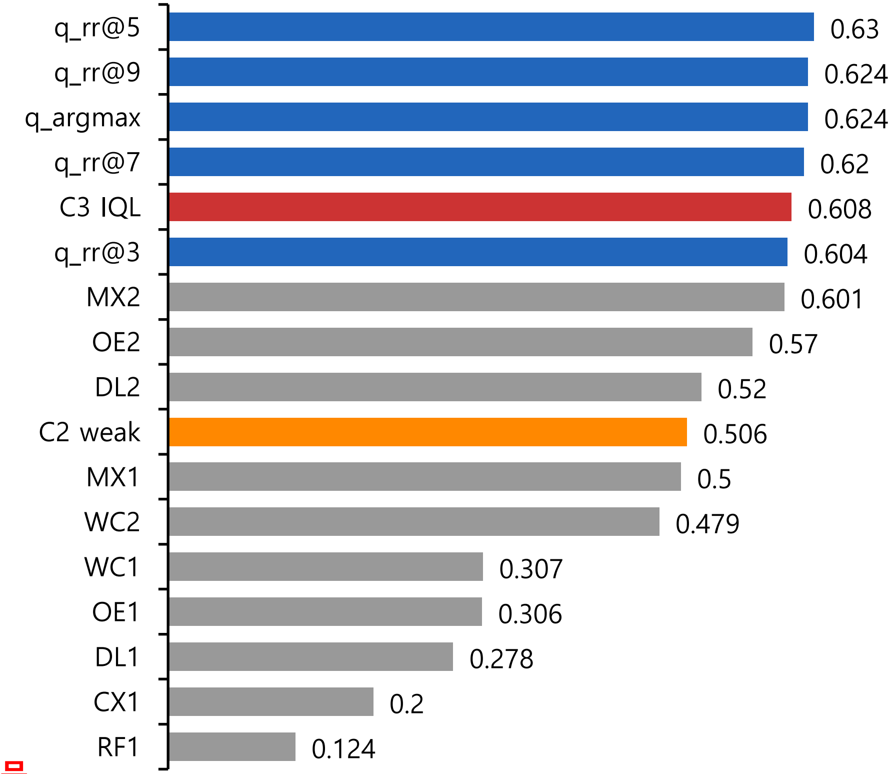

※ Oracle을 재개발하는 과정에서(R136 제외) 데이터셋이 변경되며 2024년 Eval firm 모수 변경(421 → 575)
R136(매입채무/유동부채) 제외사유 : 매입채무가 증가할수록(지급을 늦게할수록) 신용등급이 좋아지게 되기 때문

본 실험 – 28) M 0.30 F 0 L 0.90 Gamma 0.6 Tau 0.9 Beta 30 Distill 3

Hyperparameter

Stage	항목	값
2	Reward	**ρ=0 M=0.3 F=0 L=0.9**
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	**0.6 / 0.9 / 30**
5	Distill / Critic	**λ=3 / cross_attention**
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

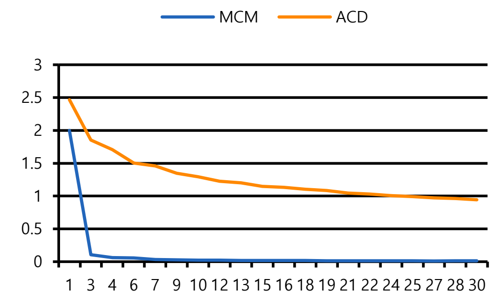

Stage 4 Loss (80ep)

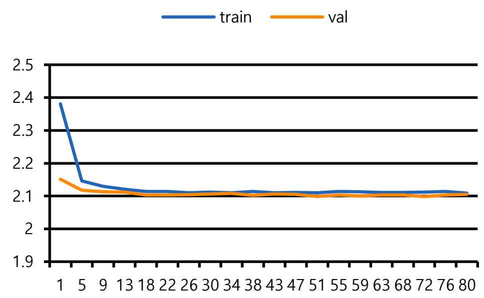

Stage 5 Loss (80ep)

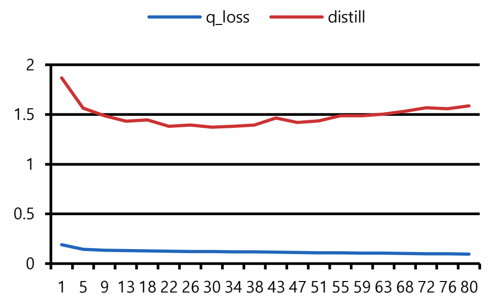

Stage 4 BC 행동 분포(%)

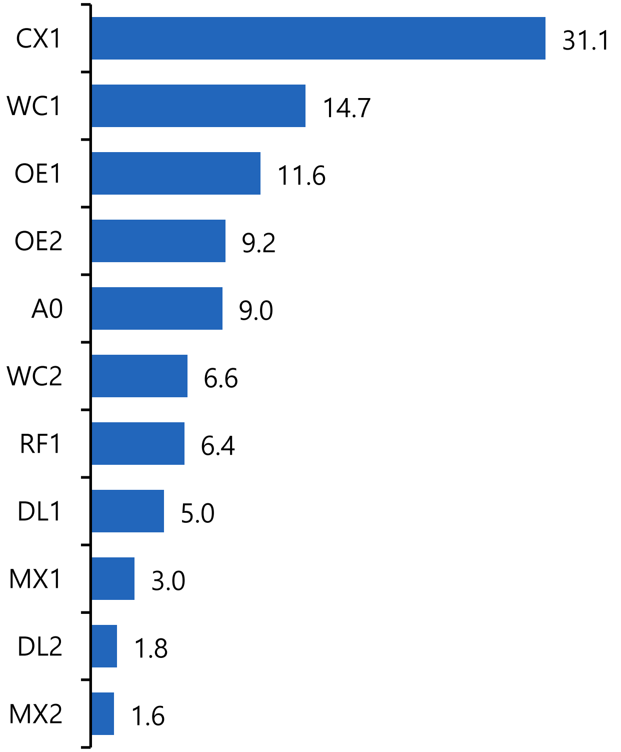

Stage 5 C3(Actor) 행동 분포(%)

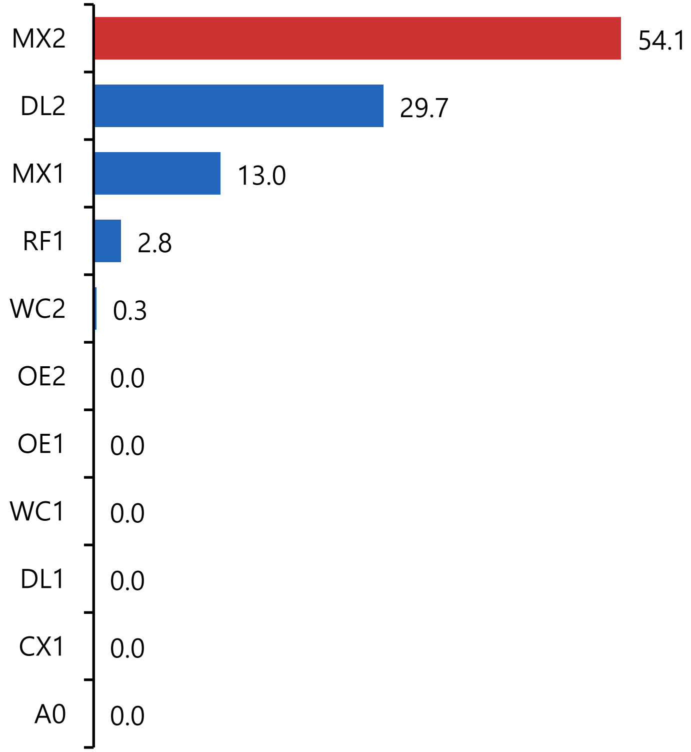

Stage 6 평가 결과 - Oracle α Δnoop

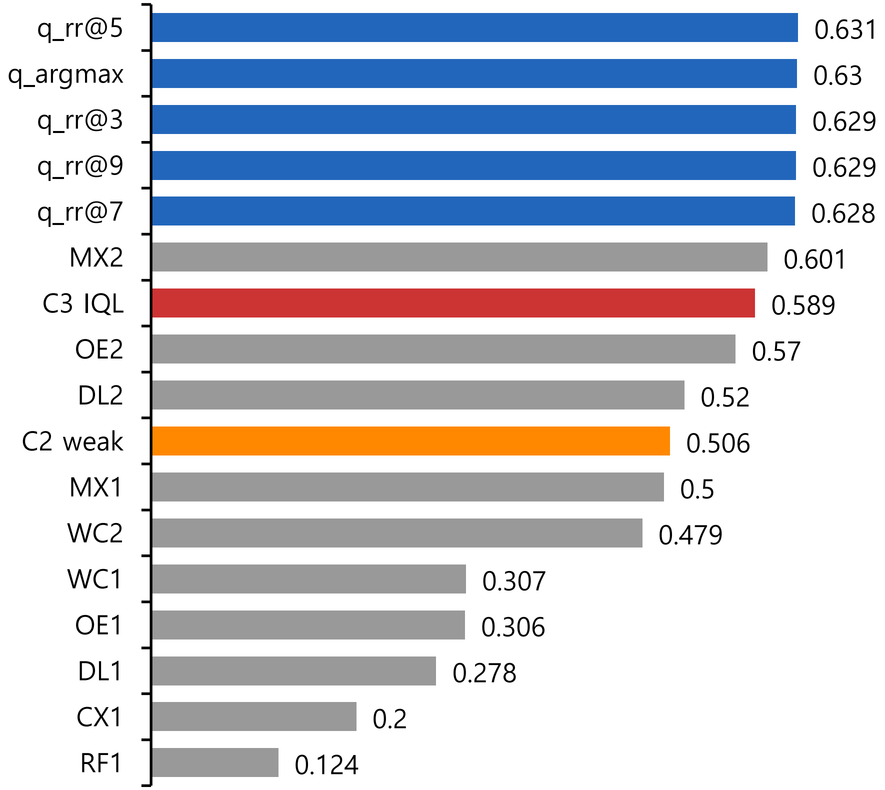

본 실험 – 29) M 0.15 F 0.25 L 0.60 Gamma 0.80 Beta 10

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.15 F=0.25 L=0.6
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.8 / 0.9 / 10
5	Distill / Critic	λ=3 / cross_attention
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

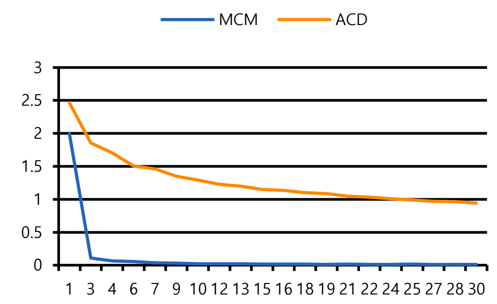

Stage 4 Loss (80ep)

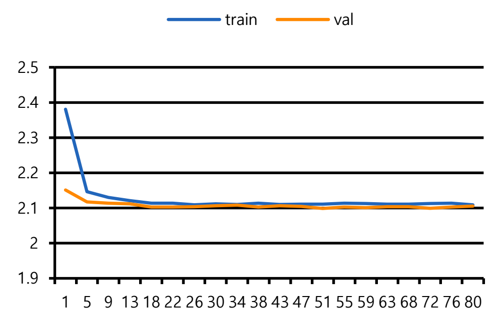

Stage 5 Loss (80ep)

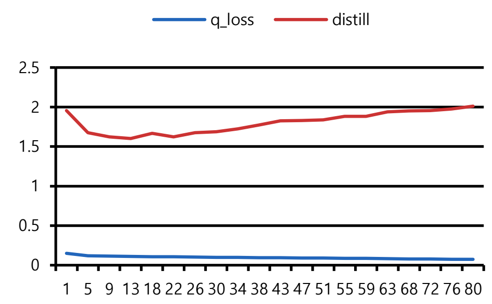

Stage 4 BC 행동 분포(%)

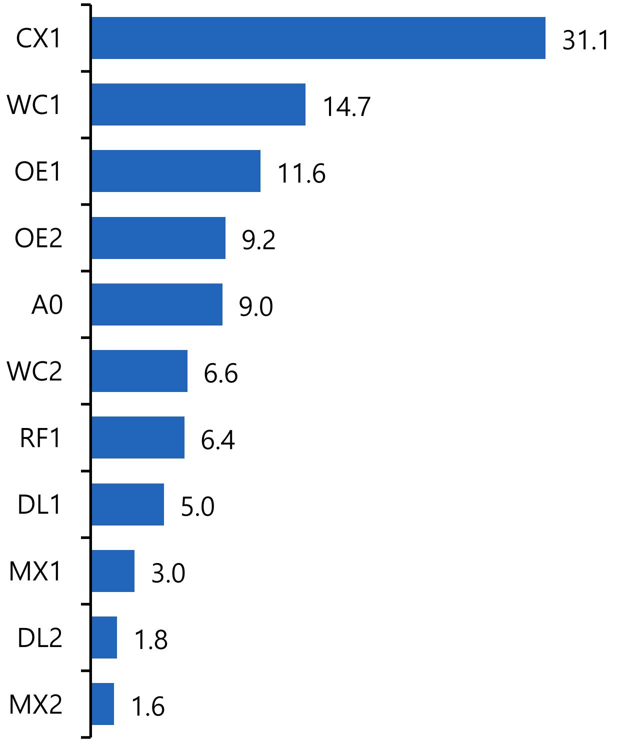

Stage 5 C3(Actor) 행동 분포(%)

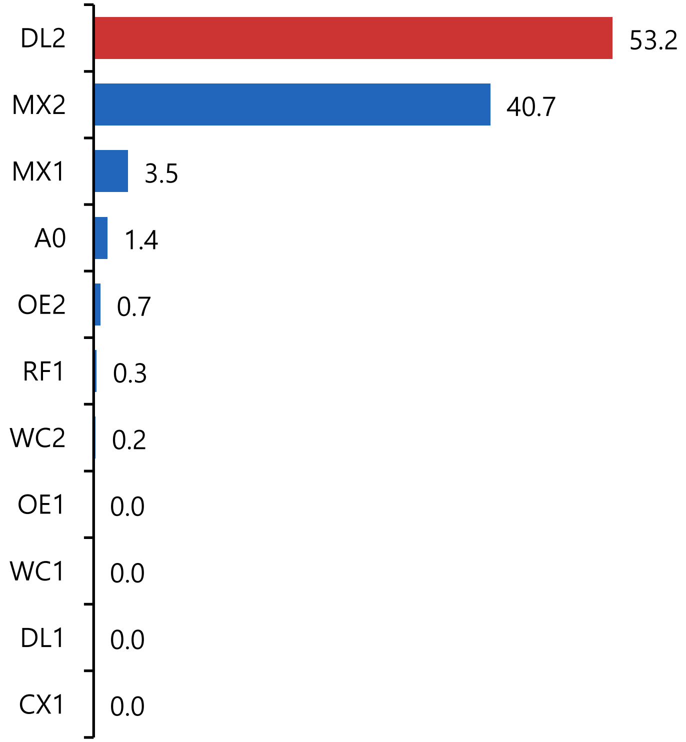

Stage 6 평가 결과 - Oracle α Δnoop

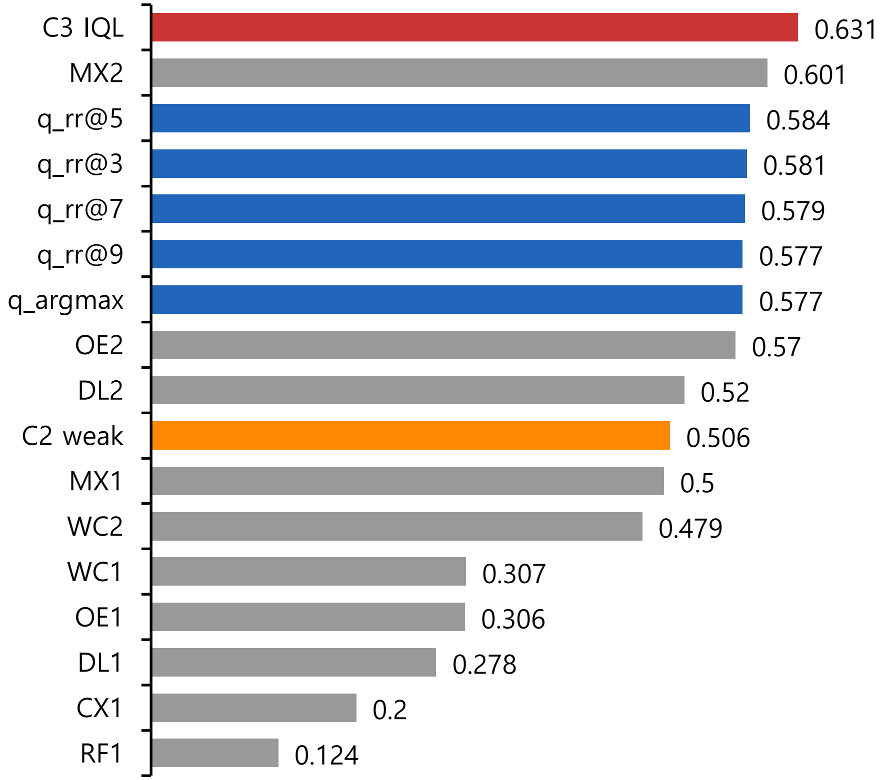

본 실험 – 30) M 0.10 F 0.35 L 0.78 Gamma 0.6 Beta 30

Hyperparameter

Stage	항목	값
2	Reward	**ρ=0 M=0.1 F=0.35 L=0.78**
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	**0.6 / 0.9 / 30**
5	Distill / Critic	λ=3 / cross_attention
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

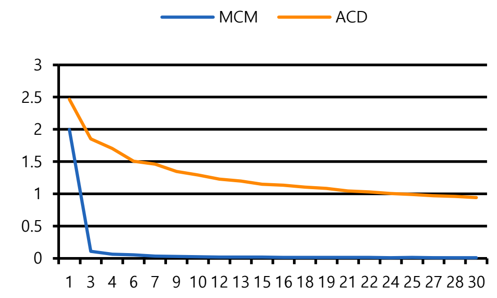

Stage 4 Loss (80ep)

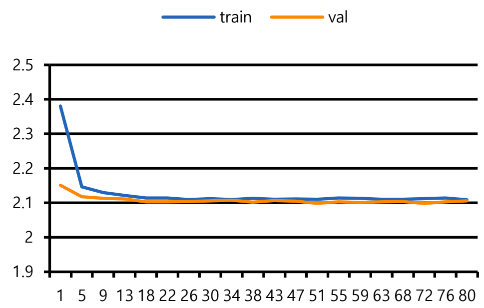

Stage 5 Loss (80ep)

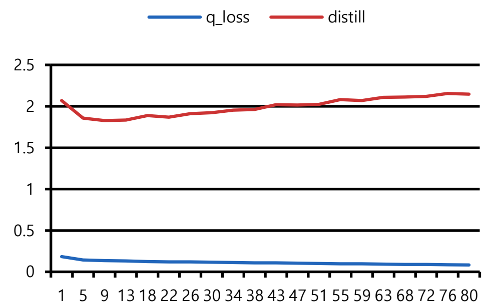

Stage 4 BC 행동 분포(%)

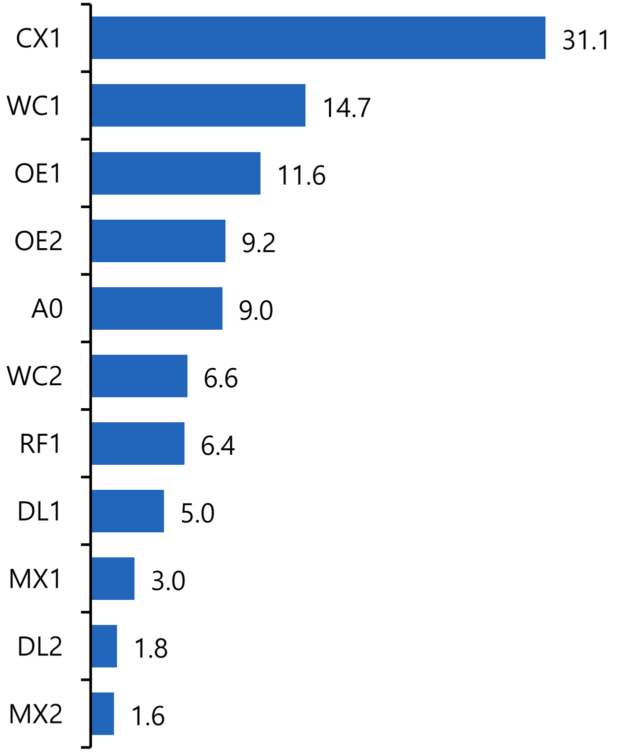

Stage 5 C3(Actor) 행동 분포(%)

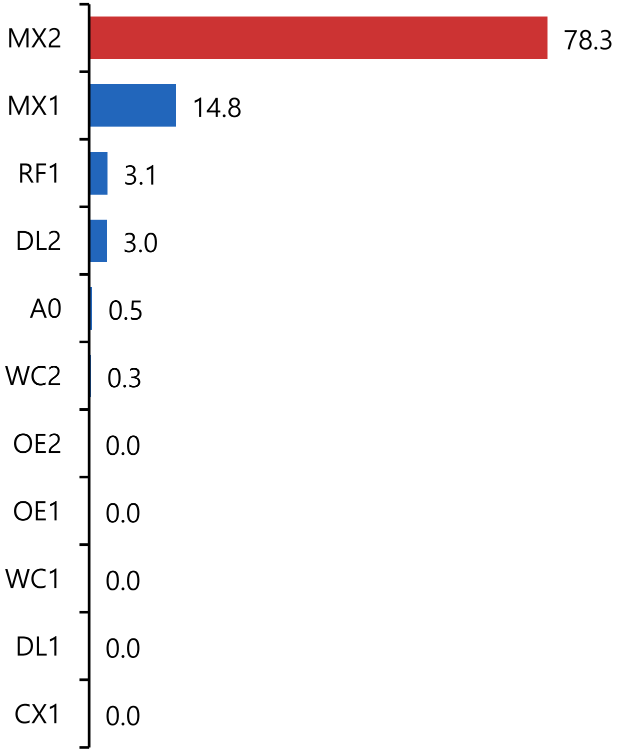

Stage 6 평가 결과 - Oracle α Δnoop

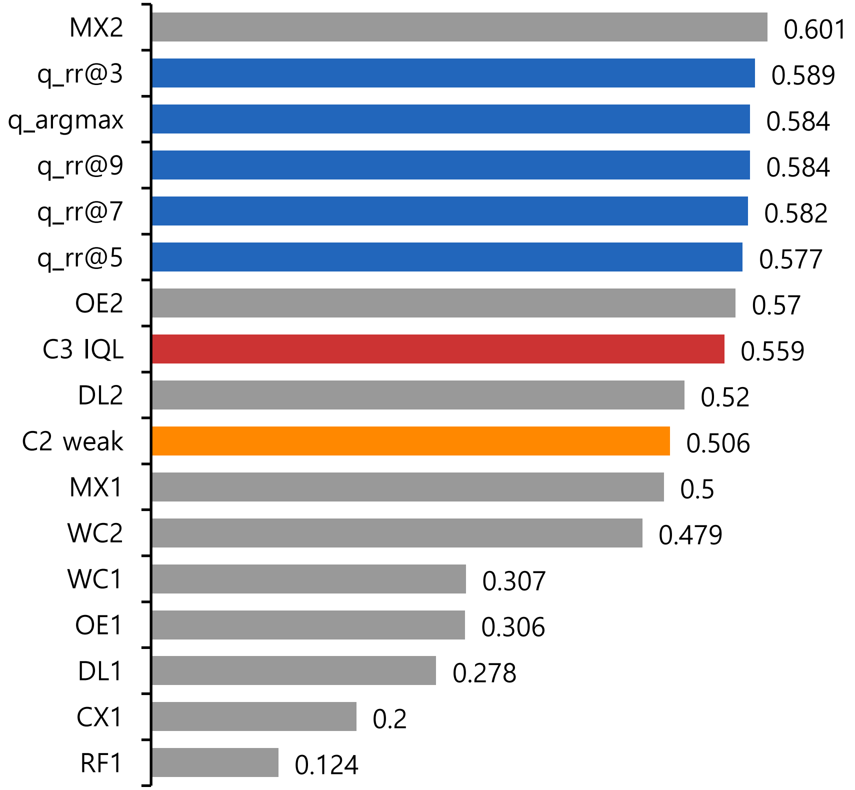

본 실험 – 31) M 0.10 F 0.35 L 0.78 Gamma 0.6 Beta 30 Selection Pareto

Hyperparameter

Stage	항목	값
2	Reward	ρ=- M=0.1 F=0.35 L=0.78
2·4	Mode	S2:reuse / S4:reuse
3	Encoder	reuse (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.6 / 0.9 / 30
5	Distill / Critic / selec	λ=3 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

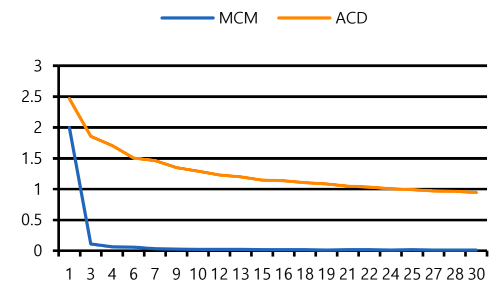

Stage 4 Loss (80ep)

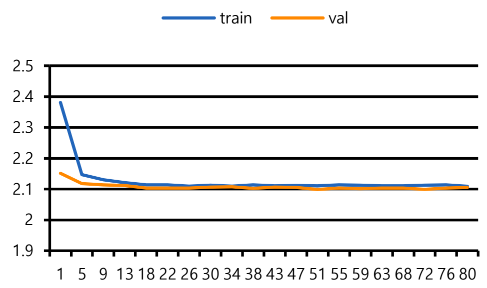

Stage 5 Loss (80ep)

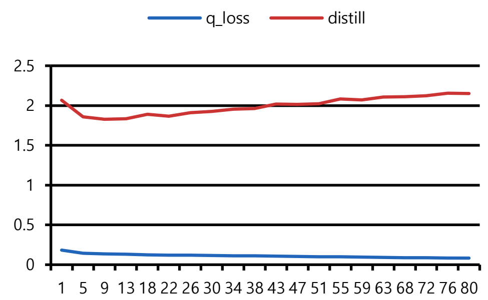

Stage 4 BC 행동 분포(%)

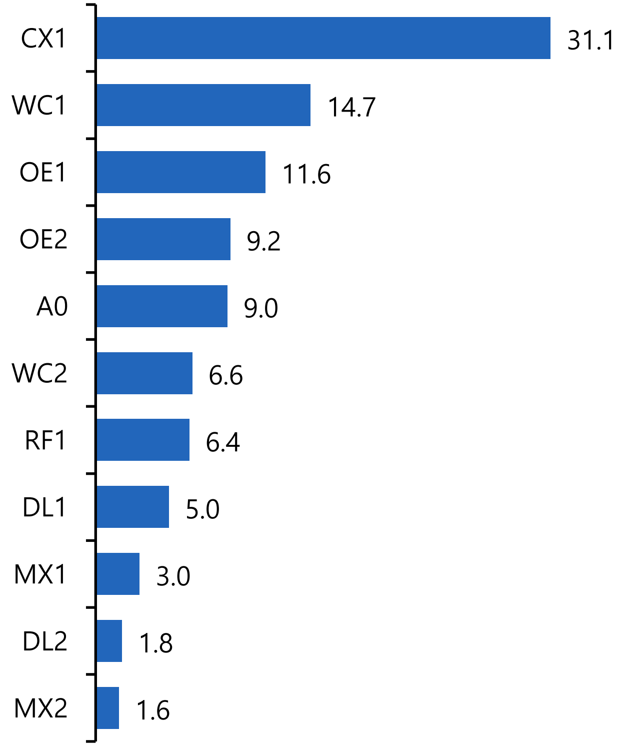

Stage 5 C3(Actor) 행동 분포(%)

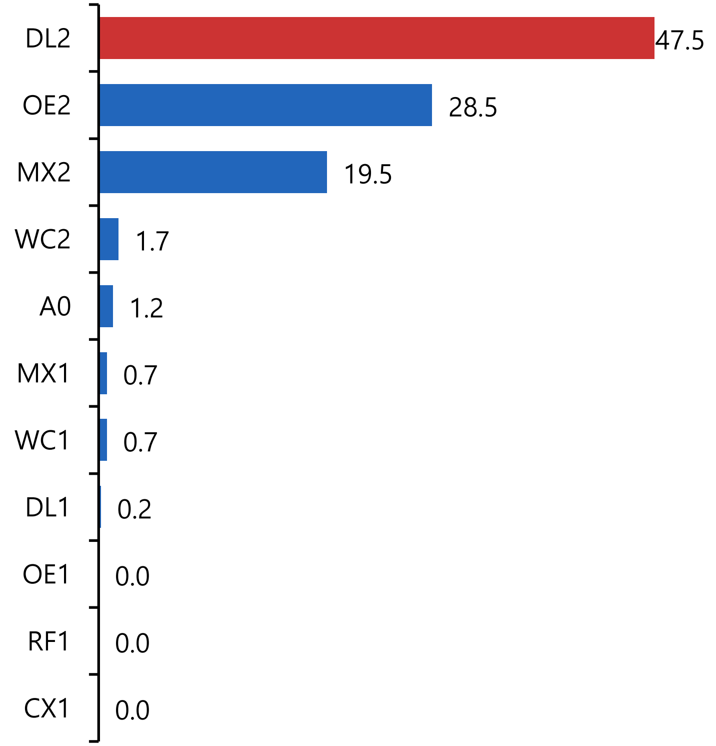

Stage 6 평가 결과 - Oracle α Δnoop

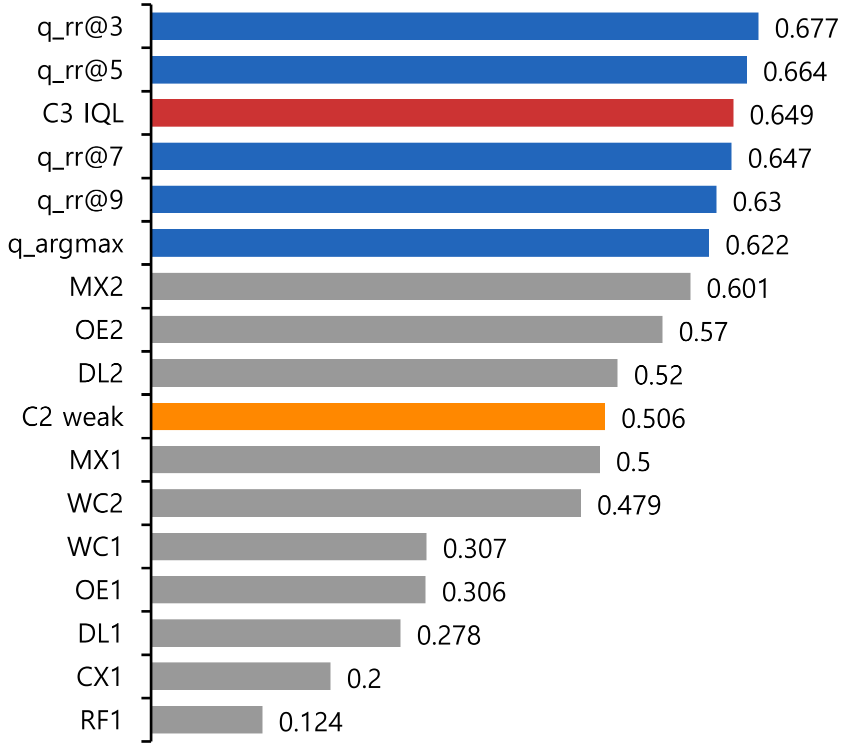

본 실험 – 32) M 0.30 F 0.30 L 0.30 Tau 0.80 Beta 12 Distill 1.5

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.3 F=0.3 L=0.3
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	train (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.6 / 0.8 / 12
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

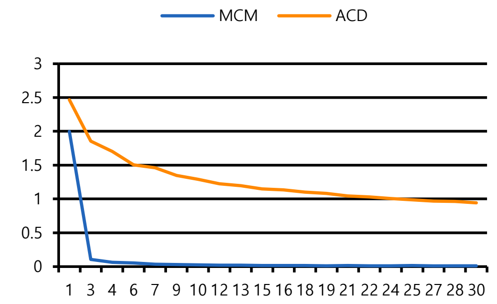

Stage 4 Loss (80ep)

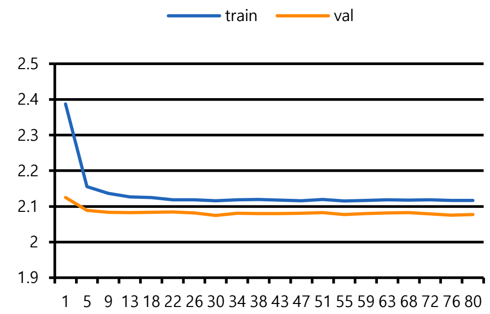

Stage 5 Loss (80ep)

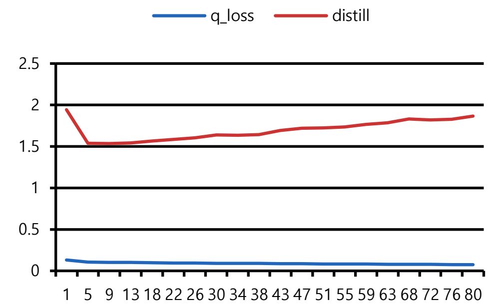

Stage 4 BC 행동 분포(%)

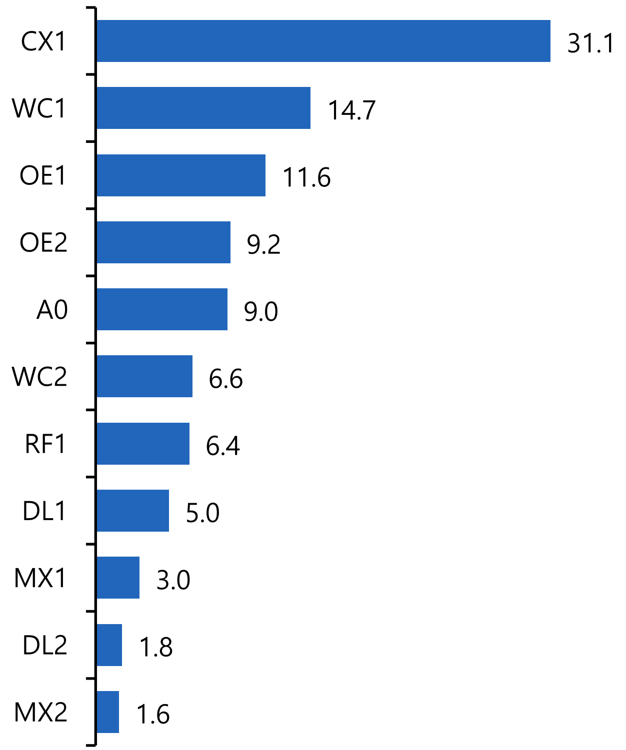

Stage 5 C3(Actor) 행동 분포(%)

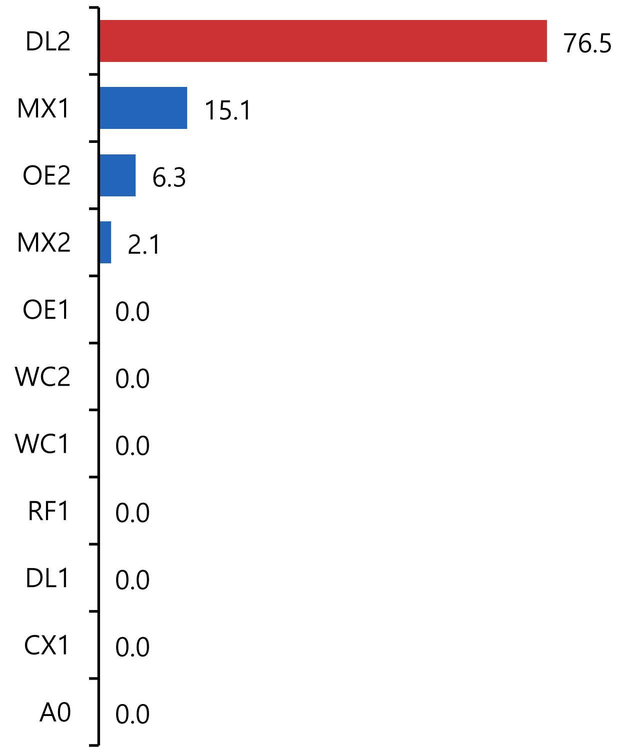

Stage 6 평가 결과 - Oracle α Δnoop

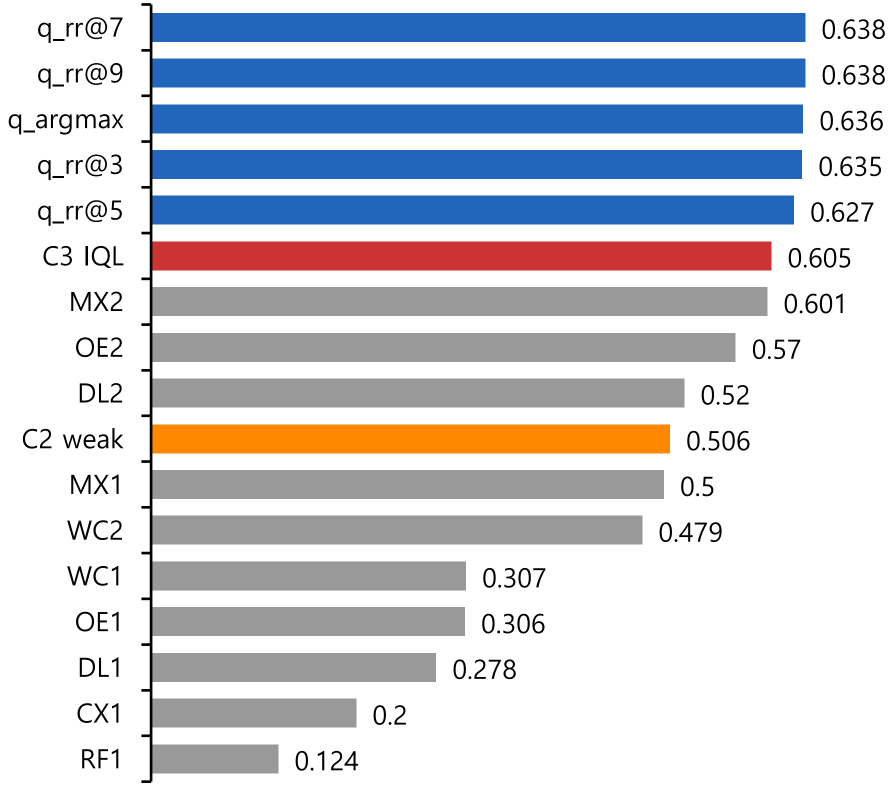

본 실험 – 33) M 0.10 F 0.45 L 0.45 Tau 0.85 Beta 15

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.1 F=0.45 L=0.45
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.6 / 0.85 / 15
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

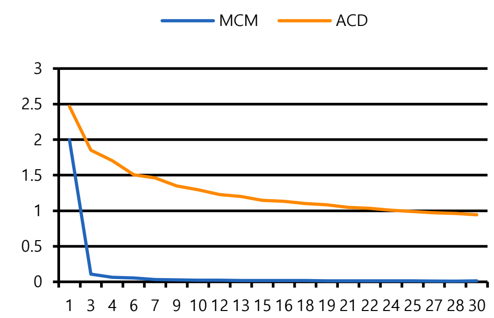

Stage 4 Loss (80ep)

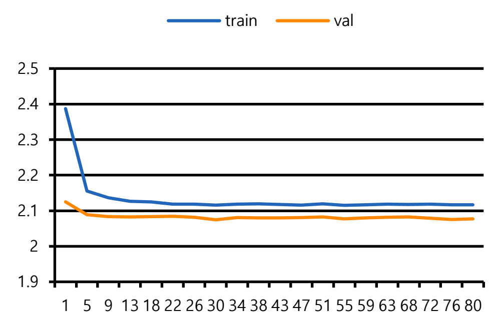

Stage 5 Loss (80ep)

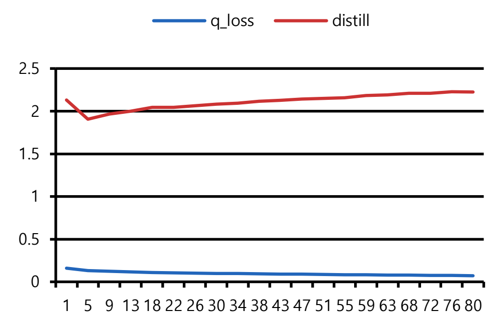

Stage 4 BC 행동 분포(%)

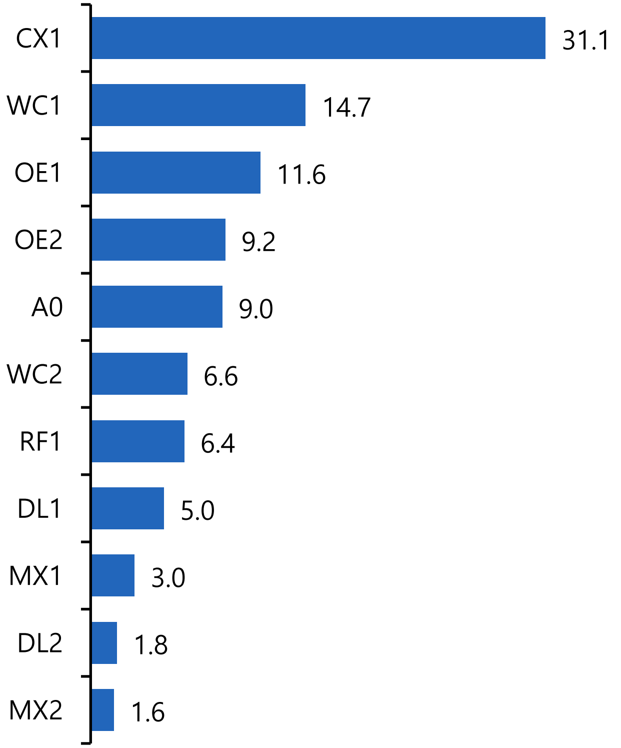

Stage 5 C3(Actor) 행동 분포(%)

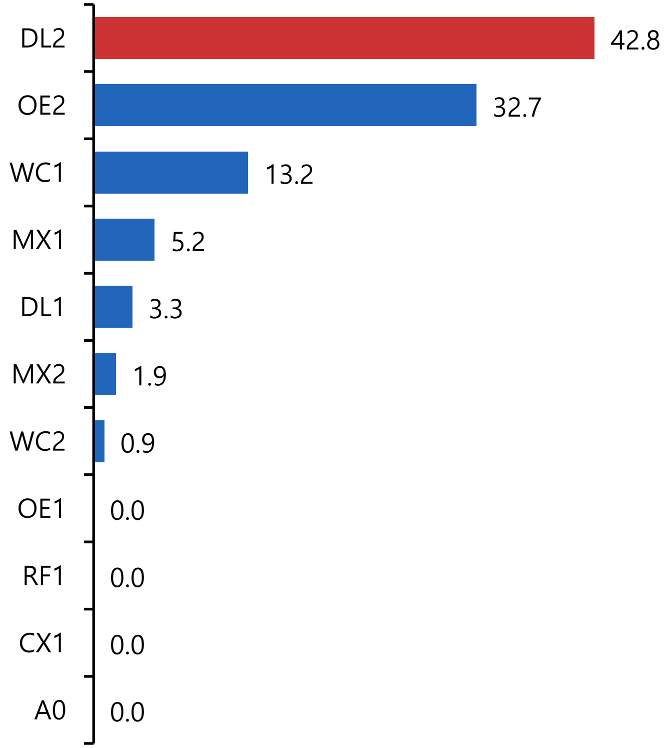

Stage 6 평가 결과 - Oracle α Δnoop

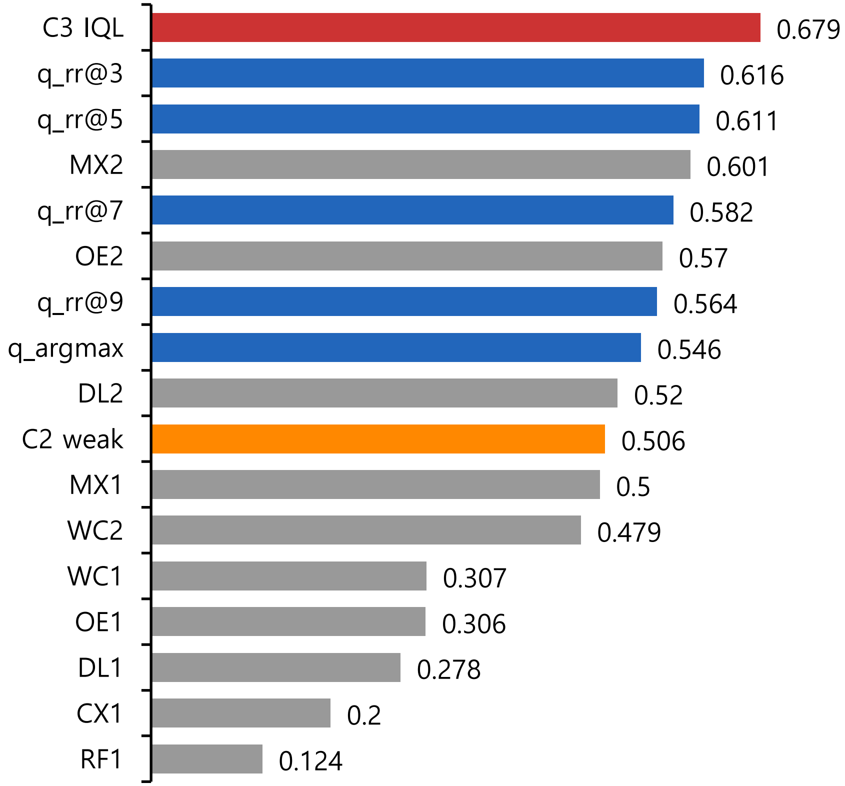

본 실험 – 34) M 0.10 F 0.60 L 0.50 Beta 10

Hyperparameter

Stage	항목	값
2	Reward	**ρ=- M=0.1 F=0.6 L=0.5**
2·4	Mode	S2:reuse / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.6 / 0.85 / **10.0**
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	final_refit (lr=0.0001) / 575

Stage 3 Loss (30ep)

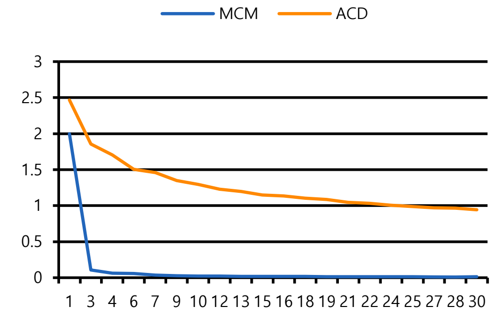

Stage 4 Loss (80ep)

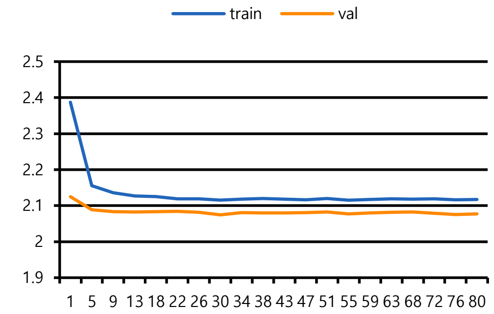

Stage 5 Loss (80ep)

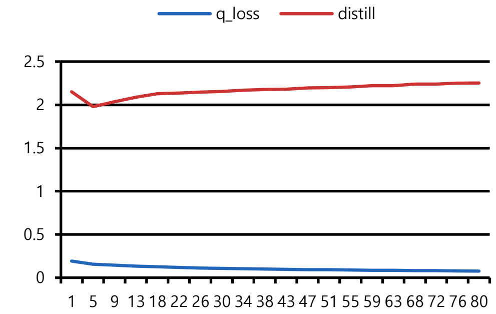

Stage 4 BC 행동 분포(%)

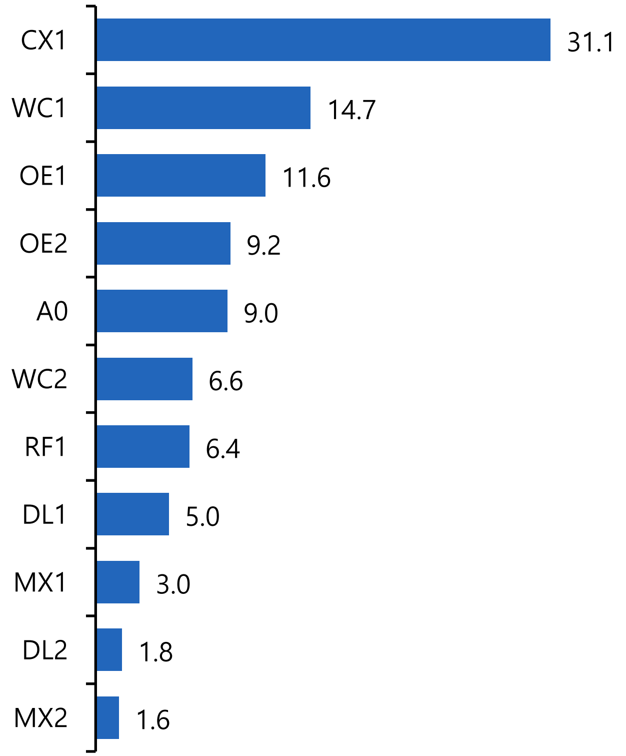

Stage 5 C3(Actor) 행동 분포(%)

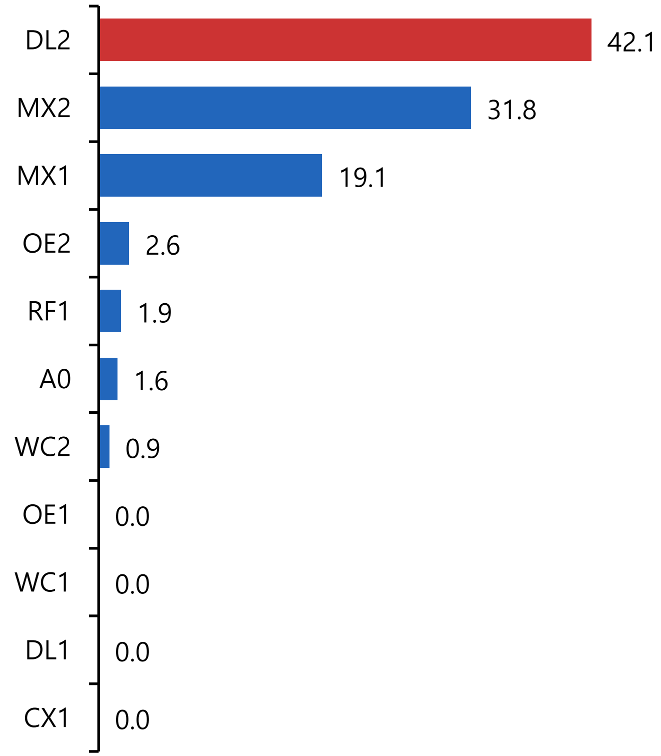

Stage 6 평가 결과 - Oracle α Δnoop

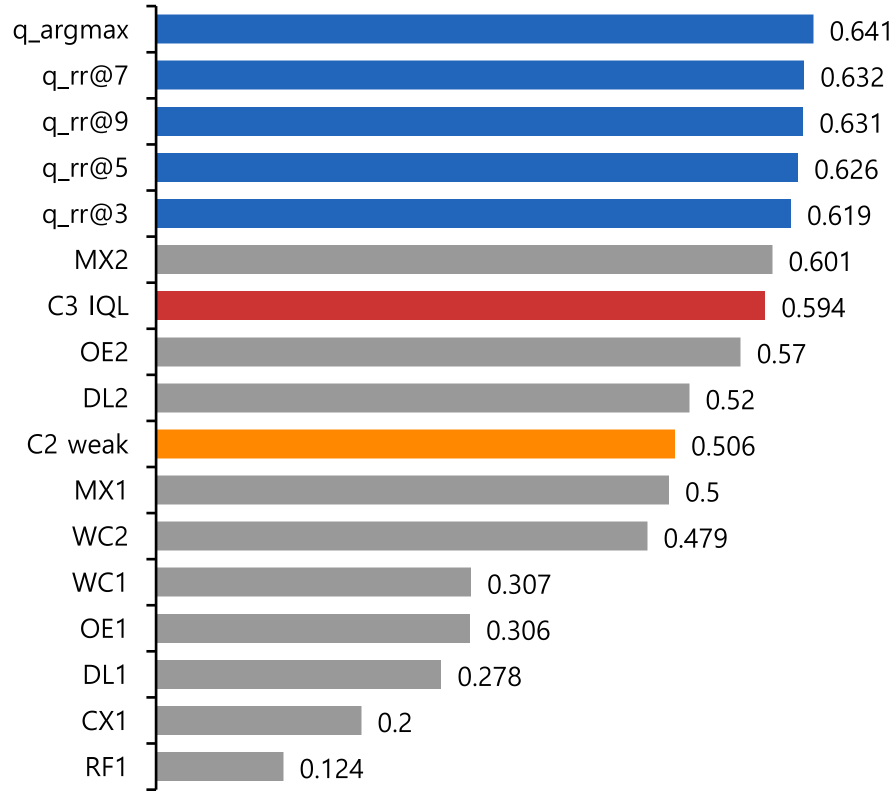

본 실험 – 35) M 0.05 F 0.50 L 0.45 Beta 15

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0.5 L=0.45
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.6 / 0.85 / 15
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

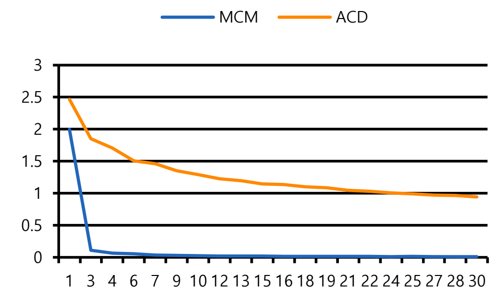

Stage 4 Loss (80ep)

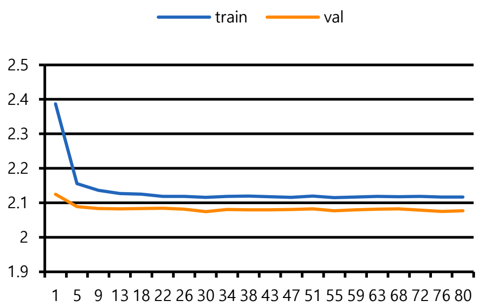

Stage 5 Loss (80ep)

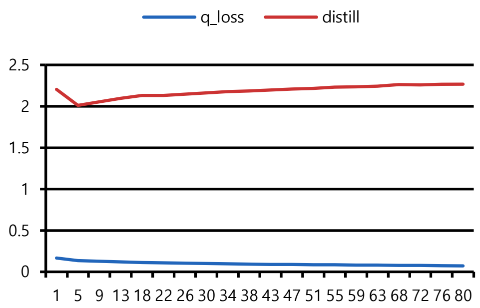

Stage 4 BC 행동 분포(%)

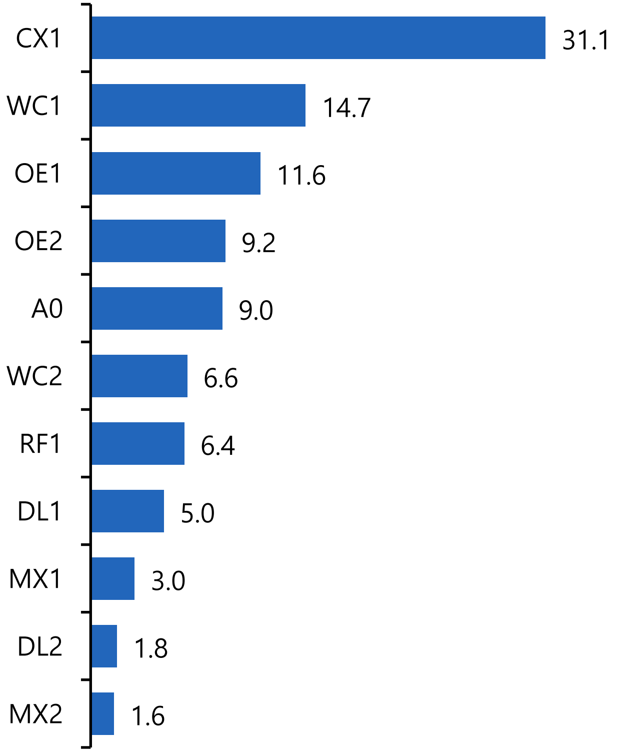

Stage 5 C3(Actor) 행동 분포(%)

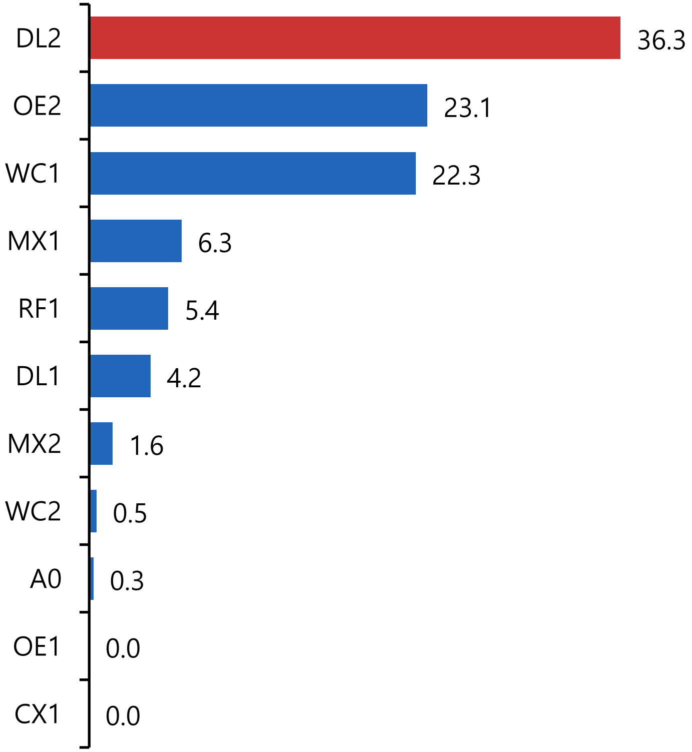

Stage 6 평가 결과 - Oracle α Δnoop

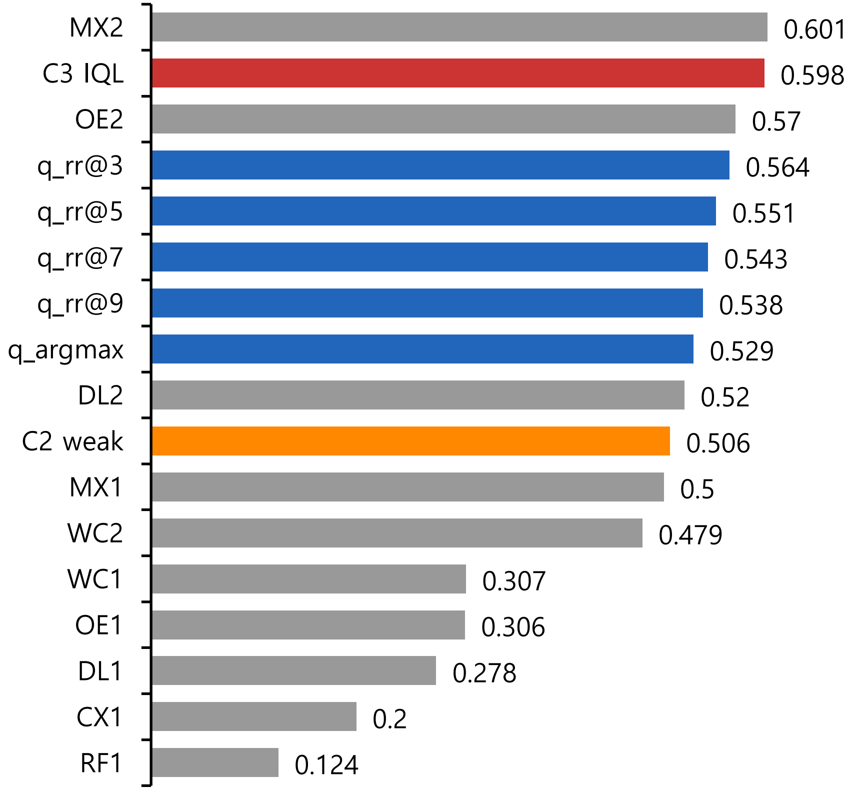

본 실험 – 36) M 0.10 F 0.45 L 0.45 Distill 1

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.1 F=0.45 L=0.45
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	skip (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.6 / 0.85 / 15
5	Distill / Critic / selec	λ=1 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

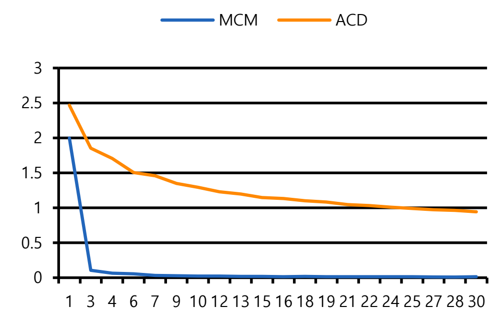

Stage 4 Loss (80ep)

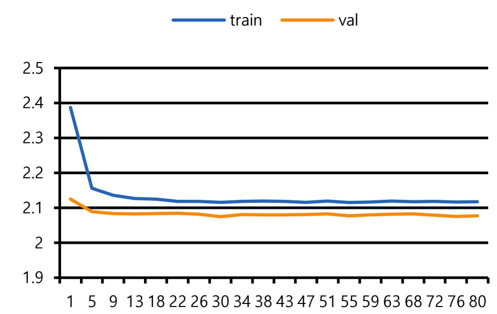

Stage 5 Loss (80ep)

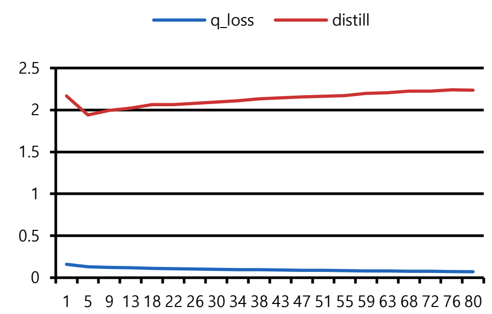

Stage 4 BC 행동 분포(%)

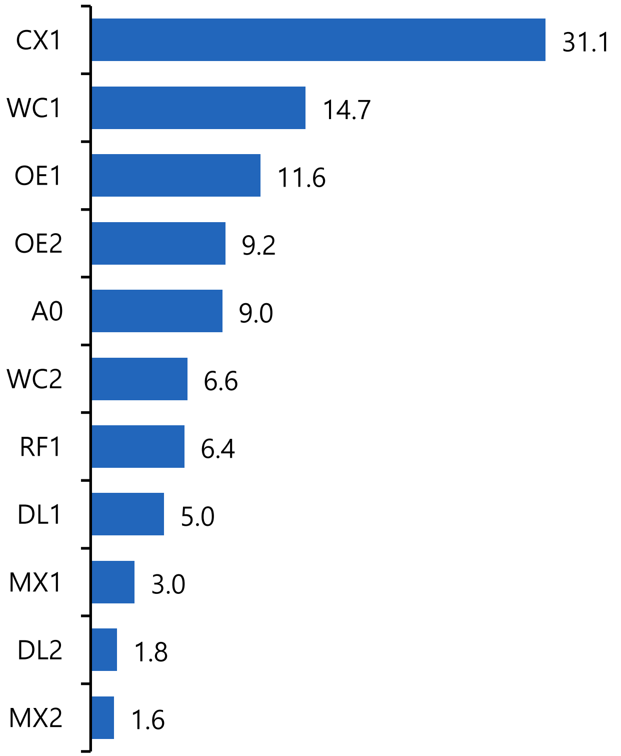

Stage 5 C3(Actor) 행동 분포(%)

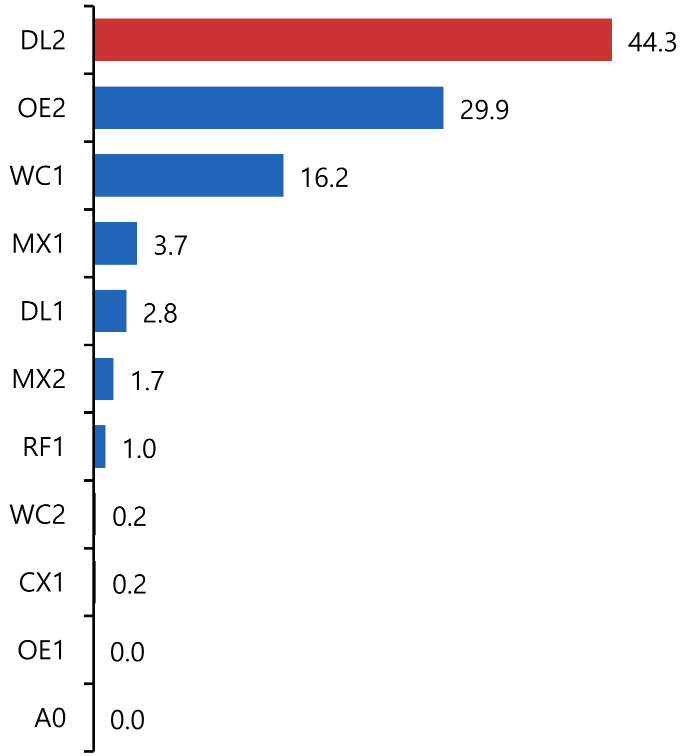

Stage 6 평가 결과 - Oracle α Δnoop

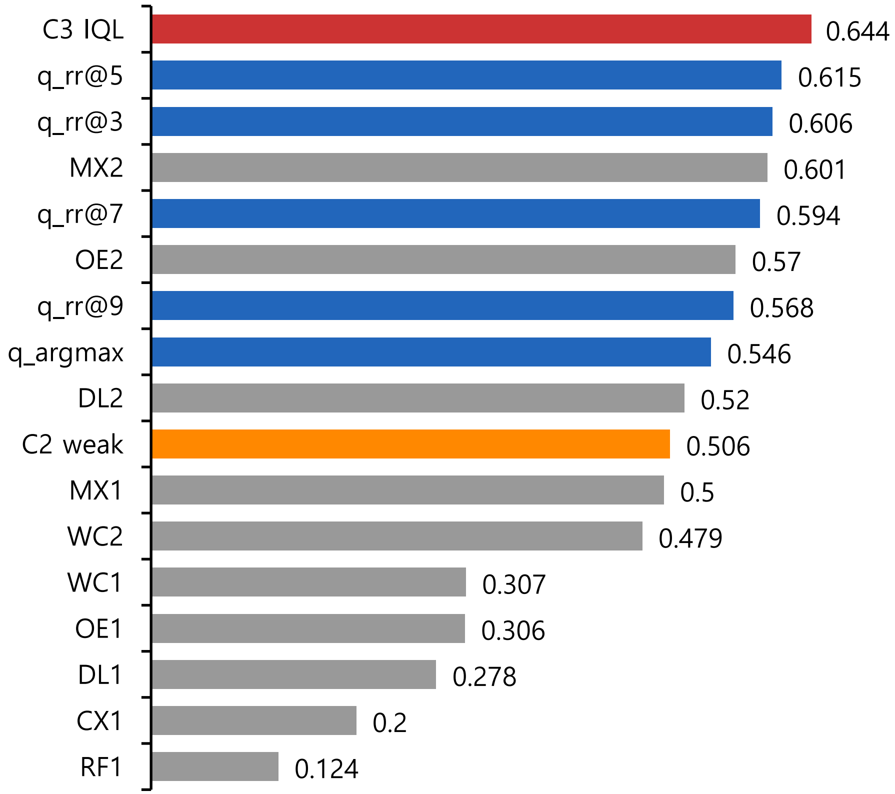

본 실험 – 37) M 0.05 F 0.45 L 0.45 Distill 1.5

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0.45 L=0.45
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	train (30ep)
4	CB / FB	β=0.999 / p=0.5
5	γ/τ/β	0.6 / 0.85 / 15
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

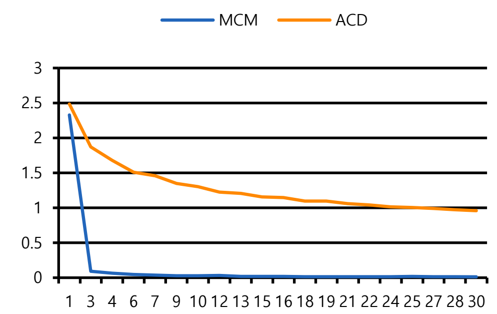

Stage 4 Loss (80ep)

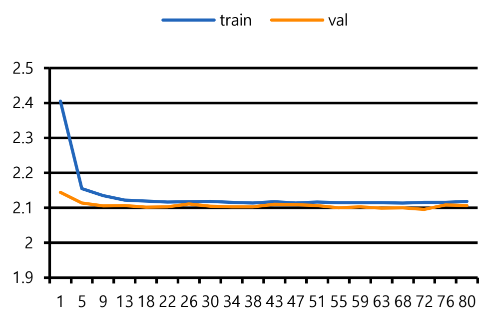

Stage 5 Loss (80ep)

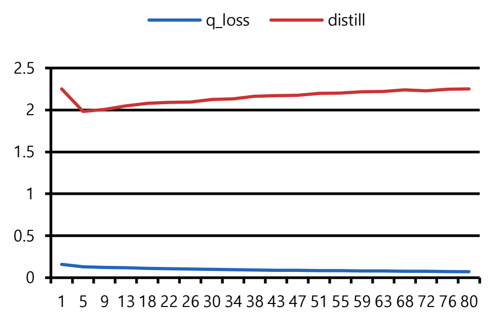

Stage 4 BC 행동 분포(%)

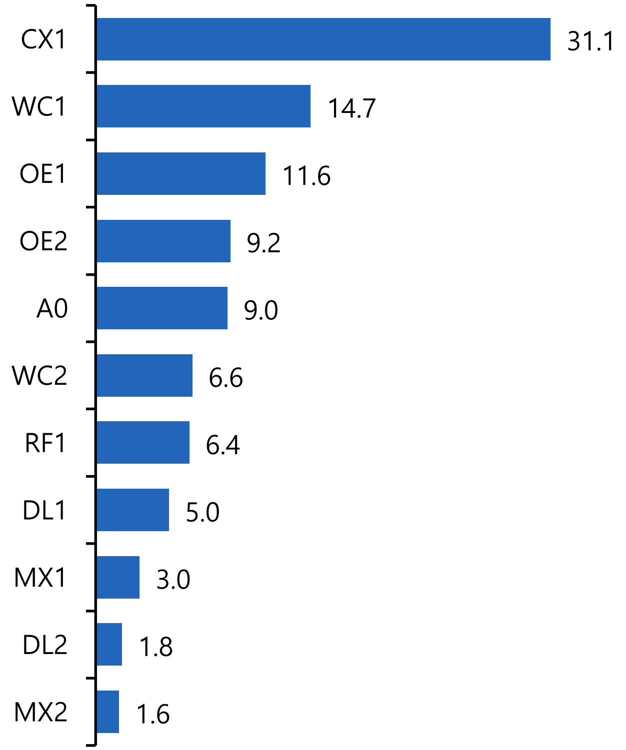

Stage 5 C3(Actor) 행동 분포(%)

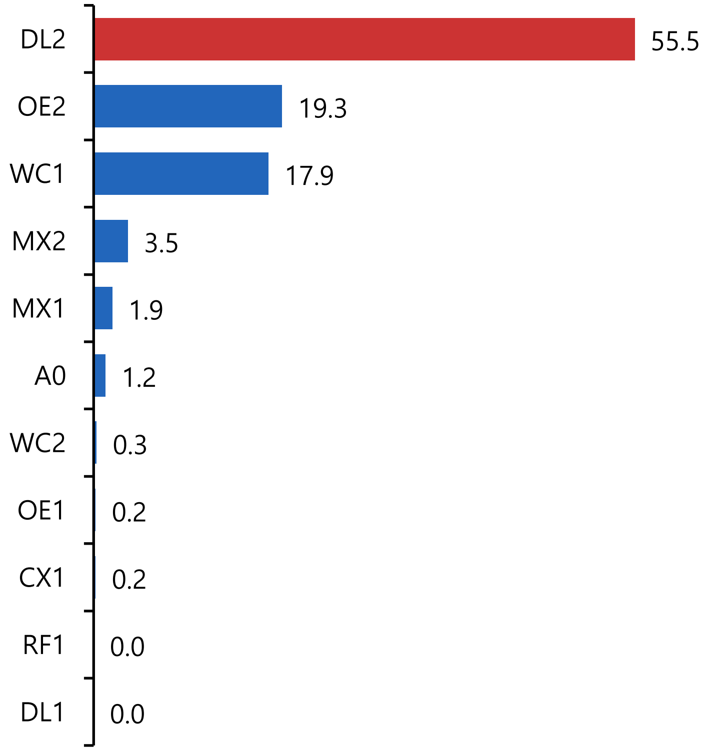

Stage 6 평가 결과 - Oracle α Δnoop

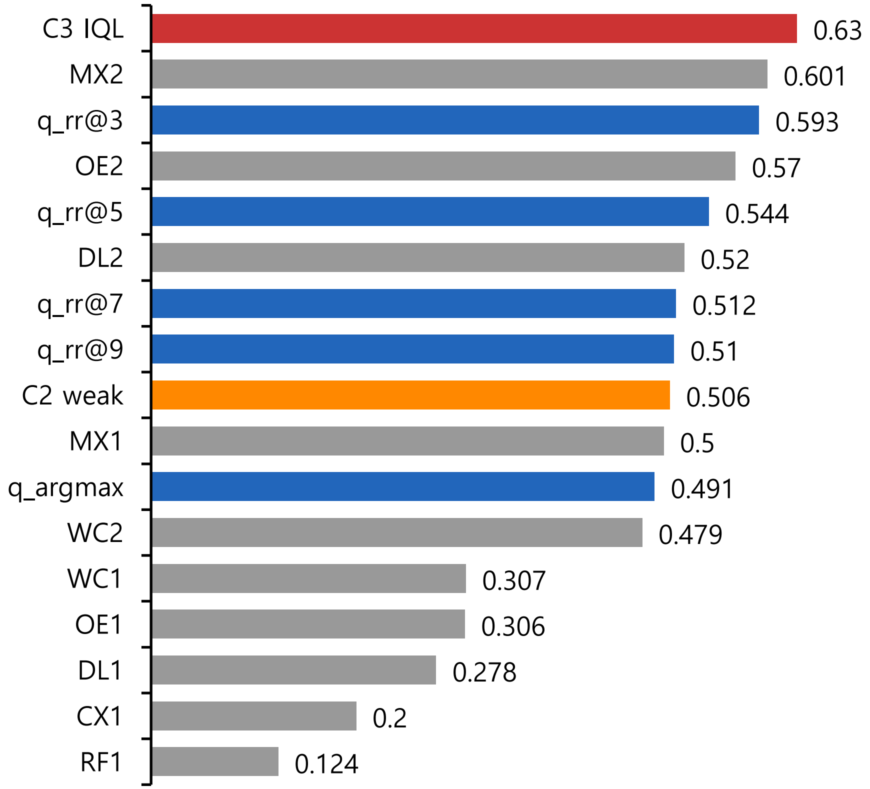

최종 실험 – 38) Stage 3 ~ 5 seed 1

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0.45 L=0.45
2·4	Mode	S2:skip / S4:train
3	Encoder	Batch 512 / 30 epoch / **seed 1**
4	CB / FB	β=0.999 / p=0.5 / **seed 1**
5	γ/τ/β	0.6 / 0.85 / 15 / **seed 1**
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

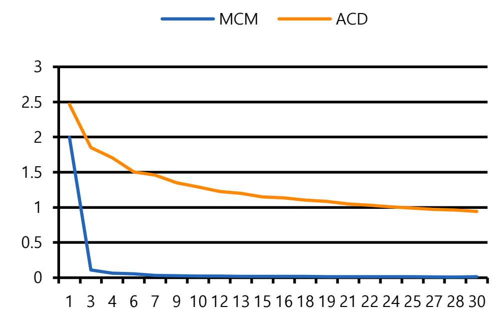

Stage 4 Loss (80ep)

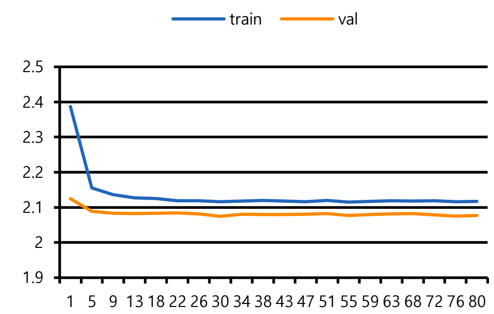

Stage 5 Loss (80ep)

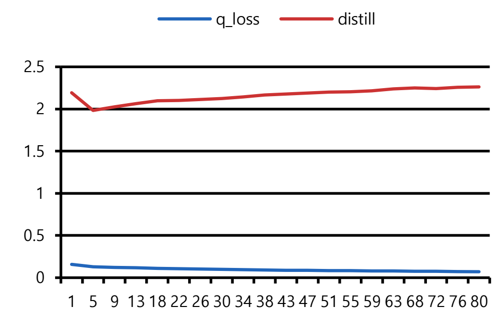

Stage 4 BC 행동 분포(%)

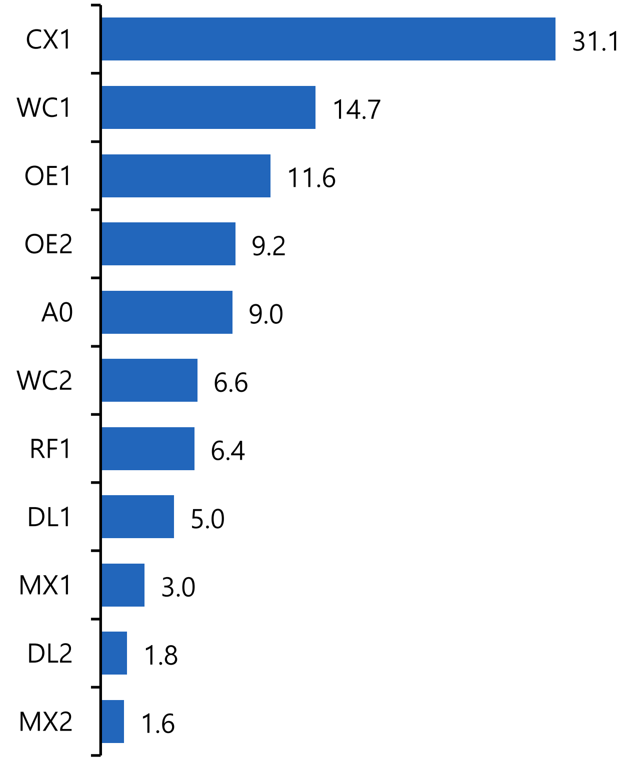

Stage 5 C3(Actor) 행동 분포(%)

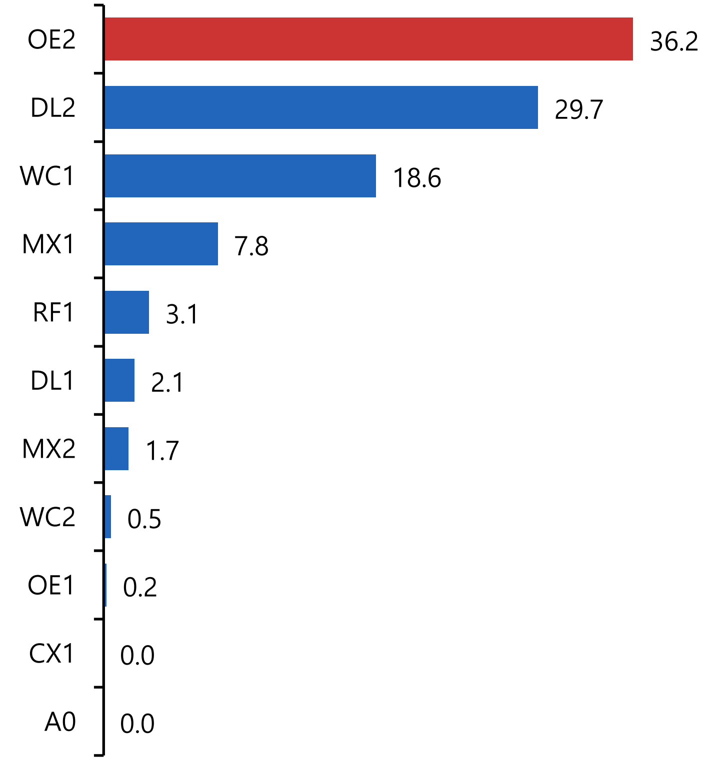

Stage 6 평가 결과 - Oracle α Δnoop

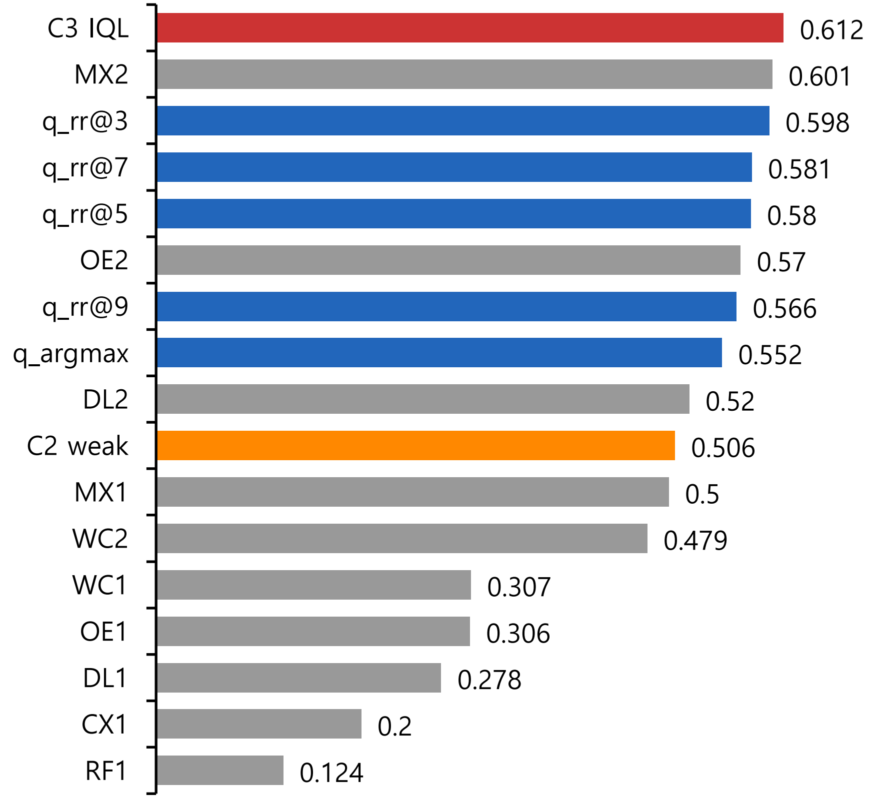

최종 실험 – 39) Stage 3 ~ 5 seed 2

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0.45 L=0.45
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	Batch 512 (30ep) / **seed 2**
4	CB / FB	β=0.999 / p=0.5 / **seed 2**
5	γ/τ/β	0.6 / 0.85 / 15 / **seed 2**
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

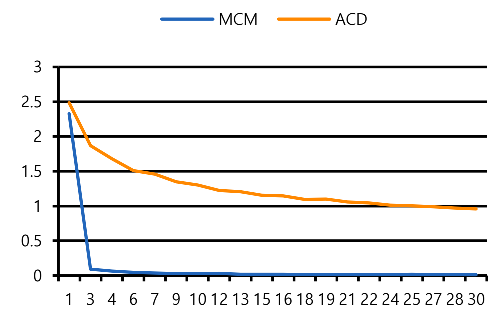

Stage 4 Loss (80ep)

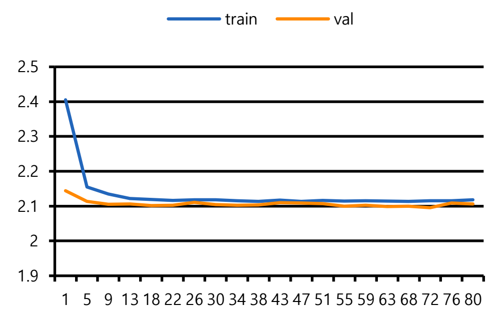

Stage 5 Loss (80ep)

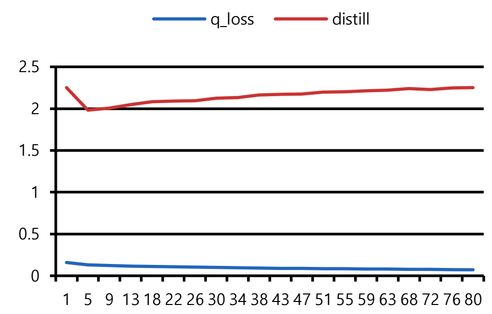

Stage 4 BC 행동 분포(%)

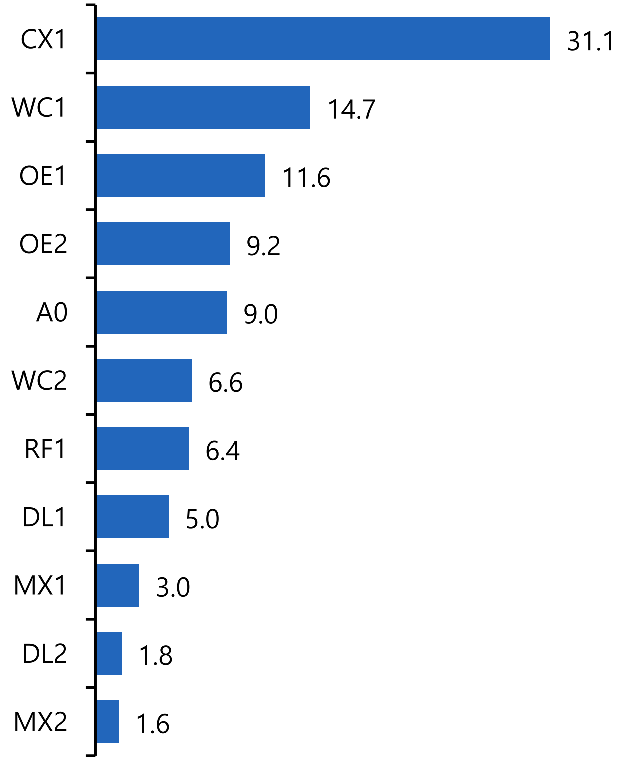

Stage 5 C3(Actor) 행동 분포(%)

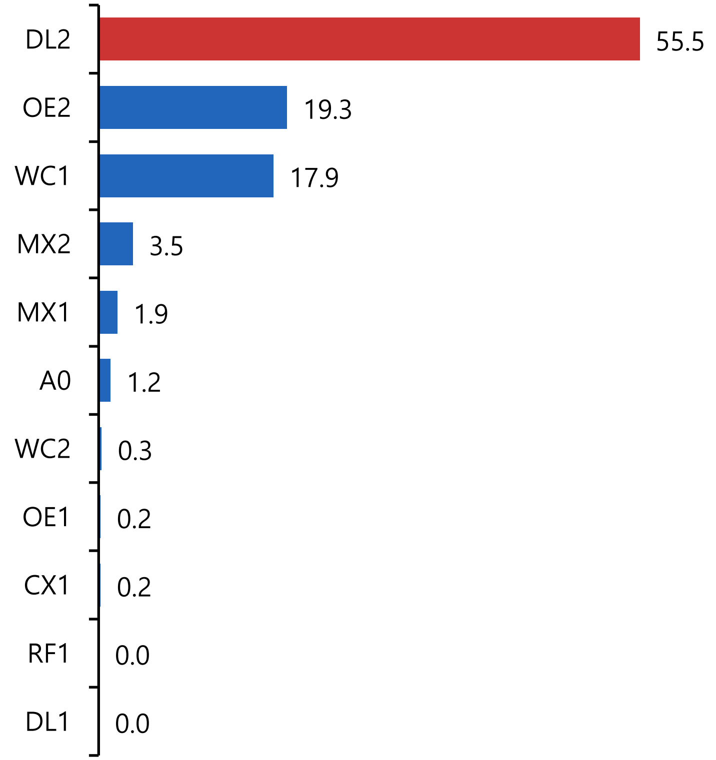

Stage 6 평가 결과 - Oracle α Δnoop

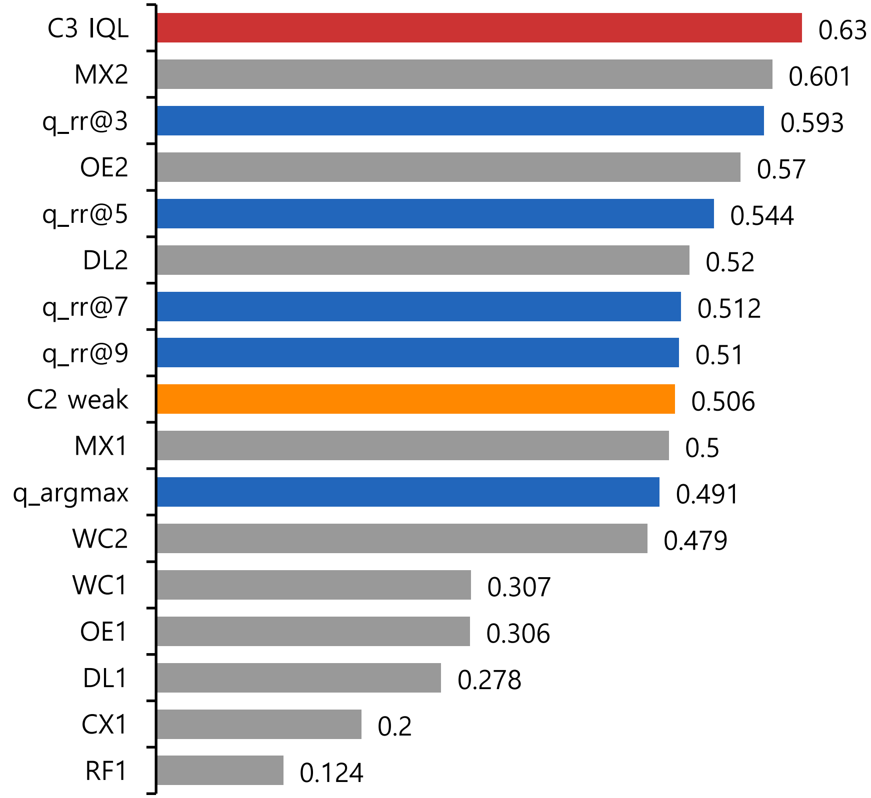

최종 실험 – 40) Stage 3 ~ 5 seed 3

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0.45 L=0.45
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	Batch 512 (30ep) / **seed 3**
4	CB / FB	β=0.999 / p=0.5 / **seed 3**
5	γ/τ/β	0.6 / 0.85 / 15 / **seed 3**
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

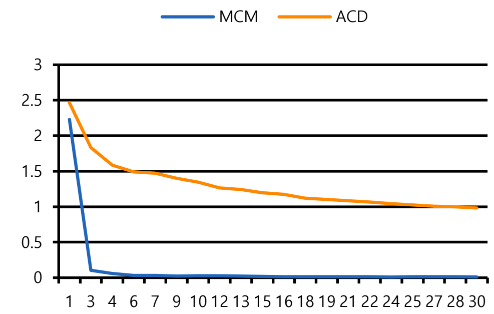

Stage 4 Loss (80ep)

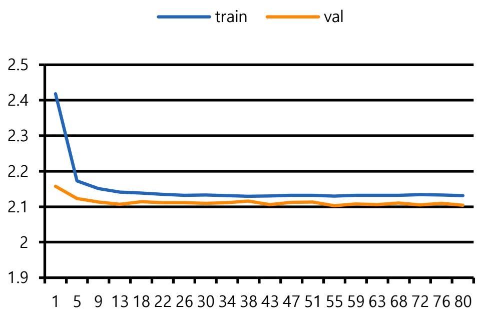

Stage 5 Loss (80ep)

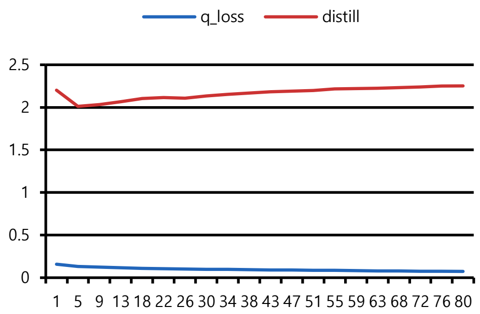

Stage 4 BC 행동 분포(%)

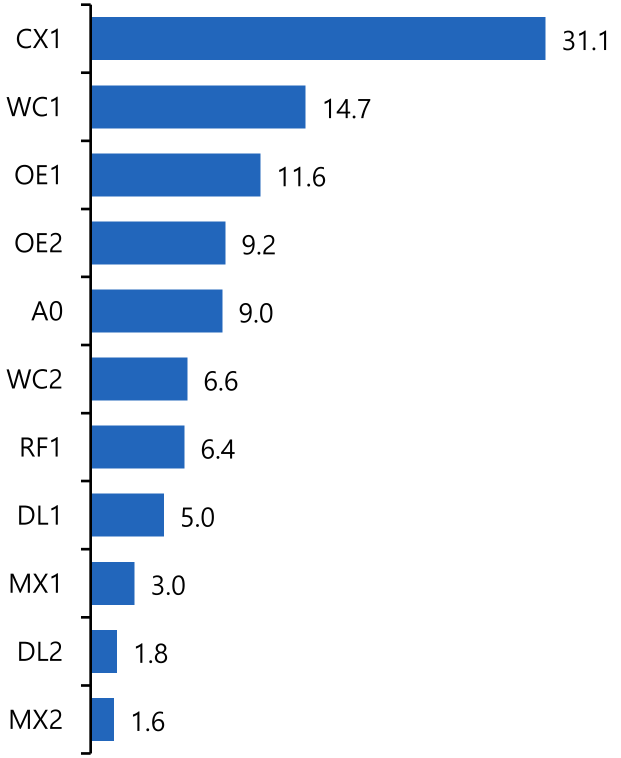

Stage 5 C3(Actor) 행동 분포(%)

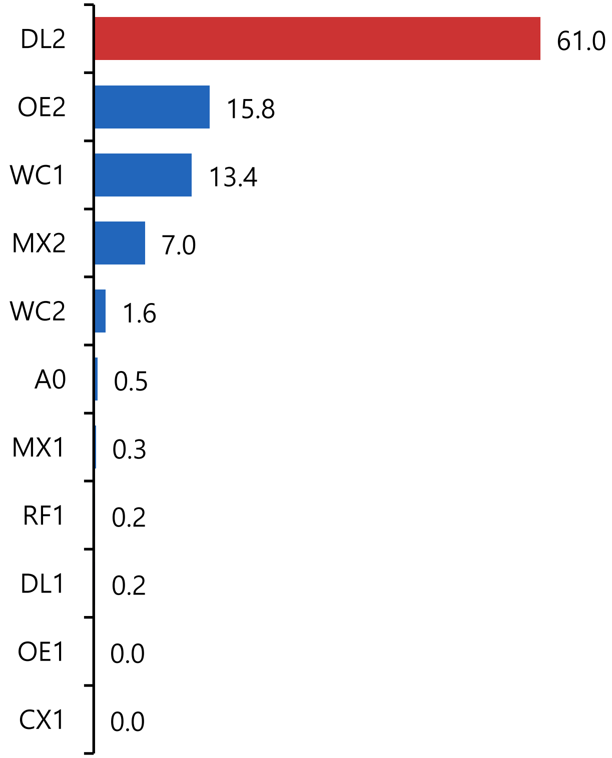

Stage 6 평가 결과 - Oracle α Δnoop

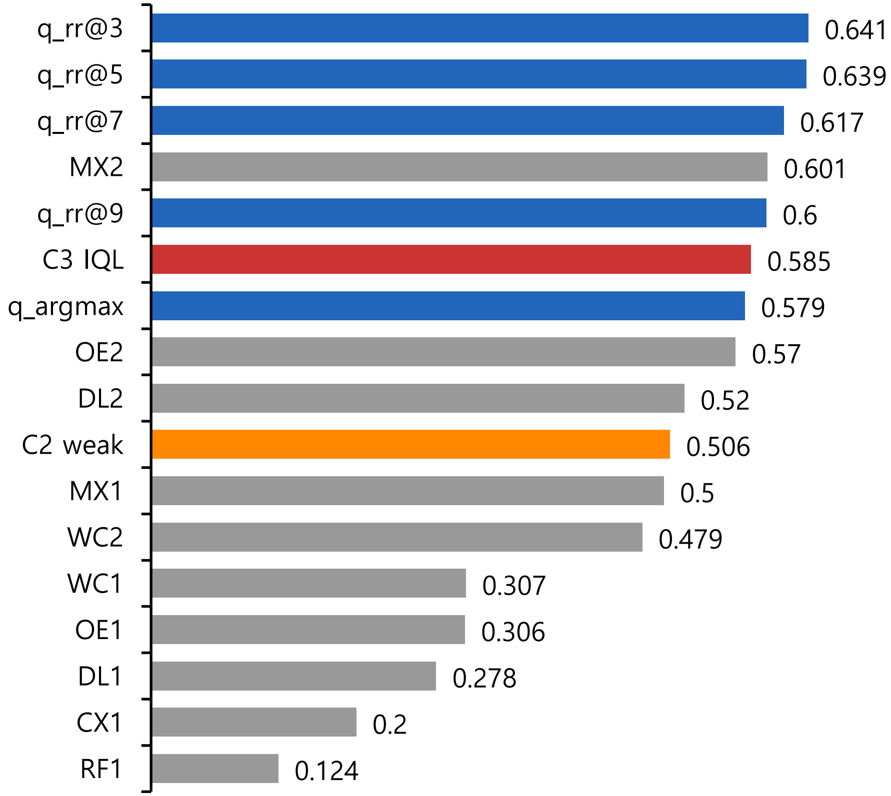

최종 실험 – 41) Stage 3 ~ 5 seed 4

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0.45 L=0.45
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	Batch 512 (30ep) / **seed 4**
4	CB / FB	β=0.999 / p=0.5 / **seed 4**
5	γ/τ/β	0.6 / 0.85 / 15 / **seed 4**
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

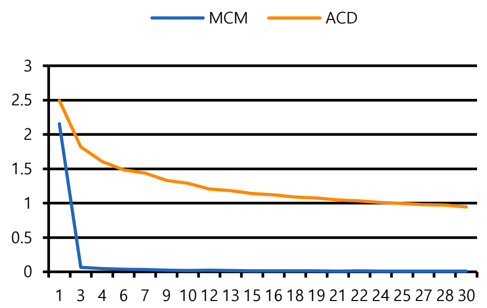

Stage 4 Loss (80ep)

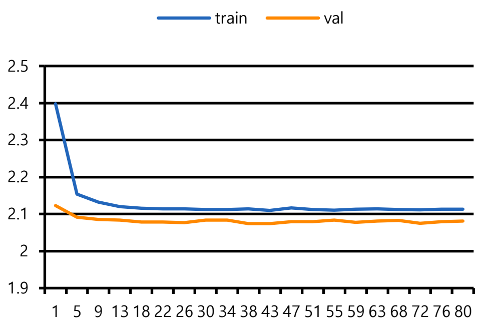

Stage 5 Loss (80ep)

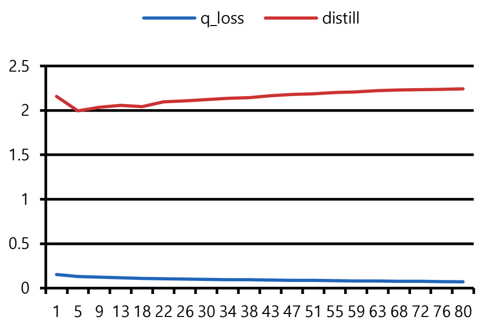

Stage 4 BC 행동 분포(%)

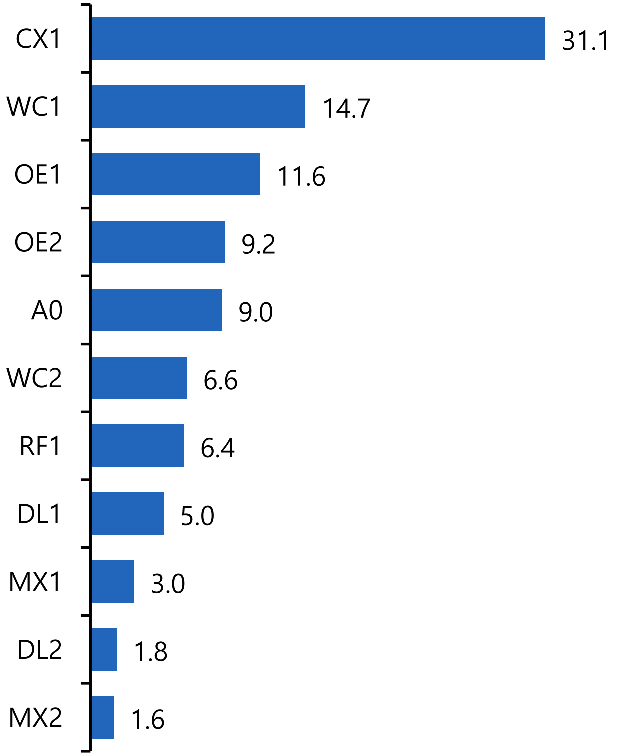

Stage 5 C3(Actor) 행동 분포(%)

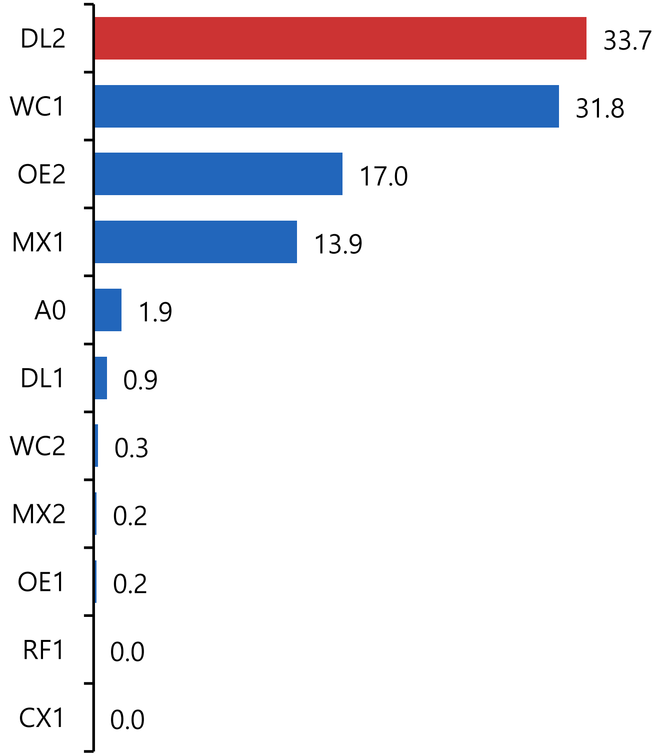

Stage 6 평가 결과 - Oracle α Δnoop

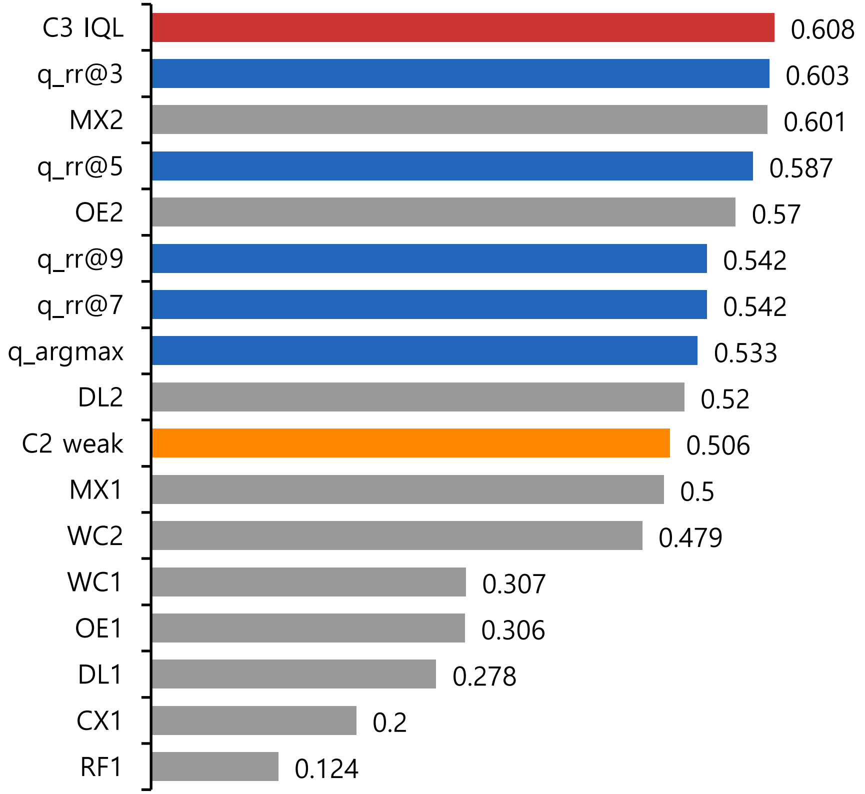

최종 실험 – 42) Stage 3 ~ 5 seed 5

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0.45 L=0.45
2·4	Mode	S2:run_before_stage3 / S4:train
3	Encoder	Batch 512 (30ep) / **seed 5**
4	CB / FB	β=0.999 / p=0.5 / **seed 5**
5	γ/τ/β	0.6 / 0.85 / 15 / **seed 5**
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

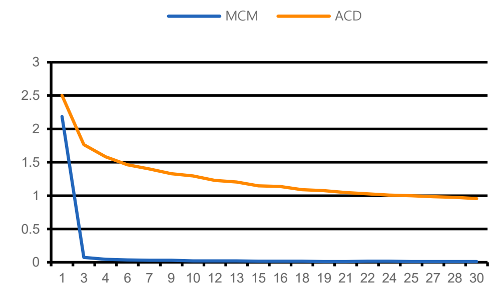

Stage 4 Loss (80ep)

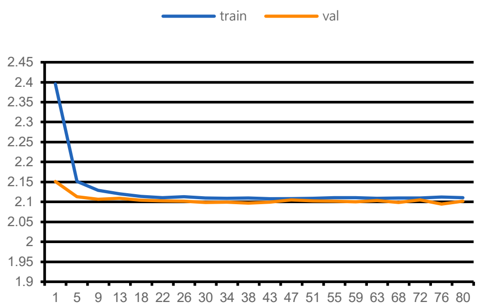

Stage 5 Loss (80ep)

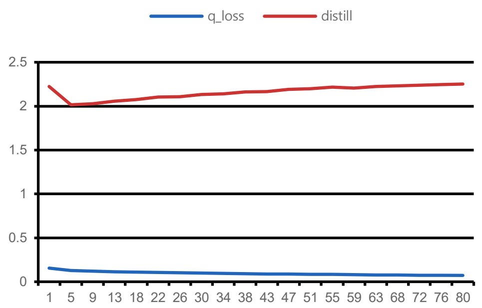

Stage 4 BC 행동 분포(%)

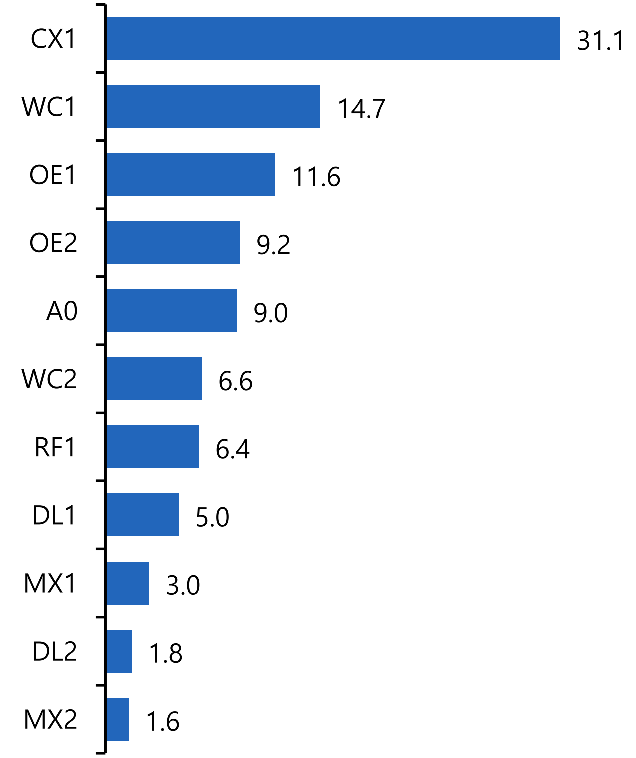

Stage 5 C3(Actor) 행동 분포(%)

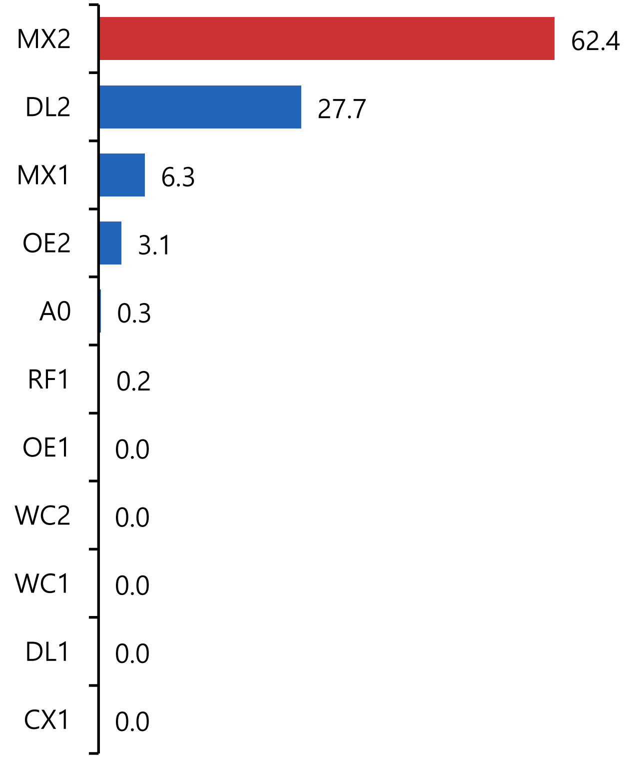

Stage 6 평가 결과 - Oracle α Δnoop

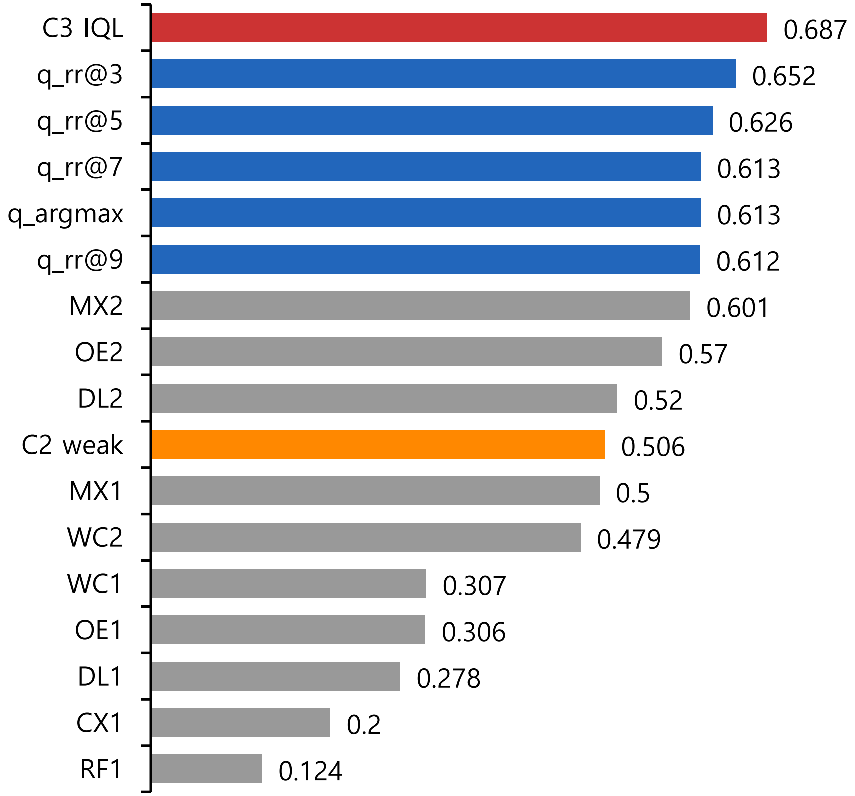

최종 실험 – 43) Stage 3 seed 1 / Stage 4 ~ 5 seed 2

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0.45 L=0.45
2·4	Mode	S2:skip / S4:train
3	Encoder	skip (30ep) / seed 1
4	CB / FB	β=0.999 / p=0.5 / seed 2
5	γ/τ/β	0.6 / 0.85 / 15 / seed 2
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

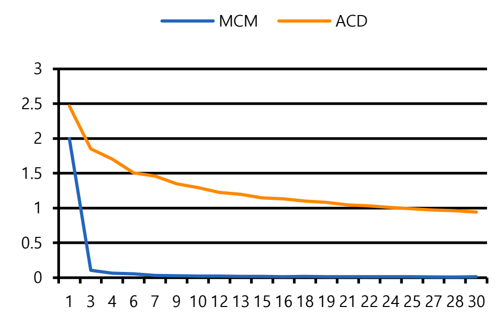

Stage 4 Loss (80ep)

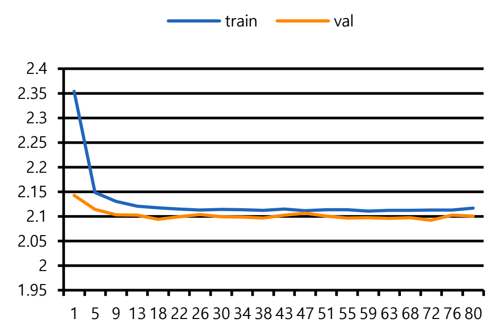

Stage 5 Loss (80ep)

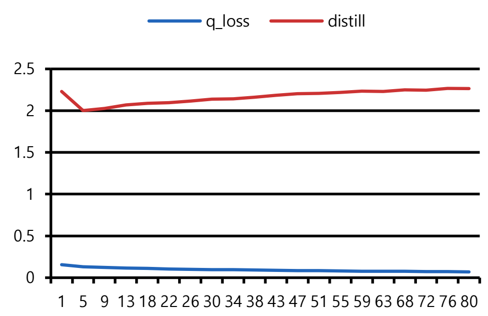

Stage 4 BC 행동 분포(%)

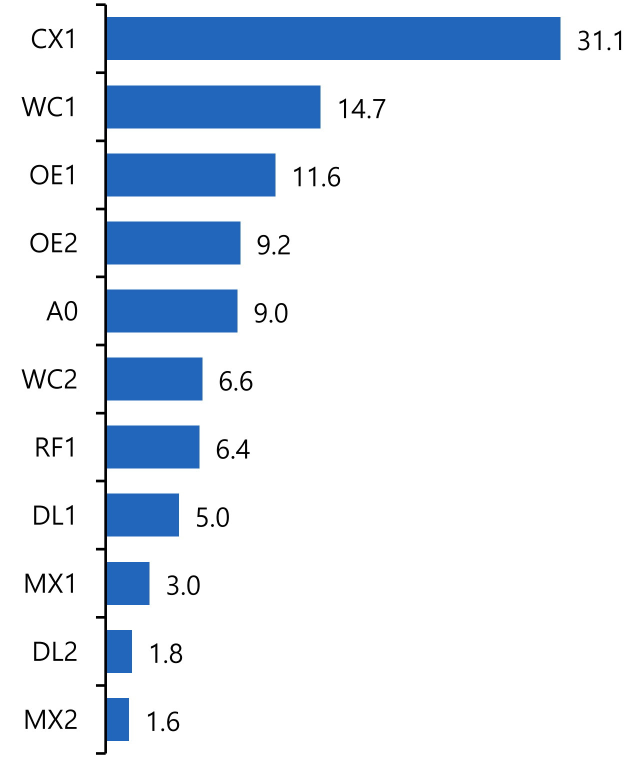

Stage 5 C3(Actor) 행동 분포(%)

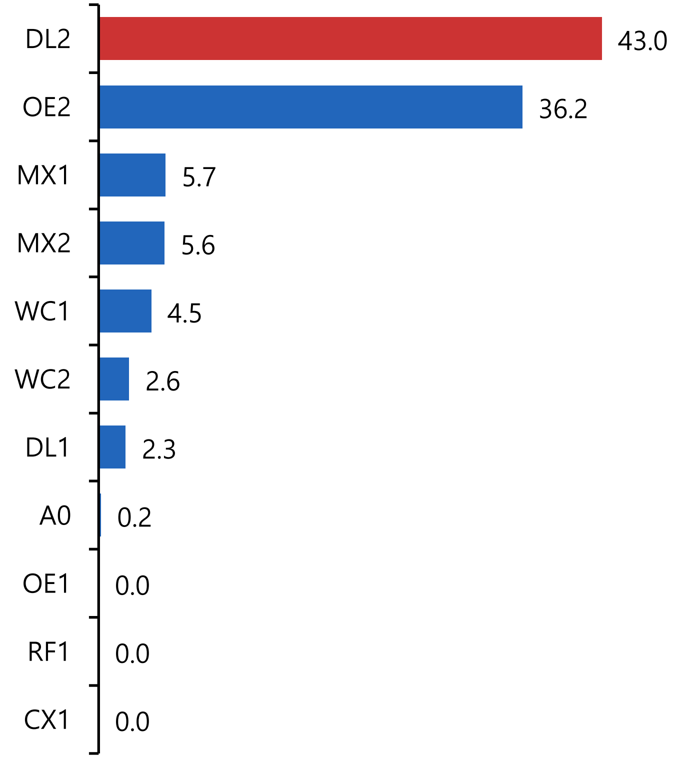

Stage 6 평가 결과 - Oracle α Δnoop

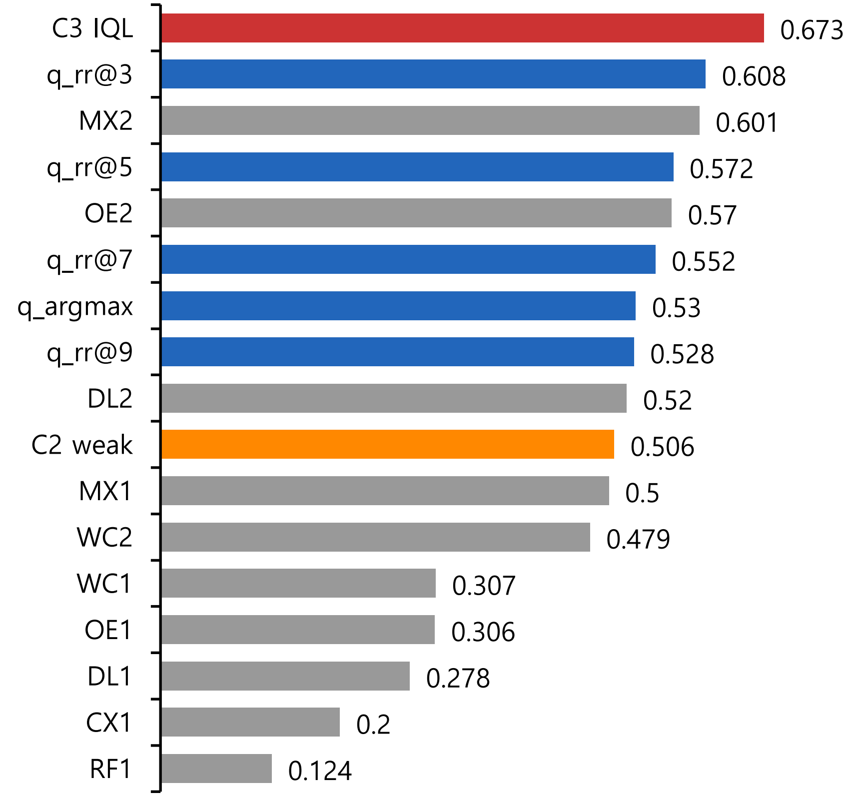

최종 실험 – 44) Stage 3 seed 2 / Stage 4 ~ 5 seed 1

Hyperparameter

Stage	항목	값
2	Reward	ρ=0 M=0.05 F=0.45 L=0.45
2·4	Mode	S2:skip / S4:train
3	Encoder	skip (30ep) / **seed 2**
4	CB / FB	β=0.999 / p=0.5 / **seed 1**
5	γ/τ/β	0.6 / 0.85 / 15 / **seed 1**
5	Distill / Critic / selec	λ=1.5 / cross_attention / pareto
5·6	S5 / Eval	train (lr=0.0001) / 575

Stage 3 Loss (30ep)

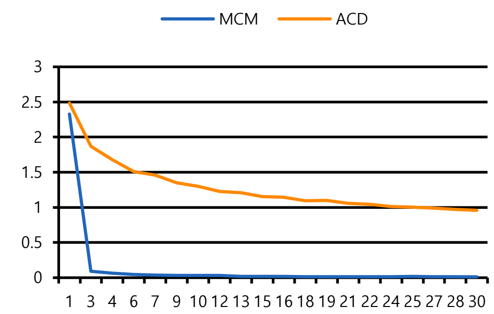

Stage 4 Loss (80ep)

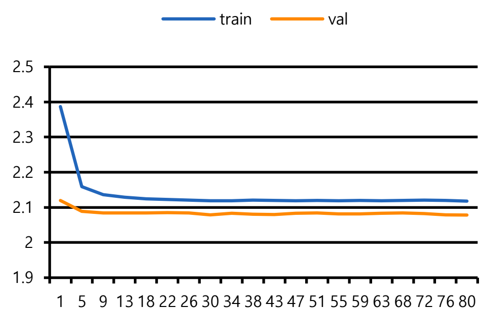

Stage 5 Loss (80ep)

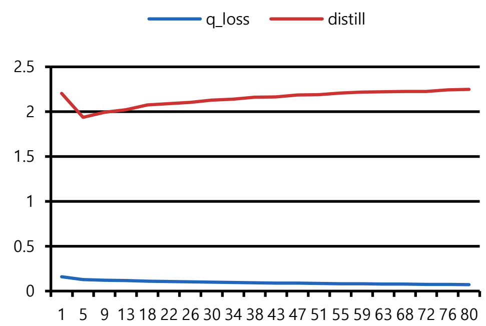

Stage 4 BC 행동 분포(%)

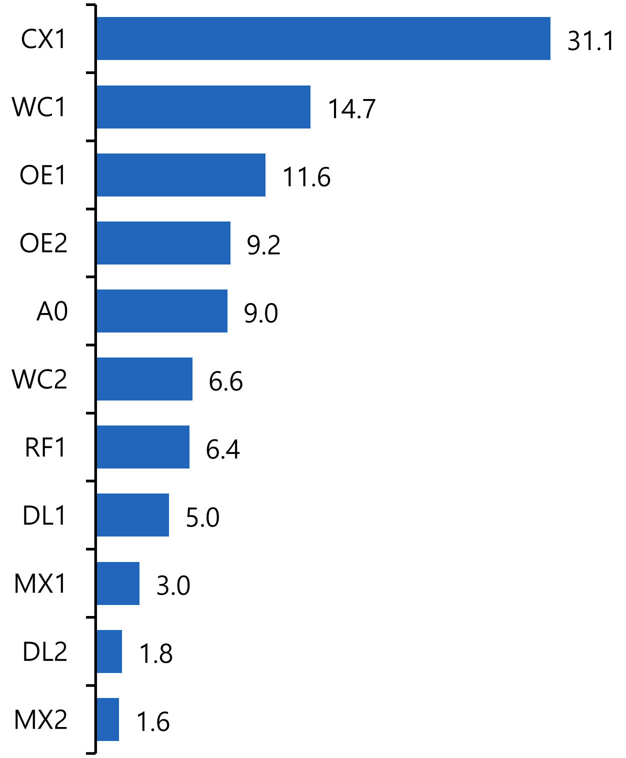

Stage 5 C3(Actor) 행동 분포(%)

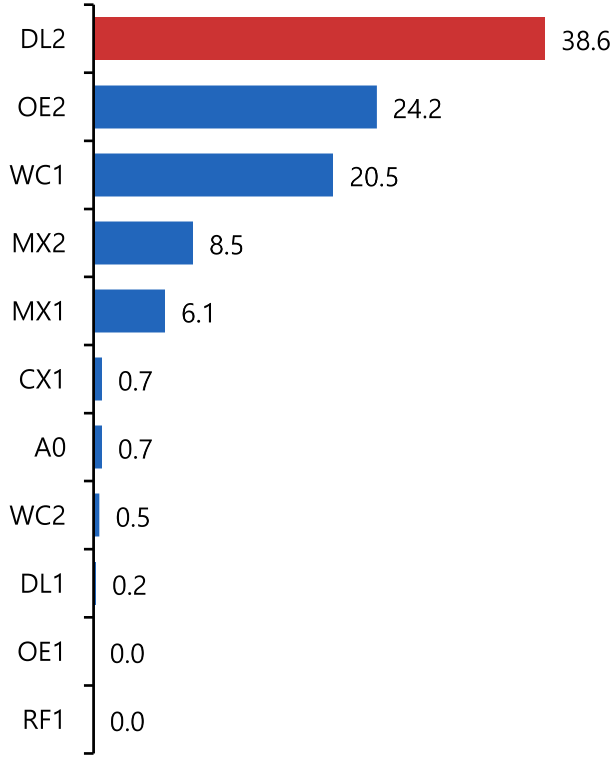

Stage 6 평가 결과 - Oracle α Δnoop